

Fixed-K Shrinkage Bayesian Transition Network Topic Model Inference with AWSGLD

고정-K 축소 베이저안 전이 네트워크 토픽 모형의 AWSGLD 추론

김다연

제1저자

고려대학교 빅데이터사이언스학과 석사과정

전수영 · 교신저자, 빅데이터사이언스학부 교수

1 Background

LDA 등 고전 토픽모형은 문서 내 단어를 **교환가능(exchangeable)**으로 가정해 문장 단위 토픽 전개를 다루지 못함

TNTM — 각 문장에 단일 잠재 토픽을 부여, 문장 간 전이를 마르코프 전이행렬로 모형화. **토픽 흐름(topic flow)**과 토픽 네트워크를 직접 추론

2 Motivation

- 토픽 수 고정 K**를 사전에 정해야 하며, 활성 토픽 수가 작을 때 해석 불안정
- Simplex 제약** Dirichlet 모수는 simplex 공간 위에 있어 합이 1인 제약
- 확장성** full-batch 사후 시뮬레이션이 대규모 코퍼스에서 비효율

3 Problem & Goals

- 기존 문제** EM알고리즘은 로컬트랩에 머무는 점추정만 제공하고, Gibbs는 멀티모달 사후의 단일 모드에 갇힘
- 목표** 문장 수준 토픽 흐름 구조는 유지한 채, 에너지 지형을 적응 가중하여 로컬트랩을 탈출하는 AWSGLD를 적용해 전이 토픽 모형(BNTM)의 사후분포 추론

4 Proposed Model — BNTM

문서 d , 문장 s , 각 문장에 단일 잠재 토픽 $g_{d,s} \in \{1, \dots, K\}$, $x_{d,s} \sim \text{Multinomial}(n_{d,s}, \beta_k)$

① 전역 토픽 가중치 — 희소(축소) **DIRICHLET** 사전
 $\pi \sim \text{Dirichlet}(\gamma/K, \dots, \gamma/K)$, $0 < \gamma < 1$

② 로지스틱-정규 모수화 — 무제약 **EUCLIDEAN** 공간
 $T_{:,j} = \text{softmax}^*(\eta_j)$, $\beta_k = \text{softmax}^*(\zeta_k)$

③ 결합 사후분포

$$p(\pi, \eta, \zeta, g|X)$$

$$\propto p(\pi) \prod_{j=1}^K p(\eta_j|\pi) \prod_{k=1}^K p(\zeta_k) \prod_{d=1}^D p(g_{d,1}|\pi) \prod_{d=1}^D \prod_{s=2}^{S_d} p(g_{d,s}|g_{d,s-1}, T) \prod_{d=1}^D \prod_{s=1}^{S_d} p(x_{d,s}|g_{d,s}, \beta)$$

5 Hybrid Inference

AWSGLD (*Adaptive Weighted SGLD*). 사후 에너지를 구간별로 나눠 적응 가중
→ **다봉 사후 평탄화**로 SGLD의 **로컬트랩 탈출**


- ① 토픽 수열 $g \rightarrow$ MH-Gibbs
- ② 축소 가중치 $\pi \rightarrow$ 켈레 Dirichlet (Keff 임계값으로 결정)
- ③ 연속 $(\eta, \zeta) \rightarrow$ AWSGLD

Algorithm — MH + AWSGLD update for $\theta = (\eta, \zeta)$

- Input:** K, γ, τ , step sizes $\{\varepsilon_m\}$, weight step sizes $\{\omega_m\}$, partition $\{u_\ell\}$.
- Initialize $(g, \pi, \eta, \zeta, \rho)$.
- for** $m = 1, \dots, M$ **do**
- $(T, \beta) \leftarrow \text{softmax}^*(\eta, \zeta)$.
- (MH) Update g by Metropolis-Hastings given (π, T, β) .
- $(\pi) \pi \sim \text{Dirichlet}(\gamma/K + n_1, \dots, \gamma/K + n_K)$.
- Minibatch B_m : energy $\tilde{U}_m$, gradient $\tilde{\nabla} U_m$, region $\tilde{J}_m$;
- $\Psi_m = 1 + \frac{\kappa\tau}{\Delta u} [\log \rho_m(\tilde{J}_m) - \log \rho_m(\tilde{J}_m - 1)]$.
- (AWSGLD) $(\eta, \zeta) \leftarrow (\eta, \zeta) - \varepsilon_m \frac{D}{|B_m|} \Psi_m \tilde{\nabla} U_m + \sqrt{2\varepsilon_m \tau} e_m$.
- (Weights) $\rho(\ell) \leftarrow \rho_m(\ell) + \omega_m \rho_m(\tilde{J}_m) [\mathbf{1}\{\ell \geq \tilde{J}_m\} - \rho_m(\ell)]$.
- Output:** posterior samples of (π, T, β, g) and $K_{\text{eff}}(\delta)$.

AWSGLD

[4] Deng (2022)



6 Contributions

핵심 질문

Q1 로지스틱-정규가 Dirichlet 대비 토픽·전이망 회복을 개선하는가?


Q2 AWSGLD가 로컬트랩·시드 민감도를 줄이는가?

7 Results

EXP 1 모형 비교 — Dirichlet-BNTM vs 로지스틱-정규-BNTM (추론: AWSGLD 고정)

Variant	Method	JS ↓	Hell ↓	π -MSE ↓	T-MSE ↓	AUC ↑	Top10 ↑	g-Acc ↑	Ppl ↓
S1 Dirichlet	T-β를 Dirichlet에서 생성, simplex 기반 기존 구조에 유리한 환경								
	Dirichlet	0.13	0.38	0.01	0.02	0.94	0.68	0.65	201
	Logit Normal	0.11	0.35	0.00	0.01	0.92	0.88	0.98	146
S2 Logit Normal	잠재 Gaussian η*, ζ*에서 softmax*로 생성, 성분 간 상관이 존재해 Dirichlet가 구조적으로 포착하지 못하는 환경								
	Dirichlet	0.13	0.38	0.01	0.03	0.61	0.44	0.30	2323
	Logit Normal	0.03	0.17	0.00	0.01	0.95	0.89	0.96	1215

EXP1 해석. Logit Normal Model AWSGLD (M2)는 Dirichlet/LN truth 양쪽에서 안정적으로 작동



EXP 2 탐색 안정성 — regime E1·E2·E3·E4 (모형: Logit Normal 고정)

Regime	Method	JS ↓	Hell ↓	π -MSE ↓	T-MSE ↓	AUC ↑	Top10 ↑	g-Acc ↑	Ppl ↓
E1 기본	Mild overlap — anchor 단어가 뚜렷이 구분되는 약한 구조의 기준 환경								
	AWSGLD	0.03	0.17	0.00	0.01	0.95	0.89	0.96	1215
	SGLD	0.05	0.21	0.00	0.01	0.89	0.84	0.94	1266
	cycSGLD	0.04	0.19	0.00	0.01	0.90	0.86	0.94	1246
	CSGLD	0.05	0.22	0.00	0.01	0.87	0.79	0.90	1276
	MH-Gibbs	0.05	0.23	0.00	0.01	0.90	0.81	0.80	1285
E2 β 중첩	Severe overlap — 토픽-단어 분포가 심하게 겹치는 환경								
	AWSGLD	0.03	0.18	0.00	0.00	0.95	0.88	0.90	1796
	SGLD	0.05	0.21	0.00	0.01	0.85	0.77	0.85	1858
	cycSGLD	0.04	0.19	0.00	0.01	0.89	0.82	0.90	1823
	CSGLD	0.04	0.21	0.00	0.01	0.87	0.80	0.85	1852
	MH-Gibbs	0.05	0.21	0.00	0.01	0.93	0.86	0.78	1886
E3 T 중첩	Weakly identifiable T — 블록 내 상관 0.6으로 전이행렬 행들을 거의 공선으로 만들어 전이 패턴이 교환가능에 가까워지는 환경								
	AWSGLD	0.03	0.17	0.00	0.01	0.94	0.85	0.88	1222
	SGLD	0.05	0.21	0.00	0.01	0.89	0.77	0.93	1279
	cycSGLD	0.04	0.19	0.00	0.01	0.91	0.82	0.96	1246
	CSGLD	0.06	0.23	0.01	0.01	0.83	0.71	0.88	1304
	MH-Gibbs	0.05	0.22	0.00	0.02	0.84	0.80	0.68	1283
E4 희소 토픽	Rare topic — 일부 활성 토픽의 진실 비중을 $\pi^* \approx 0.02$ 로 극소화해, 탐색 실패 시 통째로 놓치기 쉬운 환경								
	AWSGLD	0.05	0.20	0.00	0.01	0.96	0.80	0.96	1220
	SGLD	0.06	0.24	0.00	0.02	0.89	0.70	0.92	1268
	cycSGLD	0.05	0.22	0.00	0.01	0.95	0.76	0.99	1232
	CSGLD	0.07	0.24	0.01	0.02	0.88	0.70	0.90	1286
	MH-Gibbs	0.06	0.24	0.00	0.02	0.93	0.78	0.76	1285

EXP2 해석. AW M2가 4 변형 (mild/β-overlap/T-block/rare) 모두에서 가장 우수하며, 멀티모달이 강할수록 AW와 SGLD 격차 커짐

9 Conclusion

- TNTM에 토픽 수를 스스로 찾는 **고정-K 축소 BNTM**을 제안
- 전이행렬·토픽-단어 분포를 **로지스틱-정규**로 무제약 공간에 올려 경사 기반으로 추론
- AWSGLD** 추론으로 멀티모달 사후분포의 Local Trap을 완화