경력기술서

# 김다연



abcde0405@naver.com | 포트폴리오 kim-da-yeon.github.io | GitHub Kim-Da-yeon

## 핵심 요약

**논문 초록 114,066건과 특허 21,028건을 직접 추출해 3년 뒤 성장 기술을 예측한(AUC 0.876 · 0.746) Data Scientist입니다.**

**경험 1. 서울시 택시 수요 · 공급 분석 | 통계학술제 최우수상**

- 공공 데이터 6종을 병합해 25개 자치구를 6개 군집으로 분류하고 공차율 웹과 택시 서비스 개선 방향 제시
- 팀 3명 중 분석 코드 구현과 QGIS 공간 시각화 담당

**경험 2. 임베디드 기술 성장 예측 | AUC 논문 0.876 · 특허 0.746**

- Google BigQuery에서 SQL로 미국 특허 21,028건을, OpenAlex에서 논문 초록 114,066건을 직접 추출해 3년 뒤 성장할 기술 토픽 예측 (토픽 모델까지 기준연도별 재추정 시 0.828 · 0.691)
- 한국연구재단 과제 연구책임자로 데이터 수집 · GPU 샘플러 구현 · 미래 정보를 막는 rolling-origin 평가 설계

**경험 3. 스마트팜 데이터 분석 인턴 | 검정으로 데이터 한계 확인 · 후속 측정 설계 제안**

- 생육 데이터(개체 18개 · 20일)로는 영향요인을 규명할 수 없음을 검정으로 확인하고 후속 센서 · 카메라 배치와 측정 항목을 현업과 협의해 제안
- 데이터 분석팀이 없는 회사에서 지도교수님 조언을 받고 현업 팀원들에게 분석 내용을 설명하며 진행

## 학력

2025.03 – 2027.02 (졸업예정) **고려대학교 일반대학원 빅데이터사이언스학과 석사과정**

2021.03 – 2025.02 **고려대학교 세종캠퍼스 빅데이터사이언스학부 학사** · 융합전공 자율주행시스템학과

## 실무 경험

2023.12 – 2024.04
인턴 2명

### JERESFARM · 데이터 분석 인턴

스마트팜 Python · statsmodels(VAR · VECM) · scikit-learn · Lasso

**분석 인력이 없던 농장에서 생육 데이터(개체 18개 · 20일)로는 영향요인을 규명할 수 없음을 검정으로 확인하고, 후속 센서 · 카메라 배치와 측정 항목을 현업과 협의해 제안**

| | |
|---|---|
| 문제 | 센서 변수 29개에 비해 생육 크기는 개체 18개 · 20일 · 하루 1회 줄자 측정. 사내 데이터 분석 인력 없음 |
| 협업 | 데이터 분석팀이 없는 회사에 학부생 인턴 2명으로 합류. 데이터 쪽은 지도교수님께 조언을 구하고 현업 팀원들에게 분석 내용을 설명하며 진행. 소통에 시간이 오래 걸렸지만 서로 다른 도메인을 배움 |
| 분석 | 로그 차분 후 ADF 정상성 확인. VAR에서 유의수준 0.05의 유의 변수 없음 → 공적분 확인 후 VECM 재검정. Lasso(α=1) 변수 17개, 테스트 $R^2$ 0.99 |
| 한계→해결 | 테스트 개체가 2개뿐이라 $R^2$ 0.99는 신뢰할 수 없다고 판단, 원인을 종속변수 관측 부족으로 규명 → 다음 작물(딸기) 농장 사전 조사 · 센서 · 카메라 배치와 측정 항목 협의 |
| 다시 한다면 | 모델링 전에 개체별 센서와 시간대가 맞는 데이터를 먼저 확보 |

2024 1학기
팀 3명

### 환경에 따른 최적 작물 예측 (JERESFARM 인턴 후속)

**통계학과 머신러닝 PBL · 결과 · 코드 농장 전달** Python · Pandas · scikit-learn · LightGBM · Feature Importance · PDP

**농촌진흥청 공공 데이터(원본 827,080건, 학습 · 평가 90,000건)로 작물 5종과 랜덤 클래스 분류 모델 6개를 비교, Test F1 상위 앙상블 3개 중 격차가 가장 작은 LightGBM(Test 0.81, 작물 5종 평균 약 0.77, 격차 0.03 vs Bagging 0.17 · RF 0.21)을 선정하고 결과와 코드를 JERESFARM에 전달**

**문제** 인턴 때 생육 영향요인을 규명하지 못한 문제를 수업 PBL에서 공공 데이터로 다시 정의 → 환경으로 작물을 예측하면 작물별 최적 환경과 토지에 맞는 작물을 함께 찾을 수 있음

**해결** 공통 환경변수 5개 선정, 원본 827,080건을 239,192건으로 정제, 클래스별 15,000건으로 맞춰 Decision Tree · SVM · K-NN · Bagging · Random Forest · LightGBM 비교

**결과** Train → Test F1 LightGBM 0.84 → 0.81 · Bagging 0.98 → 0.82 · RF 1.00 → 0.79. 영향력 온도 > 일사량 > $CO_2$, 임계 구간은 작물별로 다름(예: 참외 · 오이 25°C)

**다시 한다면** 토양 등 환경 변수와 작물 데이터 추가. 환경 변수 5개만으로 작물 적합성을 판단할 수 있는지가 남은 의문

## 대표 연구 성과 순

2025 – 2026
연구책임자 · 제1저자

### 전이 네트워크 토픽 모델을 이용한 임베디드 기술의 성장 예측

**한국연구재단 석사과정생연구장려금 과제 성과 · 투고 예정** Python · GPU 샘플러 · Google BigQuery(SQL) · OpenAlex · L2 로지스틱 회귀

**논문 초록 114,066건 · 미국 특허 21,028건(BigQuery SQL로 직접 추출)으로 3년 뒤 성장할 기술 토픽을 예측해 AUC 논문 0.876 · 특허 0.746(무작위 0.5, 토픽 모델까지 기준연도별 재추정 시 0.828 · 0.691), 성장 이유를 토픽 전이로 설명**

**목표** 임베디드 분야에서 3년 뒤 크게 성장할 기술 토픽을 정확히 예측하고, 성장 이유를 문장 사이의 토픽 전이 구조로 설명

**문제** 기존 연구는 토픽 비중 · 키워드 · 인용 · 특허 지표를 썼고, 신경망 예측은 정확해도 성장 이유를 설명하기 어려움. 기존 TNTM은 전이행렬이 전 기간에 하나뿐

**내 역할** 데이터 수집 · 정제 · GPU 샘플러 구현 · 변수 정의 · 평가 설계 · 논문 작성

**해결** 연도별 전이행렬을 계층 사전분포로 묶어 TNTM 확장(K=40, AWSGLD). 전이 네트워크에서 유입 · 자기전이 · 유입 출처 · 구조 변화 변수 8개를 직접 정의하고 데이터 변수 14개와 함께 예측 모형 구성

**데이터** Google BigQuery 공개 특허 데이터셋에서 SQL로 미국 특허 21,028건(524,424문장)을, OpenAlex에서 임베디드 관련 12개 구문으로 논문 초록 114,066건을 직접 추출 · 정제

**결과** 문서 완성 perplexity 논문 TNTM 1172 · HTMM 1223 · LDA 2149. 성장 기준을 상위 10% · 30%로 바꿔도 AUC 논문 0.896 · 0.881 유지. 유입 증가(+0.31) · 자기전이(−0.28)가 주요 계수 → 다른 토픽에서 문장이 넘어오는 토픽이 성장

**한계→해결** 시점을 섞은 교차검증은 미래 정보가 섞여 성능이 부풂 → 과거 자료로만 학습하는 rolling-origin 평가(논문 13개 · 특허 11개 결과연도). 토픽 모델까지 기준연도마다 다시 추정해 기준연도 이후 문헌을 빼도 AUC 논문 0.828 · 특허 0.691

2025 – 2026
제1저자 · 공저 2인

### Fixed-K Shrinkage Bayesian Transition Network Topic Model with AWSGHMC Inference

**SCI급 학술지 투고 예정** Python · NumPy · SG-MCMC(AWSGHMC · SGHMC · SGLD) · MH-within-Gibbs · 베이지안 추론

**기존 토픽 모델의 한계를 보완한 새 토픽 모델 BNTM과 샘플러 AWSGHMC를 직접 설계하고, 정답을 아는 모의실험 데이터(환경 5종)를 생성해 검증 · 실데이터(FAERS) 문서 완성 perplexity를 HTMM 54.99 → 32.13(41.6%↓)으로 낮추고, 정답 20토픽 환경의 추정 토픽 수를 SGHMC 15.4개 → AWSGHMC 20.0개로 정확 복원 · 포스터논문 장려상**

| | |
|---|---|
| 목표 | ① 문장 순서가 있는 텍스트를 LDA · HTMM보다 잘 설명하는 모델 ② 멀티모달 사후분포를 안정적으로 추정하는 샘플러. 샘플러를 고정하고 모델을, 모델을 고정하고 샘플러를 바꿔 각각 검증 |
| 문제 | LDA는 문장 순서를 무시하고 HTMM은 전이를 값 하나로 요약, TNTM은 토픽 수를 미리 정하고 확률 단체 제약으로 경사 기반 추론이 어려움. 선행 연구(AWSGLD-TNTM)에서도 seed에 따라 토픽 구조가 크게 달라져 원인을 모델 구조로 판단 |
| 내 역할 | 모델 · 샘플러 · 모의실험 데이터 생성기 설계, 구현, 실험, 논문 작성. 지도교수 교신 |
| 해결 | Logistic-Normal 모수화(Simplex 제약 제거) + Sparse Dirichlet Prior(활성 토픽 수를 데이터가 결정) + AWSGHMC(멀티모달 사후분포의 로컬 트랩 탈출)를 결합한 새 모델 BNTM과 샘플러를 설계 |
| 검증 설계 | 토픽 모델은 정답 라벨이 없어 결과 검증이 어려움 → 정답 토픽 · 전이 · 비중을 정해 둔 모의실험 데이터 생성기를 직접 설계. 환경마다 어려움 하나만 키운 5종(기본 · 초과 용량 K 40 · 다수 토픽 20 · 소표본 200건 · 대규모 10,000건) |
| 모델 비교 | 5개 환경 모두 BNTM의 문서 완성 perplexity가 모든 관찰 길이에서 HTMM보다 낮고 LDA보다 크게 낮음 (40토픽 환경 HTMM 대비 약 20포인트) |
| 샘플러 비교 | AWSGHMC만 5개 환경 모두 K 정확 복원. 다수 토픽 환경(정답 20)에서 SGHMC 15.4 · SGLD 14.7 · MH 23.4, 토픽-단어 Hellinger 거리 0.09~0.17로 최소 |
| 실데이터 | 문서 완성 perplexity FAERS 이상반응 보고서 14,316건 BNTM 32.13 · HTMM 54.99 · LDA 78.23, NTSB 항공사고 서술문 17,733건 472.1 · 498.5 · 1,090.7. 같은 모델에서 샘플러 비교 시 AWSGHMC가 두 데이터 모두 perplexity 최저(FAERS는 전체 배치 MH 32.30과 근접, MH는 반복당 비용이 큼) |
| 한계→해결 | 모의실험 기준으로 맞춘 샘플러 설정이 실데이터의 큰 에너지 범위에서 작동하지 않음(한 구간에 갇힘) → 구간 폭을 데이터 에너지 범위에 비례하도록 바꿔 정상화 |
| 다시 한다면 | 수동으로 조정한 에너지 구간 폭을 말뭉치에 맞춰 자동으로 정하는 규칙부터 만듦 |

포스터

2025 – 2026
제1저자

### AWSGLD를 이용한 전이 네트워크 토픽 모델 추론

**한국자료분석학회지 28(1) 109–121 게재** Python · AWSGLD · TNTM

**TNTM 추론을 MH-Gibbs + AWSGLD로 바꿔 IMDB 리뷰 1,000문장 실험에서 토픽 다양성 SGD 0.48 → AWSGLD 0.96(SGLD도 0.96), 문장마다 무작위 단어 50개를 넣은 조건의 perplexity는 SGLD보다 약 8배 낮음 (m=30)**

| | |
|---|---|
| 목표 | TNTM의 추론을 확률적 기울기 기반 표본추출로 대체해, 잡음이 있는 텍스트에서도 토픽 전이 구조를 추정 |
| 내 역할 | 추론 수식 유도, 구현, 실험, 논문 작성. 지도교수 교신 |
| 해결 | 문장 토픽은 MH-Gibbs, 전이행렬 · 단어-토픽 분포는 AWSGLD로 추론. 추론에 필요한 미분식을 유도해 구현하고, 문장마다 무작위 단어 0 · 50 · 100개를 넣어 SGD · SGLD와 비교 |
| 한계→해결 | 토픽 수 K를 미리 정해야 하고 잡음이 커지면 이점이 줄어듦 → 후속 연구 BNTM에서 희소 사전분포와 AWSGHMC로 해결 |

논문 DOI

2025
제1저자

### 자율주행 도메인에서 LoRA 기반 sLLM 파인튜닝 연구

**한국자료분석학회지 27(3) 769–780 게재** PyTorch · Transformers · PEFT(LoRA) · Phi-4-mini · RAG

**자율주행 판단을 설명하는 LoRA FT-Driver(Phi-4-mini 3.8B, 파라미터 0.01% 학습)를 제안해 RAG 대비 ROUGE-1 0.0888 → 0.1495(68.4%↑), 교통법규 위반 분류 Accuracy RAG 최고 0.540 → 0.745**

| | |
|---|---|
| 목표 | 자율주행 차량이 내린 판단을 사람이 이해할 수 있게 설명하는 실시간 응답 시스템 |
| 문제 | RAG는 도메인 간 일반화는 좋지만 특정 도메인 안에서 정확성 · 응답 일관성이 떨어지고, 차량 내 임베디드 자원에서는 전체 파라미터 파인튜닝이 부담 |
| 내 역할 | 모델 선정, LoRA 학습 설계, RAG 비교 실험, 논문 작성 |
| 해결 | BDD-X(주행 설명 주석 26,228개)로 LoRA 파인튜닝, RAG와 같은 조건에서 정량 비교 |
| 결과 | ROUGE-1 0.0888 → 0.1495(68.4%↑), 응답 시간 1.145초(RAG k=1 1.099초). 교통법규 위반 유형 분류(약 7만 건, 재학습 없이 프롬프트 예시 방식)로 넓힌 실험에서 Accuracy 0.745 · Macro F1 0.731(RAG 최고 0.540 · 0.532) |
| 다시 한다면 | 학습 데이터의 양과 범위가 제한적이었으므로 주석 자동화와 멀티모달 데이터셋 구성부터 진행 |

논문 DOI

## 프로젝트 직무 관련 · 성과 순

2023
팀 3명 · QGIS 시각화 · 분석 코드

### 택시 수요 분석을 통한 택시 서비스 개선 방안 마련

**통계학술제 최우수상** R · 계층적 군집분석(Ward.D) · QGIS · 공공 데이터 병합

**공공 데이터 6종을 직접 구해 병합하고 공차율 웹을 만들어 서울 25개 자치구를 6개 군집으로 나누고, 택시 서비스 개선 방향을 정리해 통계학술제 최우수상**

| | |
|---|---|
| 문제 | 선행 자료 조사와 뉴욕 택시 데이터를 분석한 교수님 자문 → 택시 수요 · 공급 비교에는 대중교통 공급과 유동인구를 함께 봐야 한다고 판단 |
| 해결 | 빅데이터캠퍼스(택시운영분석 · 표준노드아이디DB) · 국가공간정보포털(행정구역) · 서울 열린데이터광장(유동인구 2종) 등 데이터 6종 병합. 요일별 승차건수, 면적당 대중교통 분포율, 유동인구 대비 역 · 정류장 분포 계산, 공차율 지표 설계 후 3개 변수 증감 조합 + 계층적 군집분석 |
| 결과 | 군집별 특성 정리: 강남 · 서초(전 지표 상승), 중구(대중교통 분포 낮음 · 유동인구와 택시 이용 높음), 저조 지역(광진 · 중랑 · 도봉 등). QGIS 지도와 공차율 조회 웹 화면 제작. 데이터는 2015.1–2016.4 기준 |
| 다시 한다면 | 집계치로 적정 기본요금과 거리요금을 책정하는 분석까지 진행 |

포스터

2025
팀 4명 · 수집 · 지표 정의 · 발표

### 대학 기숙사 운영 유형 분류 (대학알리미 공시 데이터)

**2025 대학알리미 데이터 아이디어 공모전 본선 진출(수상 없음)** Python · 공시 데이터 전처리 · 지표 설계

**수용률 · 이익률 지표를 정의해 대학 기숙사를 4개 운영 유형으로 분류하고 유형별 특징 · 6개 개선안을 제시, 공모전 본선 진출(수상 없음)**

| | |
|---|---|
| 내 역할 | 팀 4명 중 데이터 수집 · 지표 정의 · 발표 담당. 팀원의 로지스틱 회귀 결과를 비용 개선안에 연결 |
| 결과 | 수용률 5년 정체(23.2~23.8%). 기준선 수용률 30% · 이익률 20%로 공공복지형 · 균형형 · 수익중심형 · 형식적 운영형 분류, 공립은 전부 형식적 운영형 |

2024
팀 2명

### 베이지안 기법을 이용한 강수예보 정확도 분석

**학부 베이지안 PBL(A+)** Python · 베이지안 갱신 · 베이즈 팩터 검정

**기상청 예보 약 18만 건(세종시 조치원읍)으로 강수확률을 사후확률로 다시 계산해, 10시간 예보에서 강수확률 70% 이상이면 비가 올 확률 0.82~0.95, 0~30%면 0에 가깝다는 판단 기준 도출 · 과목 A+**

**문제** 강수예보가 자주 틀리는 이유가 궁금해 직접 잡은 주제. 예보 정확도는 90%에 가깝지만 기상청 강수 적중률은 63%(국정감사 발표), 강수확률을 어느 값부터 믿을지 기준 없음

**내 역할** 사전확률 설계, 사후 갱신, 베이즈 팩터 검정, 결론 담당. 데이터는 공동, 가능도 · 신뢰구간은 팀원 담당

**해결** 예보시간 × 강수확률 구간 결합분포로 가능도 구성, 강수확률을 사전확률로 5단계 갱신, 베이즈 팩터 ≥ 1을 판정 기준으로 설정

**결과** 10시간 예보에서 비가 올 사후확률 60~69% 구간 0.54 · 70~79% 0.88 · 80~89% 0.82 · 90~100% 0.95, 베이즈 팩터 60~69% 1.18 · 70~79% 7.36 · 90~100% 21.04

**한계→해결** 50시간 예보는 사후확률이 낮고 신뢰구간이 넓음 → 결론을 신뢰구간이 좁은 10~30시간 예보로 한정

2023
개인

### 잦은 배달 음식 섭취가 건강에 미치는 영향

**학부 수업 프로젝트(A+)** R · 다중 로지스틱 회귀 · AIC 변수 선택 · K-means · 계층적 군집분석

**2022 식품소비행태조사 6,366명으로 식사 방법별 건강 오즈비를 추정해 단체급식 1.25 · 일반식당 1.19 · 집밥 1.14 · 배달 0.80을 밝히고, 배달 빈도가 높아도 식생활 역량이 높은 군집이 더 건강함을 확인 · 과목 A+**

**문제** 배달이 식생활 문화가 된 상황에서 배달 음식이 정말 건강에 해로운지, 배달을 먹으면서도 건강을 지키는 방법이 있는지 확인

**해결** 건강 상태를 종속변수로 다중 로지스틱 회귀(AIC 1995 → 1989로 변수 선택), 식생활 역량 10문항 + 배달 빈도로 K-means(덴드로그램 · Elbow로 k=4)

**결과** 편의점 식사도 오즈비 1.12로 긍정적, 배달 월평균 비용은 0.79. 배달을 자주 먹어도 식생활 역량이 높은 군집이 더 건강 → 아침 식사 · 가족과의 식사 같은 습관도 함께 봐야 함

2025.09 – 12
개인

### 국제 메타데이터 표준 통합 LLM 기반 그래프 증강 추천시스템

**수업 프로젝트(A+) · KIAT 표준전문인력양성 과제 성과** Python · LLM(LLMRec) · LightGCN · ISO 3166-1 · BCP 47 · 대응표본 t-검정

**LLM이 만든 메타데이터를 국제 표준으로 정규화해 표준 적합률 48.4% → 91.4%(43.0%p↑), 상호운용성 80.3%, 추천 성능 유의한 저하 없음 · 과목 A+**

**문제** LLMRec으로 만든 Netflix 메타데이터(17,366건)에서 같은 국가가 USA · United States · America로 나뉘어 시스템 간 결합 불가

**해결** ISO 3166-1 alpha-2 · BCP 47 정규화 레이어 설계, 필드별 형식 적합률 측정

**결과** country 표면형 1,166개 → 57개(95%↓), language 326개 → 52개(84%↓), column-shift 724건 자동 검출. LightGCN 10 seed 반복 · 대응표본 t-검정에서 Recall · NDCG · Precision 6개 지표 모두 $p > 0.05$

**다시 한다면** 사후 정규화 대신 구조화 출력으로 생성 시점에 표준 강제. 약 20%는 생성 단계 문제라 사후 정규화로 해결되지 않음

저장소

## 연구과제 참여

2025 – 2026 **TNTM을 활용한 임베디드 시스템 문서의 주제 흐름 분석** · 연구책임자 · 한국연구재단 석사과정생연구장려금 · RS-2025-25437035 → 「전이 네트워크 토픽 모델을 이용한 임베디드 기술의 성장 예측」 제1저자 투고 예정

2024 – 2027 **베이지안 추론을 위한 적응적 가중 SGMCMC 알고리즘** · 참여연구원 · 한국연구재단 · RS-2024-00352792 · 2차년도 샘플러 구현 · 실험 설계 · 결과 분석 전담 → 제1저자 논문 4편(게재 2 · 투고 예정 2)

2025 – 2026 **초격차산업기반표준전문인력양성** · 참여연구원 · KIAT · RS-2025-02215617 · 표준 프로젝트 2건(메타데이터 표준 정규화, TBT 규제 분석)

## 수상

| | |
|---|---|
| 2026 | **한국자료분석학회 하계학술발표대회 포스터논문 장려상** · Fixed-K Shrinkage Bayesian Transition Network Topic Model Inference with AWSGLD · 제1저자 |
| 2023 | **고려대학교 빅데이터사이언스학부 통계학술제 최우수상** · 택시 수요 분석 · 팀 3명 |
| 2023 | **미래모빌리티 및 세종지역혁신 아이디어 공모전 장려상** · Smart Green-STOP(압전 · 태양광 자가발전 스마트 정류소) · 3D 구현 담당 · 세종특별자치시 |

## 활동 · 리더십

| | |
|---|---|
| 2025.03 – 현재 | **DLM연구실 대표** · 구성원 간 소통 · 세미나 일정 · 공지 공유, 공동 연구 자원 · 안전 사항 관리 |
| 2025.03 – 09 | **학부생 연구원 프로그램 대학원생 멘토** · 에코업혁신융합대학사업단 · 멘티 1명과 연구 주제 구체화 · 방법론 선정 · 실험 설계를 함께 진행해 포스터 발표까지 완료 |
| 2023 · 2025 | **Python · Excel 실습 멘토** · 디지털리터러시(Python, 2025.03 – 12) · 글로벌역량멘토링(Excel, 2023.03 – 06) 수업에서 실습 오류 해결 · 기초 개념 설명 |
| 2023.02 – 07 | **예큐레이션(예산시장) 마케팅 서포터즈 5인 팀장** · 팀장 중심 업무 배분을 팀원별 자율 기획 · 실행 방식으로 바꿔 참여도 개선, 인스타그램 21건 · 유튜브 8건 제작, 팔로워 375명 · 대표 영상 조회 2,523회 |
| 2024.12 – 2025.01 | **미국 UNLV 해외연수 · CES 2025 참관** · AI+IoT Communication 과정 수료, 다양한 국적의 학생들과 토론 · 발표 |
| 2021.09 – 2022.06 | **뮤지컬 동아리 '캐스팅' 의상 · 분장팀장** · 팀원 3명과 배우 14명의 공연 준비 일정 조율 |

## 기술

| | |
|---|---|
| 언어 · 도구 | Python(Pandas), R, SQL(MySQL · Google BigQuery), Git, CUDA, Excel |
| ML · DL | PyTorch, TensorFlow, scikit-learn, Transformers, PEFT(LoRA · QLoRA), OpenPCDet, LangChain, Chroma |
| 통계 · 추론 | SGLD · SGHMC · AWSGLD · AWSGHMC · MH-within-Gibbs 구현, 시계열(VAR · VECM), 베이지안 검정 |
| 자격 | ADsP(데이터분석 준전문가, 2023.11) · OPIc IM1(2026.09) |