경력기술서

# 김다연

abcde0405@naver.com | 포트폴리오 kim-da-yeon.github.io | GitHub Kim-Da-yeon



## 핵심 요약

**논문 초록 114,066건과 특허 21,028건을 직접 추출해 3년 뒤 성장 기술을 예측한(AUC 0.876 · 0.746) Data Scientist입니다.**

**경험 1. 서울시 택시 수요 · 공급 분석 | 통계학술제 최우수상**

- 공공 데이터 6종을 병합해 25개 자치구를 6개 군집으로 분류하고 공차율 웹과 택시 서비스 개선 방향 제시
- 팀 3명 중 분석 코드 구현과 QGIS 공간 시각화 담당

**경험 2. 임베디드 기술 성장 예측 | AUC 논문 0.876 · 특허 0.746**

- Google BigQuery에서 SQL로 미국 특허 21,028건을, OpenAlex에서 논문 초록 114,066건을 직접 추출해 3년 뒤 성장할 기술 토픽 예측 (토픽 모델까지 기준연도별 재추정 시 0.828 · 0.691)
- 한국연구재단 과제 연구책임자로 데이터 수집 · GPU 샘플러 구현 · 미래 정보를 막는 rolling-origin 평가 설계

**경험 3. 스마트팜 데이터 분석 인턴 | 검정으로 데이터 한계 확인 · 후속 측정 설계 제안**

- 생육 데이터(개체 18개 · 20일)로는 영향요인을 규명할 수 없음을 검정으로 확인하고 후속 센서 · 카메라 배치와 측정 항목을 현업과 협의해 제안
- 데이터 분석팀이 없는 회사에서 지도교수님 조언을 받고 현업 팀원들에게 분석 내용을 설명하며 진행

## 학력

2025.03 – 2027.02 (졸업예정)
**고려대학교 일반대학원 빅데이터사이언스학과 석사과정**
학위논문 「AWSGMCMC를 이용한 베이지안 전이 네트워크 토픽 모형 추론」 · 2026.11 발표 예정

2021.03 – 2025.02
**고려대학교 세종캠퍼스 빅데이터사이언스학부 학사** · 융합전공 자율주행시스템학과

## 실무 경험 · 후속 프로젝트

2023.12 – 2024.04
인턴 2명

### JERESFARM · 데이터 분석 인턴

스마트팜 Python · statsmodels(VAR · VECM) · scikit-learn · Lasso

분석 인력이 없던 농장에서 생육 데이터(개체 18개 · 20일)로는 영향요인을 규명할 수 없음을 검정으로 확인하고, 후속 센서 · 카메라 배치와 측정 항목을 현업과 협의해 제안

| | |
|---|---|
| 문제 | 센서 변수 29개에 비해 생육 크기는 개체 18개 · 20일 · 하루 1회 줄자 측정. 사내 데이터 분석 인력 없음 |
| 협업 | 데이터 분석팀이 없는 회사에 학부생 인턴 2명으로 합류. 데이터 쪽은 지도교수님께 조언을 구하고 현업 팀원들에게 분석 내용을 설명하며 진행. 소통에 시간이 오래 걸렸지만 서로 다른 도메인을 배움 |
| 분석 | 로그 차분 후 ADF 정상성 확인. VAR에서 유의수준 0.05의 유의 변수 없음 → 공적분 확인 후 VECM 재검정. Lasso(α=1) 변수 17개, 테스트 $R^2$ 0.99 |
| 한계→해결 | 테스트 개체가 2개뿐이라 $R^2$ 0.99는 신뢰할 수 없다고 판단, 원인을 종속변수 관측 부족으로 규명 → 다음 작물(딸기) 농장 사전 조사 · 센서 · 카메라 배치와 측정 항목 협의 |

다시 한다면 모델링 전에 개체별 센서와 시간대가 맞는 데이터를 먼저 확보

2024 1학기
팀 3명

### 환경에 따른 최적 작물 예측 (JERESFARM 인턴 후속)

**통계학과 머신러닝 PBL · 결과 · 코드 농장 전달** Python · Pandas · scikit-learn · LightGBM · Feature Importance · PDP

농촌진흥청 공공 데이터(원본 827,080건, 학습 · 평가 90,000건)로 작물 5종과 그 외(랜덤) 클래스를 분류하는 모델 6개를 비교, Test F1 상위 앙상블 3개 중 격차가 가장 작은 LightGBM(Test 0.81, 작물 5종 평균 약 0.77, 격차 0.03 vs Bagging 0.17 · RF 0.21)을 선정하고 결과와 코드를 JERESFARM에 전달

**문제** 인턴 때 생육 영향요인을 규명하지 못한 문제를 수업 PBL에서 공공 데이터로 다시 정의 → 환경으로 작물을 예측하면 작물별 최적 환경과 토지에 맞는 작물을 함께 찾을 수 있음

**해결** 공통 환경변수 5개 선정, 원본 827,080건을 239,192건으로 정제, 클래스별 15,000건으로 맞춰 Decision Tree · SVM · K-NN · Bagging · Random Forest · LightGBM 비교

**결과** Train → Test F1 LightGBM 0.84 → 0.81 · Bagging 0.98 → 0.82 · RF 1.00 → 0.79. 영향력 온도 > 일사량 > $CO_2$, 임계 구간은 작물별로 다름(예: 참외 · 오이 25°C)

**다시 한다면** 토양 등 환경 변수와 작물 데이터 추가. 환경 변수 5개만으로 작물 적합성을 판단할 수 있는지가 남은 의문

## 대표 연구 성과 순

2025 – 2026
연구책임자 · 제1저자

### 전이 네트워크 토픽 모델을 이용한 임베디드 기술의 성장 예측

**한국연구재단 석사과정생연구장려금 과제 성과 · 투고 예정** Python · GPU 샘플러 · Google BigQuery(SQL) · OpenAlex · L2 로지...

논문 초록 114,066건 · 미국 특허 21,028건(BigQuery SQL로 직접 추출)으로 3년 뒤 성장할 기술 토픽을 예측해 AUC 논문 0.876 · 특허 0.746(무작위 0.5, 토픽 모델까지 기준연도별 재추정 시 0.828 · 0.691), 성장 이유를 토픽 전이로 설명

**목표** 임베디드 분야에서 3년 뒤 크게 성장할 기술 토픽을 정확히 예측하고, 성장 이유를 문장 사이의 토픽 전이 구조로 설명

**문제** 기존 연구는 토픽 비중 · 키워드 · 인용 · 특허 지표를 썼고, 신경망 예측은 정확해도 성장 이유를 설명하기 어려움. 기존 TNTM은 전이행렬이 전 기간에 하나뿐

**내 역할** 데이터 수집 · 정제 · GPU 샘플러 구현 · 변수 정의 · 평가 설계 · 논문 작성

**해결** 연도별 전이행렬을 계층 사전분포로 묶어 TNTM 확장(K=40, AWSGLD). 전이 네트워크에서 유입 · 자기전이 · 유입 출처 · 구조 변화 변수 8개를 직접 정의하고 데이터 변수 14개와 함께 예측 모형 구성

**데이터** Google BigQuery 공개 특허 데이터셋에서 SQL로 미국 특허 21,028건(524,424문장)을, OpenAlex에서 임베디드 관련 12개 구문으로 논문 초록 114,066건을 직접 추출 · 정제

**결과** 문서 완성 perplexity 논문 TNTM 1172 · HTMM 1223 · LDA 2149. 성장 기준을 상위 10% · 30%로 바꿔도 AUC 논문 0.896 · 0.881 유지. 유입 증가(+0.31) · 자기전이(−0.28)가 주요 계수 → 다른 토픽에서 문장이 넘어오는 토픽이 성장

한계→해결 시점을 섞은 교차검증은 미래 정보가 섞여 성능이 부풂 → 과거 자료로만 학습하는 rolling-origin 평가(논문 13개 · 특허 11개 결과연도). 토픽 모델까지 기준연도마다 다시 추정해 기준연도 이후 문헌을 빼도 AUC 논문 0.828 · 특허 0.691

2025 – 2026
제1저자 · 공저 2인

### Fixed-K Shrinkage Bayesian Transition Network Topic Model with AWSGHMC Inference

**SCI급 학술지 투고 예정** Python · NumPy · SG-MCMC(AWSGHMC · SGHMC · SGLD) · MH-within-Gibbs

기존 토픽 모델의 한계를 보완한 새 토픽 모델 BNTM과 샘플러 AWSGHMC를 직접 설계하고, 정답을 아는 모의실험 데이터(환경 5종)를 생성해 검증 · 모델 비교에서 실데이터(FAERS) 문서 완성 perplexity를 HTMM 54.99 → 32.13(41.6%↓)으로 낮추고, 샘플러 비교(모의실험 정답 20토픽)에서 추정 토픽 수를 SGHMC 15.4개 → AWSGHMC 20.0개로 정확 복원 · 포스터논문 장려상

목표 ① 문장 순서가 있는 텍스트를 LDA · HTMM보다 잘 설명하는 모델 ② 멀티모달 사후분포를 안정적으로 추정하는 샘플러. 샘플러를 고정하고 모델을, 모델을 고정하고 샘플러를 바꿔 각각 검증

문제 LDA는 문장 순서를 무시하고 HTMM은 전이를 값 하나로 요약, TNTM은 토픽 수를 미리 정하고 확률 단체 제약으로 경사 기반 추론이 어려움. 선행 연구(AWSGLD-TNTM)에서도 seed에 따라 토픽 구조가 크게 달라져 원인을 모델 구조로 판단

내 역할 모델 · 샘플러 · 모의실험 데이터 생성기 설계, 구현, 실험, 논문 작성. 지도교수 교신

해결 Logistic-Normal 모수화(Simplex 제약 제거) + Sparse Dirichlet Prior(최대 토픽 수 K는 고정, 그중 실제로 쓰이는 토픽 수는 데이터가 결정) + AWSGHMC(멀티모달 사후분포의 로컬 트랩 탈출)를 결합한 새 모델 BNTM과 샘플러를 설계

검증 설계 토픽 모델은 정답 라벨이 없어 결과 검증이 어려움 → 정답 토픽 · 전이 · 비중을 정해 둔 모의실험 데이터 생성기를 직접 설계. 환경마다 어려움 하나만 키운 5종(기본 · 초과 용량 K 40 · 다수 토픽 20 · 소표본 200건 · 대규모 10,000건)

모델 비교 5개 환경 모두 BNTM의 문서 완성 perplexity가 모든 관찰 길이에서 HTMM보다 낮고 LDA보다 크게 낮음(40토픽 환경 HTMM 대비 약 20포인트)

샘플러 비교 AWSGHMC만 5개 환경 모두 K 정확 복원. 다수 토픽 환경(정답 20)에서 SGHMC 15.4 · SGLD 14.7 · MH 23.4, 토픽-단어 Hellinger 거리 0.09~0.17로 최소

실데이터 문서 완성 perplexity FAERS 이상반응 보고서 14,316건 BNTM 32.13 · HTMM 54.99 · LDA 78.23, NTSB 항공사고 서술문 17,733건 472.1 · 498.5 · 1,090.7. 같은 모델에서 샘플러 비교 시 AWSGHMC가 두 데이터 모두 perplexity 최저(FAERS는 전체 배치 MH 32.30과 근접, MH는 반복당 비용이 큼)

한계→해결 모의실험 기준으로 맞춘 샘플러 설정이 실데이터의 큰 에너지 범위에서 작동하지 않음(한 구간에 갇힘) → 구간 폭을 데이터 에너지 범위에 비례하도록 바꿔 정상화

다시 한다면 수동으로 조정한 에너지 구간 폭을 말뭉치에 맞춰 자동으로 정하는 규칙부터 만듦

포스터

2025 – 2026
제1저자

### AWSGLD를 이용한 전이 네트워크 토픽 모델 추론

**한국자료분석학회지 28(1) 109–121 게재** Python · AWSGLD · TNTM

TNTM 추론을 MH-Gibbs + AWSGLD로 바꿔 IMDB 리뷰 1,000문장의 문장마다 무작위 단어 50개를 넣은 조건에서 perplexity를 SGLD보다 약 8배 낮춤(m=30). 토픽 다양성은 SGD 0.48 대비 0.96(SGLD와 같음)

목표 TNTM의 추론을 확률적 기울기 기반 표본추출로 대체해, 잡음이 있는 텍스트에서도 토픽 전이 구조를 추정

내 역할 추론 수식 유도, 구현, 실험, 논문 작성. 지도교수 교신

해결 문장 토픽은 MH-Gibbs, 전이행렬 · 단어-토픽 분포는 AWSGLD로 추론. 추론에 필요한 미분식을 유도해 구현하고, 문장마다 무작위 단어 0 · 50 · 100개를 넣어 SGD · SGLD와 비교

한계→해결 토픽 수 K를 미리 정해야 하고 잡음이 커지면 이점이 줄어듦 → 후속 연구 BNTM에서 희소 사전분포와 AWSGHMC로 해결

논문 DOI

2025
제1저자

### 자율주행 도메인에서 LoRA 기반 sLLM 파인튜닝 연구

**한국자료분석학회지 27(3) 769–780 게재** PyTorch · Transformers · PEFT(LoRA) · Phi-4-mini · RAG

자율주행 판단을 설명하는 LoRA FT-Driver(Phi-4-mini 3.8B, 파라미터 0.01% 학습)를 제안해 RAG 대비 ROUGE-1 0.0888 → 0.1495(68.4%↑), 교통법규 위반 분류(재학습 없이 프롬프트 예시) Accuracy RAG 최고 0.540 → 0.745

목표 자율주행 차량이 내린 판단을 사람이 이해할 수 있게 설명하는 실시간 응답 시스템

문제 RAG는 도메인 간 일반화는 좋지만 특정 도메인 안에서 정확성 · 응답 일관성이 떨어지고, 차량 내 임베디드 자원에서는 전체 파라미터 파인튜닝이 부담

내 역할 모델 선정, LoRA 학습 설계, RAG 비교 실험, 논문 작성

해결 BDD-X(주행 설명 주석 26,228개)로 LoRA 파인튜닝, RAG와 같은 조건에서 정량 비교

결과 ROUGE-1 0.0888 → 0.1495(68.4%↑), 응답 시간 1.145초(RAG k=1 1.099초). 교통법규 위반 유형 분류(약 7만 건, 재학습 없이 프롬프트 예시 방식)로 넓힌 실험에서 Accuracy 0.745 · Macro F1 0.731(RAG 최고 0.540 · 0.532)

다시 한다면 학습 데이터의 양과 범위가 제한적이었으므로 주석 자동화와 멀티모달 데이터셋 구성부터 진행

논문 DOI

## 프로젝트 직무 관련 · 성과 순

2023
팀 3명 · QGIS 시각화 · 분석 코드

### 택시 수요 분석을 통한 택시 서비스 개선 방안 마련

**통계학술제 최우수상** R · 계층적 군집분석(Ward.D) · QGIS · 공공 데이터 병합

공공 데이터 6종을 직접 구해 병합하고 공차율 웹을 만들어 서울 25개 자치구를 6개 군집으로 나누고, 택시 서비스 개선 방향을 정리해 통계학술제 최우수상

문제 선행 자료 조사와 뉴욕 택시 데이터를 분석한 교수님 자문 → 택시 수요 · 공급 비교에는 대중교통 공급과 유동인구를 함께 봐야 한다고 판단

해결 빅데이터캠퍼스(택시운영분석 · 표준노드아이디DB) · 국가공간정보포털(행정구역) · 서울 열린데이터광장(유동인구 2종) 등 데이터 6종 병합. 요일별 승차건수, 면적당 대중교통 분포율, 유동인구 대비 역 · 정류장 분포 계산, 공차율 지표 설계 후 3개 변수 증감 조합 + 계층적 군집분석

결과 군집별 특성 정리: 강남 · 서초(전 지표 상승), 중구(대중교통 분포 낮음 · 유동인구와 택시 이용 높음), 저조 지역(광진 · 중랑 · 도봉 등). QGIS 지도와 공차율 조회 웹 화면 제작. 데이터는 2015.1–2016.4 기준

다시 한다면 집계치로 적정 기본요금과 거리요금을 책정하는 분석까지 진행

포스터

2025
팀 4명 · 수집 · 지표 정의 · 발표

### 대학 기숙사 운영 유형 분류 (대학알리미 공시 데이터)

**2025 대학알리미 데이터 아이디어 공모전 본선 진출(수상 없음)** Python · 공시 데이터 전처리 · 지표 설계

수용률 · 이익률 지표를 정의해 대학 기숙사를 4개 운영 유형으로 분류하고 유형별 특징 · 6개 개선안을 제시, 공모전 본선 진출(수상 없음)

내 역할 팀 4명 중 데이터 수집 · 지표 정의 · 발표 담당. 팀원의 로지스틱 회귀 결과를 비용 개선안에 연결

결과 수용률 5년 정체(23.2~23.8%). 기준선 수용률 30% · 이익률 20%로 공공복지형 · 균형형 · 수익중심형 · 형식적 운영형 분류, 공립은 전부 형식적 운영형

---

2024
팀 2명

### 베이지안 기법을 이용한 강수예보 정확도 분석

**학부 베이지안 PBL(A+)** Python · 베이지안 갱신 · 베이즈 팩터 검정

기상청 예보 약 18만 건(세종시 조치원읍)으로 강수확률을 사후확률로 다시 계산해, 10시간 예보에서 강수확률 70% 이상이면 비가 올 확률 0.82~0.95, 0~30%면 0에 가깝다는 판단 기준 도출 · 과목 A+

**문제** 강수예보가 자주 틀리는 이유가 궁금해 직접 잡은 주제. 예보 정확도는 90%에 가깝지만 기상청 강수 적중률은 63%(국정감사 발표), 강수확률을 어느 값부터 믿을지 기준 없음

**내 역할** 사전확률 설계, 사후 갱신, 베이즈 팩터 검정, 결론 담당. 데이터는 공동, 가능도 · 신뢰구간은 팀원 담당

**해결** 예보시간 × 강수확률 구간 결합분포로 가능도 구성, 강수확률을 사전확률로 5단계 갱신, 베이즈 팩터 ≥ 1을 판정 기준으로 설정

**결과** 10시간 예보에서 비가 올 사후확률 60~69% 구간 0.54 · 70~79% 0.88 · 80~89% 0.82 · 90~100% 0.95, 베이즈 팩터 60~69% 1.18 · 70~79% 7.36 · 90~100% 21.04

**한계→해결** 50시간 예보는 사후확률이 낮고 신뢰구간이 넓음 → 결론을 신뢰구간이 좁은 10~30시간 예보로 한정

---

2023
개인

### 잦은 배달 음식 섭취가 건강에 미치는 영향

**학부 수업 프로젝트(A+)** R · 다중 로지스틱 회귀 · AIC 변수 선택 · K-means · 계층적 군집분석

2022 식품소비행태조사 6,366명으로 식사 방법별 건강 오즈비를 추정해 단체급식 1.25 · 일반식당 1.19 · 집밥 1.14 · 배달 0.80을 밝히고, 배달 빈도가 높아도 식생활 역량이 높은 군집이 더 건강함을 확인 · 과목 A+

**문제** 배달이 식생활 문화가 된 상황에서 배달 음식이 정말 건강에 해로운지, 배달을 먹으면서도 건강을 지키는 방법이 있는지 확인

**해결** 건강 상태를 종속변수로 다중 로지스틱 회귀(AIC 1995 → 1989로 변수 선택), 식생활 역량 10문항 + 배달 빈도로 K-means(덴드로그램 · Elbow로 k=4)

**결과** 편의점 식사도 오즈비 1.12로 긍정적, 배달 월평균 비용은 0.79. 배달을 자주 먹어도 식생활 역량이 높은 군집이 더 건강 → 아침 식사 · 가족과의 식사 같은 습관도 함께 봐야 함

---

2025.09 – 12
개인

### 국제 메타데이터 표준 통합 LLM 기반 그래프 증강 추천시스템

**수업 프로젝트(A+) · KIAT 표준전문인력양성 과제 성과** Python · LLM(LLMRec) · LightGCN · ISO 3166-1 · BCP 47 · 대응표본 ...

LLM이 만든 메타데이터를 국제 표준으로 정규화해 표준 적합률 48.4% → 91.4%(43.0%p↑), 상호운용성 80.3%, 추천 성능 유의한 저하 없음 · 과목 A+

**문제** LLMRec으로 만든 Netflix 메타데이터(17,366건)에서 같은 국가가 USA · United States · America로 나뉘어 시스템 간 결합 불가

**해결** ISO 3166-1 alpha-2 · BCP 47 정규화 레이어 설계, 필드별 형식 적합률 측정

**결과** country 표면형 1,166개 → 57개(95%↓), language 326개 → 52개(84%↓), column-shift 724건 자동 검출. LightGCN 10 seed 반복 · 대응표본 t-검정에서 Recall · NDCG · Precision 6개 지표 모두 $p > 0.05$

**다시 한다면** 사후 정규화 대신 구조화 출력으로 생성 시점에 표준 강제. 약 20%는 생성 단계 문제라 사후 정규화로 해결되지 않음

저장소

## 연구과제 참여

2025 – 2026 **TNTM을 활용한 임베디드 시스템 문서의 주제 흐름 분석** · 연구책임자 · 한국연구재단 석사과정생연구장려금 · RS-2025-25437035 → 「전이 네트워크 토픽 모델을 이용한 임베디드 기술의 성장 예측」 제1저자 투고 예정

2024 – 2027 **베이지안 추론을 위한 적응적 가중 SGMCMC 알고리즘** · 참여연구원 · 한국연구재단 · RS-2024-00352792 · 2차년도 샘플러 구현 · 실험 설계 · 결과 분석 전담 → 제1저자 논문 4편(게재 2 · 투고 예정 2)

2025 – 2026 **초격차산업기반표준전문인력양성** · 참여연구원 · KIAT · RS-2025-02215617 · 표준 프로젝트 2건(메타데이터 표준 정규화, TBT 규제 분석)

## 수상

2026 **한국자료분석학회 하계학술발표대회 포스터논문 장려상** · Fixed-K Shrinkage Bayesian Transition Network Topic Model Inference with AWSGLD · 제1저자 · AWSGLD 버전, 이후 추론을 AWSGHMC로 바꿔 SCI급 투고 예정

2023 **고려대학교 빅데이터사이언스학부 통계학술제 최우수상** · 택시 수요 분석 · 팀 3명

2023 **미래모빌리티 및 세종지역혁신 아이디어 공모전 장려상** · Smart Green-STOP(압전 · 태양광 자가발전 스마트 정류소) · 3D 구현 담당 · 세종특별자치시

## 활동 · 리더십

2025.03 – 현재 **DLM연구실 대표** · 구성원 간 소통 · 세미나 일정 · 공지 공유, 공동 연구 자원 · 안전 사항 관리

2025.03 – 09 **학부생 연구원 프로그램 대학원생 멘토** · 에코업혁신융합대학사업단 · 멘티 1명과 연구 주제 구체화 · 방법론 선정 · 실험 설계를 함께 진행해 포스터 발표까지 완료

2023 · 2025 **Python · Excel 실습 멘토** · 디지털리터러시(Python, 2025.03 – 12) · 글로벌역량멘토링(Excel, 2023.03 – 06) 수업에서 실습 오류 해결 · 기초 개념 설명

2023.02 – 07 **예큐레이션(예산시장) 마케팅 서포터즈 5인 팀장** · 팀장 중심 업무 배분을 팀원별 자율 기획 · 실행 방식으로 바꿔 참여도 개선, 인스타그램 21건 · 유튜브 8건 제작, 팔로워 375명 · 대표 영상 조회 2,523회

2024.12 – 2025.01 **미국 UNLV 해외연수 · CES 2025 참관** · AI+IoT Communication 과정 수료, 다양한 국적의 학생들과 토론 · 발표

2021.09 – 2022.06 **뮤지컬 동아리 '캐스팅' 의상 · 분장팀장** · 팀원 3명과 배우 14명의 공연 준비 일정 조율

## 기술

| | |
|---|---|
| 언어 · 도구 | Python(Pandas), R, SQL(MySQL · Google BigQuery), Git, CUDA, Excel, ROS · Autoware(학부 실습) |
| ML · DL | PyTorch, TensorFlow, scikit-learn, Transformers, PEFT(LoRA · QLoRA), OpenPCDet, LangChain, Chroma |
| 통계 · 추론 | SGLD · SGHMC · AWSGLD · AWSGHMC · MH-within-Gibbs 구현, 시계열(VAR · VECM), 베이지안 검정 |
| 자격 | ADsP(데이터분석 준전문가, 2023.11) · OPIc IM1(2026.09) |