경력기술서

# 김다연

dayun0405@gmail.com | 포트폴리오 kim-da-yeon.github.io | GitHub Kim-Da-yeon



## 핵심 요약

**Python, R, SQL을 기반으로 수요 · 공급 분석, 데이터 정합성 검증, 통계 · 머신러닝 모델링을 수행해 온 빅데이터사이언스 석사과정 지원자입니다.**

### 경험 1. 서울시 택시 수요 · 공급 분석 | 통계학술제 최우수상

- 서울시 공공데이터 6종을 활용해 25개 자치구를 6개 유형으로 분류하고 지역별 배차 · 서비스 전략 제안
- 팀 3명 중 분석 코드 구현과 QGIS 공간 시각화 담당

### 경험 2. LLM 생성 데이터 정합성 검증 | 형식 적합률 43.0%p 개선

- Netflix 메타데이터 17,366건의 형식 적합률을 48.4%에서 91.4%로 개선하고 필드 밀림 오류 724건 자동 검출, 추천 성능 손실 없음을 검정으로 확인
- ISO · BCP 47 기반 정규화 규칙과 오류 검출 파이프라인 단독 구현 · 과목 A+

### 경험 3. 스마트팜 데이터 분석 인턴 | 분석 한계 검증 및 후속 수집 방향 제안

- 생육 · 환경 데이터의 결측과 관측 구조를 검토해 기존 데이터만으로는 신뢰할 만한 영향요인을 규명하기 어렵다는 한계 확인
- 공공 데이터로 대체 분석(Test F1 0.81)하고, 현장 조사 · 현업 협의로 후속 센서 · 카메라 배치와 측정 항목 검토

### 경험 4. 임베디드 기술 성장 예측 | AUC 논문 0.876 · 특허 0.746

- Google BigQuery에서 SQL로 미국 특허 21,028건을, OpenAlex에서 논문 초록 114,066건을 직접 추출해 3년 뒤 성장할 기술 토픽 예측
- 한국연구재단 과제 연구책임자로 데이터 수집 · GPU 샘플러 구현 · 미래 정보를 막는 rolling-origin 평가 설계

### 경험 5. 강수예보 베이지안 분석 | 강수확률 70% 이상이면 비 올 확률 88~95%

- 기상청 예보 약 18만 건으로 강수확률을 사후확률로 다시 계산하고 베이즈 팩터로 판단 기준 도출
- 사전확률 설계 · 갱신 · 검정 담당 · 과목 A+

## 학력

| | |
|---|---|
| 2025.03 – 2027.02 (졸업예정) | **고려대학교 일반대학원 빅데이터사이언스학과 석사과정** |
| 2021.03 – 2025.02 | **고려대학교 세종캠퍼스 빅데이터사이언스학부 학사** · 융합전공 자율주행시스템학과 · 표준학 |

## 연구과제 참여

| | |
|---|---|
| 2025 – 2026 | **TNTM을 활용한 임베디드 시스템 문서의 주제 흐름 분석** · 연구책임자 · 한국연구재단 석사과정생연구장려금 · RS-2025-25437035 → 「전이 네트워크 토픽 모델을 이용한 임베디드 기술의 성장 예측」 제1저자 투고 예정 |
| 2024 – 2027 | **베이지안 추론을 위한 적응적 가중 SGMCMC 알고리즘** · 참여연구원 · 한국연구재단 · RS-2024-00352792 · 2차년도 샘플러 구현 · 실험 설계 · 결과 분석 전담 → 제1저자 논문 4편(게재 2 · 투고 예정 2) |
| 2025 – 2026 | **초격차산업기반표준전문인력양성** · 참여연구원 · KIAT · RS-2025-02215617 · 표준 프로젝트 2건(메타데이터 표준 정규화, TBT 규제 분석) |

## 수상

2026 **한국자료분석학회 하계학술대회 포스터논문 장려상** · Fixed-K Shrinkage BNTM with AWSGLD Inference · 제1저자

2023 **고려대학교 빅데이터사이언스학부 통계학술제 최우수상** · 택시 수요 분석 · 팀 3명

2023 **미래모빌리티 및 세종지역혁신 아이디어 공모전 장려상** · Smart Green-STOP(압전 · 태양광 자가발전 스마트 정류소) · 3D 구현 담당 · 세종특별자치시

## 대표 연구 성과 순

2025 – 2026
연구책임자 · 제1저자

### 전이 네트워크 토픽 모델을 이용한 임베디드 기술의 성장 예측

**한국연구재단 석사과정생연구장려금 과제 성과 · 투고 예정** Python · GPU 샘플러 · Google BigQuery(SQL) · OpenAlex · L2 로지스틱 회귀

> **논문 초록 114,066건 · 미국 특허 21,028건(BigQuery SQL로 직접 추출)으로 3년 뒤 성장할 기술 토픽을 예측해 AUC 논문 0.876 · 특허 0.746, 성장 이유를 토픽 전이로 설명**

**문제** 기존 TNTM은 전 기간에 전이행렬이 하나뿐이라 전이 구조의 연도별 변화를 볼 수 없음

**해결** 연도별 전이행렬을 계층 사전분포로 묶어 TNTM 확장(K=40, AWSGLD). 전이 네트워크에서 유입 · 자기전이 · 유입 출처 · 구조 변화 변수 8개를 직접 정의하고 데이터 변수 14개와 함께 예측 모형 구성

**결과** 문서 완성 perplexity 논문 TNTM 1172 · HTMM 1223 · LDA 2149. 성장 기준을 상위 10% · 30%로 바꿔도 AUC 논문 0.896 · 0.881 유지. 유입 증가(+0.31) · 자기전이(−0.28)가 주요 계수 → 다른 토픽에서 문장이 넘어오는 토픽이 성장

**한계→해결** 시점을 섞은 교차검증은 미래 정보가 섞여 성능이 부풂 → 과거 자료로만 학습하는 rolling-origin 평가(논문 13개 · 특허 11개 결과연도). 토픽 모델까지 기준연도마다 다시 추정해 기준연도 이후 문헌을 빼도 AUC 논문 0.828 · 특허 0.691

**데이터** Google BigQuery 공개 특허 데이터셋에서 SQL로 미국 특허 21,028건(524,424문장)을, OpenAlex에서 임베디드 관련 12개 구문으로 논문 초록 114,066건을 직접 추출 · 정제

**담당** 데이터 수집 · 정제 · GPU 샘플러 구현 · 변수 정의 · 평가 설계 · 논문 작성

2025 – 2026
개인 연구 · 제1저자

### Fixed-K Shrinkage BNTM with AWSGHMC Inference

**SCI급 학술지 투고 예정** Python · NumPy · SG-MCMC(AWSGHMC · SGHMC · SGLD) · MH-within-Gibbs · 베이지안 추론

> **토픽 수를 데이터로 정하는 토픽 모델과 샘플러를 설계해, 직접 설계한 모의실험 데이터 5종 모두에서 토픽 수를 정확히 복원(10 seed)하고 실데이터 2종에서 perplexity 최저 달성**

**문제** 선행 연구(AWSGLD-TNTM)는 토픽 수 K를 미리 정해야 하고, seed와 설정에 따라 토픽 구조가 크게 달라짐. 학습률 · 하이퍼파라미터 · prior 조정으로 해결되지 않아 원인을 모델 구조로 판단

**해결** Logistic-Normal 모수화(Simplex 제약 제거) + Sparse Dirichlet Prior(활성 토픽 수를 데이터가 결정) + AWSGHMC(다봉 사후분포의 로컬 트랩 탈출)로 모델과 샘플러를 다시 설계

**검증 설계** 토픽 모델은 정답 라벨이 없어 결과 검증이 어려움 → 정답 토픽 · 전이 · 비중을 정해 둔 모의실험 데이터 생성기를 직접 설계. 환경마다 어려움 하나만 키운 5종(기본 · 초과 용량 K 40 · 다수 토픽 20 · 소표본 200건 · 대규모 10,000건)

**결과** AWSGHMC만 5개 환경 모두 K 정확 복원. 다수 토픽 환경(정답 20)에서 SGHMC 15.4 · SGLD 14.7 · MH 23.4, 토픽-단어 Hellinger 거리 0.09~0.17로 최소

**실데이터** 문서 완성 perplexity FAERS 이상반응 보고서 14,316건 BNTM 32.13 · HTMM 54.99 · LDA 78.23, NTSB 항공사고 서술문 17,733건 472.1 · 498.5 · 1,090.7. 같은 모델에서 샘플러 비교 시 AWSGHMC가 두 데이터 모두 perplexity · 최저 에너지 1위

**한계→해결** 모의실험 기준으로 맞춘 샘플러 설정이 실데이터의 큰 에너지 범위에서 작동하지 않음(한 구간에 갇힘) → 구간 폭을 데이터 에너지 범위에 비례하도록 바꿔 정상화

**배운 점** 모델이 맞는지는 정답을 아는 데이터로 먼저 확인해야 함. 생성기와 평가 지표는 LDA · HTMM · TNTM · BNTM 비교에 그대로 재사용

2025
제1저자

### 자율주행 도메인에서 LoRA 기반 sLLM 파인튜닝 연구

**한국자료분석학회지 27(3) 769–780 게재** PyTorch · Transformers · PEFT(LoRA) · Phi-4-mini · RAG

> **Phi-4-mini(3.8B)를 파라미터 0.01%만 학습하는 LoRA로 자율주행 도메인에 맞춰, 같은 조건 RAG 대비 ROUGE-1 0.0888 → 0.1495(68.4%↑)**

**문제** 임베디드 환경에서는 전체 파라미터 파인튜닝의 자원 부담이 큼. 파인튜닝과 검색 증강 중 무엇을 쓸지가 핵심 결정

**해결** BDD-X 주행 설명 주석 26,228개로 LoRA 파인튜닝, RAG(k=1)와 같은 조건에서 정량 비교

**결과** ROUGE-1 0.0888 → 0.1495(68.4%↑), 평균 응답 시간 1.145초. 교통법규 분류(약 7만 건)로 넓힌 실험에서 Accuracy 0.745 · Macro F1 0.731

2025 – 2026
제1저자

### AWSGLD를 이용한 전이 네트워크 토픽 모델 추론

**한국자료분석학회지 28(1) 109–121 게재** Python · AWSGLD · TNTM

> **Simplex 제약 때문에 경사 기반 추론이 어려운 TNTM에 AWSGLD를 적용해 SGD 대비 토픽 다양성 0.48 → 0.96(2배), 잡음 조건에서 SGLD 대비 perplexity 약 10배 개선**

**해결** TNTM 원 논문에 없는 추론 수식을 유도해 구현. 사후분포를 에너지 구간별로 가중해 다봉 사후분포를 평탄화

**한계→해결** 토픽 수 K를 미리 정해야 하고 잡음이 커지면 이점이 줄어듦 → 후속 연구 BNTM에서 희소 사전분포와 AWSGHMC로 해결

## 실무 경험

2023.12 – 2024.04
팀 2명

### JERESFARM · 데이터 분석 인턴

**스마트팜** Python · statsmodels(ARIMA · VAR · VECM) · scikit-learn · LGBM

> **현장 생육 데이터로는 결론을 낼 수 없음을 검정으로 확인하고, 공공 데이터로 과제를 다시 정해 Test F1 0.81 모델과 환경 임계값을 도출, 다음 작물의 센서 측정 설계까지 연결**

**문제** 센서 변수 29개에 비해 생육 크기는 개체 18개 · 20일 · 하루 1회 줄자 측정. 사내 데이터 분석 인력 없음

**분석** 로그 차분 후 ADF 정상성 확인. VAR에서 유의수준 0.05의 유의 변수 없음 → 공적분 확인 후 VECM 재검정. Linear · Ridge · Lasso 테스트 $R^2$ 0.36 · 0.51 · 0.99, Lasso 변수 17개

**한계→해결** 테스트 데이터가 10%뿐이라 $R^2$ 0.99는 과적합으로 판단, 원인을 종속변수 관측 부족으로 규명 → ① 농촌진흥청 공공 데이터로 작물별 최적 환경과 토지에 맞는 작물을 찾는 6종 작물 다중 분류로 전환 ② 다음 작물(딸기) 농장 사전 조사 · 카메라 센서 구성 협의

**결과** 모델 6종(DT · SVM · K-NN · Bagging · RF · LGBM) 비교, Train–Test 격차가 가장 작은 LGBM 선정 (Test F1 0.81). 영향력 온도 > 일사량 > $CO_2$, 임계 구간 온도 25°C · $CO_2$ 400ppm

**배운 점** 모델보다 측정 설계가 먼저. 최고 점수보다 일반화 격차로 모델 선택

## 프로젝트 직무 관련 · 성과 순

2025
개인

### 국제 메타데이터 표준 통합 LLM 기반 그래프 증강 추천시스템

**수업 프로젝트(A+) · KIAT 표준전문인력양성 과제 성과** Python · LLM(LLMRec) · LightGCN · ISO 3166-1 · BCP 47 · 대응표본 t-검정

> **LLM이 만든 메타데이터를 국제 표준으로 정규화해 표준 적합률 48.4% → 91.4%(43.0%p↑), 상호운용성 0% → 80.3%, 추천 성능 손실 없음 · 과목 A+**

**문제** LLMRec으로 만든 Netflix 메타데이터(17,366건)에서 같은 국가가 USA · United States · America로 나뉘어 시스템 간 결합 불가

**해결** ISO 3166-1 alpha-2 · BCP 47 정규화 레이어와 필드별 형식 적합률 지표 설계

**결과** country 표면형 1,166개 → 57개(95%↓), language 326개 → 52개(84%↓), column-shift 724건 자동 검출. LightGCN 10 seed 반복 · 대응표본 t-검정에서 recall@k · ndcg@k 7개 지표 모두 $p > 0.05$

**배운 점** 성능이 오르지 않아도 손실이 없음을 검정으로 보이면 데이터 품질이 기여가 됨

2024
팀 2명

### 베이지안 기법을 이용한 강수예보 정확도 분석

**학부 베이지안 PBL(A+)** Python · 베이지안 갱신 · 베이즈 팩터 검정

> **기상청 예보 약 18만 건으로 강수확률을 사후확률로 다시 계산해, 강수확률 70% 이상이면 비가 올 확률 88~95%(베이즈 팩터 7.36 이상), 0~30%면 0에 가깝다는 판단 기준 도출 · 과목 A+**

**문제** 강수예보가 자주 틀리는 이유가 궁금해 직접 잡은 주제. 예보 정확도는 90%에 가깝지만 기상청 강수 적중률은 63%(국정감사 발표), 강수확률을 어느 값부터 믿을지 기준 없음

**해결** 예보시간 × 강수확률 구간 결합분포로 가능도 구성, 강수확률을 사전확률로 5단계 갱신, 베이즈 팩터 ≥ 1을 판정 기준으로 설정(사전확률 설계 · 갱신 · 검정 · 결론 담당)

**결과** 10시간 예보에서 비가 올 사후확률 60~69% 구간 54% · 70~79% 88% · 90~100% 95%, 베이즈 팩터 1.18 · 7.36 · 21.04

**한계→해결** 50시간 예보는 사후확률이 낮고 신뢰구간이 넓음 → 결론을 신뢰구간이 좁은 10~30시간 예보로 한정

2023
개인

### 잦은 배달 음식 섭취가 건강에 미치는 영향

**학부 수업 프로젝트(A+)** R · 다중 로지스틱 회귀 · AIC 변수 선택 · K-means · 계층적 군집분석

> **2022 식품소비행태조사 6,366명으로 식사 방법별 건강 오즈비를 추정해 단체급식 1.25 · 일반식당 1.19 · 집밥 1.14 · 배달 0.80을 밝히고, 배달 빈도보다 식생활 습관이 건강에 더 크게 작용함을 확인 · 과목 A+**

**문제** 배달이 식생활 문화가 된 상황에서 배달 음식이 정말 건강에 해로운지, 배달을 먹으면서도 건강을 지키는 방법이 있는지 확인

**해결** 건강 상태를 종속변수로 다중 로지스틱 회귀(AIC 1995 → 1989로 변수 선택, 다중공선성 변수 제거), 식생활 역량 10문항 + 배달 빈도로 K-means(덴드로그램 · Elbow로 k=4)

**결과** 편의점 식사도 오즈비 1.12로 긍정적, 배달 월평균 비용은 0.79. 배달을 자주 먹어도 식생활 역량이 높은 군집이 더 건강 → 아침 식사 · 가족과의 식사가 건강에 기여

**배운 점** 설문의 주관적 건강 상태는 식사 횟수만으로 예측력이 제한적 → 예측 성능보다 계수 해석에 초점을 두고 결론 도출

2023
팀 3명 · QGIS 시각화 · 분석 코드

### 택시 수요 분석을 통한 택시 서비스 개선 방안

**통계학술제 최우수상** R · 계층적 군집분석(Ward.D) · QGIS · 공공 데이터 병합

> **데이터 5건을 직접 구해 병합하고 공차율 지표를 설계해 서울 25개 자치구를 6개 군집으로 나누고, 군집별 문제와 배차 전략을 제안해 통계학술제 최우수상**

**준비** 선행 자료 조사와 뉴욕 택시 데이터를 분석한 교수님 자문 → 택시 수요 · 공급 비교에는 대중교통 공급과 유동인구를 함께 봐야 한다고 판단

**해결** 빅데이터캠퍼스(택시운영분석 · 표준노드아이디DB) · 국가공간정보포털(행정구역) · 서울 열린데이터광장(유동인구 2종)에서 데이터 5건 병합. 요일별 승차건수, 면적당 대중교통 분포율, 유동인구 대비 역 · 정류장 분포 계산, 공차율 지표 설계 후 3개 변수 증감 조합 + 계층적 군집분석

**결과** 군집별 문제(대중교통 부족 · 인구 대비 교통수단 부족 등) 정의와 배차 전략: 강남 · 서초(전 지표 상승), 중구(관광 · 업무), 저조 지역(광진 · 중랑 · 도봉 등). QGIS 지도와 공차율 조회 웹 화면 제작

**한계→해결** 데이터가 실시간이 아니라 공차율 화면을 서비스로 운영할 수 없음 → 실시간 데이터 없이 적용할 수 있는 자치구 군집별 배차 · 서비스 전략으로 정리

## 협업 · 리더십

2025.03 – 09 **학부생 연구원 프로그램 대학원생 멘토** · 에코업혁신융합대학사업단 · 멘티 1명과 연구 주제 구체화 · 방법론 선정 · 실험 설계를 함께 진행해 포스터 발표까지 완료

2022 – 2023 **마케팅 서포터즈 4건 · 예큐레이션(예산시장) 5인 팀 리더** · 팀 콘텐츠 기획과 이벤트 운영을 이끌어 콘텐츠 29건 총 조회 3,671회, 영상 단일 2,500회 · KU_KEY 1 · 2기 · 사야컴퍼니 전시 2건

## 기술

언어 · 도구 Python, R, SQL, Git, CUDA

| | |
|---|---|
| ML · DL | PyTorch, TensorFlow, scikit-learn, Transformers, PEFT(LoRA · QLoRA), OpenPCDet, LangChain, Chroma |
| 통계 · 추론 | SGLD · SGHMC · AWSGLD · AWSGHMC · MH-within-Gibbs 구현, 시계열(ARIMA · VAR · VECM), 베이지안 검정 |
| 자격 | ADsP(데이터분석 준전문가, 2023.11) |