

경력기술서

김다연

dayun0405@gmail.com | 포트폴리오 kim-da-yeon.github.io | GitHub Kim-Da-yeon



Summary

- KCI 등재지 한국자료분석학회지(JKDAS) 제 1 저자 논문 2 편 게재
- SCI 급 학술지 1 편 2026.09. 투고 예정 (심사 전)

NRF 석사과정생연구장려금 연구책임자(PI) 선정, BNTM 확장 연구를 제 1 저자로 진행 중

정형·비정형 데이터 전반에 회귀·머신러닝·베이지안·딥러닝·LLM·토픽 모델링 적용

자율주행·모빌리티·스마트팜 등 실제 도메인 프로젝트로 문제 정의부터 결과 해석까지 수행

기술 능력

프로그래밍·도구: Python, R, SQL, Git, GPU Computing (CUDA), ROS · Autoware (학부 실습)

ML/DL: PyTorch, TensorFlow, scikit-learn, Transformers (LoRA/QLoRA)

데이터 처리·시각화: Pandas, Matplotlib, Seaborn, ggplot2, QGIS

자격증·어학: ADsP (데이터분석 준전문가, 2023.11)

학력

2025.03. - 현재 고려대학교 일반대학원 · 빅데이터사이언스학과 석사과정

졸업예정: 2027.02. · 석사 학위논문: BNTM with AWSGHMC (SCI 투고)

2021.03. - 고려대학교 세종캠퍼스 · 빅데이터사이언스학부 학사

2025.02. 융합전공: 자율주행시스템학과

실무 경험

2023.12. - JERESFARM · 데이터분석 인턴

2024.03. 스마트팜 도메인 · 활용: Python, scikit-learn, statsmodels, LGBM

팀 2 명

- ▶ 상황 작물 생육 데이터가 하루 1 회 사람이 줄자로 직접 측정(18 개 개체, 20 일 관측)에 그쳐 종속변수 관측 절대 부족. 사내에 데이터 분석 전담 인력이 없어 외부 자문 병행 및 자체 조사로 분석 수행
- ▶ 담당 최적 환경 도출과 데이터 구축을 위한 센서 환경 세팅 방안 결정 담당 (팀원 2 명 공동 진행)
- ▶ 시계열 분석 ARIMA·VAR·VECM 여러 시계열 기법으로 최적 생장 환경 도출 시도. 결측 구간 보간 후 유의성 검정으로 독립변수 유의성 제약 조건을 정량 검증. Lasso 회귀로 유의 변수 15 개 후보 추출, Y 관측 부족의 구조적 한계를 결론에 명시
- ▶ 공공 데이터 확장 현장 데이터 한계 근거로 농촌진흥청 공공 데이터 재접근 → 6 개 모델(DT, SVM, K-NN, Bagging, RF, LGBM) 비교하여 6 종 작물 다중 분류. LGBM 최종 선정 — Test F1 0.81 이지만 Train-Test 격차가 세 앙상블 중 가장 작아 과적합 위험 최소

- ▶ **결과** 도출 Feature Importance 로 온도>일사량>CO2 순 영향력 규명, Partial Dependence Plot 으로 온도 25°C·CO2 400ppm 등 변수별 임계 구간 도출
- ▶ **후속** 활동 다음 작물 딸기의 정확한 측정을 위해 회사 사람들과 함께 딸기 농장 사전 조사, 카메라 센서 구성 방식 협의. 데이터 한계의 원인을 측정 설계 단계로 규명

연구 참여

2025. - 2026. **TNTM 을 활용한 임베디드 시스템 문서의 주제 흐름 분석**
연구책임자 (석사과정생연구장려금) · RS-2025-25437035
▶ **성과** 관련 논문 1 편 투고 예정

2024. - 2027. **베이지안 추론을 위한 적응적 가중 SGMCMC 알고리즘**
참여연구원 (한국연구재단) · RS-2024-00352792
▶ **기여** 2 차년도(2025-2026) 연구 수행 전담 — 샘플러 구현, 실험 설계·수행, 결과 분석
▶ **성과** 제 1 저자 논문 3 편(게재 2 · 투고 예정 1), 학회 발표 1 건

2025. - 2026. **초격차산업기반표준전문인력양성**
참여연구원 (KIAT, 표준학 융합전공) · RS-2025-02215617
▶ **기여** 표준학 융합전공 이수와 함께 표준 관련 프로젝트 3 건 중 2 건 수행 (1 건 진행 예정)
▶ **성과** LLM 국제 메타데이터 표준화, 미국 자율주행·자동차 TBT 규제 분석

논문

2025. - 2026. **Fixed-K Shrinkage BNTM with AWSGHMC Inference (2026.09. 투고 예정 · 심사 전)**
Kim, D. & Cheon, S. (제 1 저자) · 석사 학위논문
▶ **담당** 연구 가설 수립부터 모델 설계, 시뮬레이션 데이터 생성, 평가 지표 정의, 샘플러 구현, 실험 수행, 논문 작성까지 지도교수 자문 하에 전 과정 수행
▶ **문제** 정의 선행 연구(JKDAS 28(1), AWSGLD)에서 남은 두 근본 한계 — 토픽 수 K 사전 고정, 노이즈 환경에서 이점 상쇄 — 를 문제 정의로 삼아 확장
▶ **WHY** Logistic-Normal 모수화 + Sparse Dirichlet Prior + AWSGHMC 하이브리드 추론을 선택한 이유: (1) Simplex 제약이 경사 기반 추론의 근본 걸림돌, Logistic-Normal 변환으로 무제약 공간에서 처리 가능 (2) K 사전 고정 문제를 데이터가 결정하게 하려면 희소 사전분포가 이론적으로 가장 안전 (3) 이산 잠재변수·연속 모수를 각각 다른 방식으로 처리해야 로컬 트랩 극복
▶ **결과** 토픽 모델은 정답 라벨이 없어 성능 검증이 어렵다는 한계가 있음. 파라미터 중첩·희소 토픽·토픽 수 변동 등 까다로운 조건을 통제한 시뮬레이션 데이터를 직접 설계해 Ground-truth 기반 검증 체계를 구축(LDA·HTMM·TNTM·BNTM 전반에 재사용 가능). 설계한 5 개 환경 (Ktrue 8~40) 전부에서 활성 토픽 수를 정확히 복원(Keff=Ktrue, 10 seed 편차 0). 예: Ktrue=20 환경에서 AWSGHMC 20.0 vs SGHMC 15.4·SGLD 14.7(과소), MH 23.4(과다). 토픽-단어 Hellinger 0.09~0.17(SGLD 계열 0.40~0.65), Sentence Accuracy 전 환경 1.00. 시뮬레이션 검증 통과 후 FAERS·NTSB 실제 코퍼스에 적용

2026. **AWSGLD 를 이용한 전이 네트워크 토픽 모델 추론**
Kim, D. & Cheon, S. (제 1 저자) · JKDAS 28(1), 109-121

▶ 문제	TNTM 은 문장 수를 모델링하지만 Simplex 제약으로 경사 기반 추론이 어려워 → 고차원 다중 모드 사후분포에서 로컬 트랩 발생
▶ 방법	TNTM 에 AWSGLD 적용 — 사후분포를 구간별 적응 가중해 다중 모드 사후 평탄화, 로컬 트랩 탈출 및 대규모 데이터 확장성 확보
▶ 결과	원본 데이터에서 SGD 대비 토픽 다양성 2 배(0.48→0.96), 노이즈 50 개 조건 SGLD 대비 Perplexity 약 10 배 우수 — Coherence·Diversity·Perplexity 종합 비교로 검증

2025. 자율주행 도메인에서 LoRA 기반 sLLM 파인튜닝 연구

Kim, D., Cheon, S. & Joo, A. (제 1 저자)

JKDAS 27(3), 769-780 · LoRA 파인튜닝

- ▶ 문제 도메인 특화 sLLM 의 응답 품질 개선 필요, 전체 파라미터 파인튜닝은 임베디드 환경 자원 부담 큼
- ▶ WHY Phi-4-mini(3.8B)는 임베디드 자원 제약, LoRA 는 자원 효율과 도메인 적응의 균형 때문에 선정. 파인튜닝 vs 검색 증강 트레이드오프가 핵심 의사결정 지점이라 RAG 와 정량 비교로 검증
- ▶ 결과 BDD-X 자율주행 데이터셋(주행 영상 6,970 개·주석 26,228 개)으로 LoRA 파인튜닝, 전체 파라미터의 약 0.01%만 조정. 동일 조건 RAG(k=1) 대비 ROUGE-1 0.0888 → 0.1495 향상, 응답 시간 평균 1.145 초. Traffic violations 7 만 건 확장 실험 Accuracy 0.745·Macro F1 0.731

수상

2026. 한국자료분석학회 하계학술대회 포스터논문 부문 장려상

Fixed-K Shrinkage BNTM with AWSGLD Inference (제 1 저자)

발표 시점 AWSGLD 버전, 이후 AWSGHMC 로 확장

- ▶ 내용 논문 「Fixed-K Shrinkage BNTM」 의 발표 시점 버전 (상세는 논문 항목 참조)
- ▶ 성과 시뮬레이션·실제 코퍼스 양쪽에서 우수성 정량 입증

2023. 통계학술제 최우수상 — 택시 수요 분석을 통한 택시 서비스 개선 방안 마련

팀 3 명

고려대학교 빅데이터사이언스학부 · 담당: QGIS 시각화 · 분석 코드 구현

- ▶ 문제 택시 요금 인상 후 기사·이용자 동반 이탈로 이용률 하락, 자치구별 수요·공급 불균형 해소 데이터 기반 배차 전략 부재
- ▶ 방법 서울시 6 종 공공 데이터 병합, 계층적 군집분석(Ward.D) + 3 변수 증감 조합, QGIS 로 자치구별 공간 분포 시각화 담당, 공차율 웹 인터페이스 제작
- ▶ 핵심 결과 25 개 자치구를 8 개 조합 중 6 개 군집으로 배정 (B·G 공집합) — 강남·서초(전 지표 상승), 중구(관광·업무 특성), 저조 지역(광진·중랑·도봉 등)별 차별화된 배차·서비스 전략 제안

2023. 미래모빌리티 및 세종지역혁신 아이디어 공모전 장려상

팀 2 명

Smart Green-STOP (친환경 스마트 정류소) · (3D 구현 담당) · 주관: 세종특별자치시

- ▶ 담당 3D 구현 담당. 팀원과 서로 아이디어를 제시하고 실현 가능성을 함께 검토하는 방식으로 진행
- ▶ 아이디어 제안 정류소 운영 비용 마련 방안으로 압전 에너지 하베스팅(승객 발자국 에너지 수집) + 태양광 발전 결합 방식 제안
- ▶ 결과 IoT 센서·압전 하베스팅·태양광 결합 친환경 스마트 정류소 모델 완성 — 도시 모빌리티 데이터 수집 인프라 문제 해결을 위한 저전력·자가발전 데이터 수집 노드 컨셉 설계

연구 프로젝트

2025.

팀 4 명

대학 기숙사 운영 유형 분류 (대학알리미 공시 데이터)

2025 대학알리미 데이터 아이디어 공모전 참가작 (교육부·한국대학교육협의회, 미수상)

- ▶ **문제** 대학 기숙사 수용률이 5년간 23.2~23.8%에 정체(2024년 대학 23.4%, 전문대학 18.0%)되어 있으나, 대학별 운영 방식의 차이를 설명할 분류 기준이 부재
- ▶ **담당** 데이터 수집·전처리, 지표 정의 및 4분면 분류 기준 설정, 카드뉴스 기획·디자인, 발표 담당 (팀 4명). 수용률 = 수용가능인원/재학생×100, 이익률 = (수익총계-비용총계)/수익총계×100으로 정의
- ▶ **방법** 수용률 30%·이익률 20%를 기준선으로 공공복지형·균형형·수익중심형·형식적 운영형 4개 유형 분류. 공립은 전부 형식적 운영형, 국립·국립대법인은 대부분 공공복지형, 특별법국립은 균형형 비중이 높음을 지역·설립구분별로 확인
- ▶ **팀 분석** 팀원이 수행한 이항 로지스틱 회귀에서 인건비·운영비가 높을수록 수익형 확률이 낮고, 재학생 수·경쟁률이 높을수록 수익형 확률이 높게 나타남
- ▶ **결과** 경쟁률 문제(시설 확충·입사 기준 개선·수익 재투자)와 비용 문제(예산 투명화·학생 참여 운영·인력 효율 분석)로 나눠 6개 개선안 제시

2025.

개인

국제 메타데이터 표준 통합 LLM 기반 그래프 증강 추천시스템

수업 프로젝트 · 활용: LLM (GPT/LLaMA/Gemma), LightGCN

- ▶ **문제** LLM(LLMRec)이 생성한 메타데이터를 활용하는 과정에서, LLM 산출물 특유의 표면형 비일관성(USA·United States·America 혼재)이 시스템 간 상호운용성을 해치는 문제를 발견
- ▶ **방법** 국제 표준(ISO 3166-1 alpha-2, BCP 47) 정규화 레이어 설계. 필드별 형식 적합률 지표 정의. Netflix 17,366건 대상 정규화 후 LightGCN 추천 성능 유지 여부를 seed 10회 반복으로 검증
- ▶ **결과** 표준 적합률 0.484 → 0.914로 향상. country 표면형 1,166개 → 표준 코드 57개, language 326 → 52개. 상호운용성 0 → 80.3%. column-shift 724건 자동 검출. LightGCN 추천 성능 유지 확인(7개 지표 전부 $p > 0.05$) — 정규화 이후 하위 태스크 성능 손실 없음을 입증하여 데이터 품질·상호운용성 개선을 핵심 기여로 확정

2024. - 2025.

팀 2 명

sLLM + Advanced RAG를 활용한 SONY 브랜드 AI 설명서 챗봇

활용: LangChain, Chroma, bge-m3, KoAlpaca-llama-7b, Streamlit

- ▶ **문제** 제품별 설명서 PDF가 분리되어 사용자가 해당 문서·페이지를 직접 탐색해야 함. sLLM은 할루시네이션 한계
- ▶ **방법** PyMuPDF 페이지 단위 로드, 청크 500/overlap 50, bge-m3 임베딩 + Chroma 영속화. 유사도 top-5 후 제품명 필터($\cos \geq 0.7$). KoAlpaca-llama-7b 생성, 페이지 번호 반환. 검색 실패 시 Tavily 웹 검색 fallback. Streamlit 웹 인터페이스
- ▶ **결과** SONY 7개 제품(카메라·헤드폰·스피커) 매뉴얼 기반 챗봇 구현. 답변마다 근거 청크의 파일명·페이지 번호 반환으로 출처 추적
- ▶ **개선 방향** 정량 평가·한국어 특화 임베딩 도입·필터 임계 튜닝을 고도화 방향으로 도출

2025.

개인

SGMCMC 기반 3D 객체 탐지 모델 최적화

수업 프로젝트 · 활용: PyTorch, OpenPCDet, KITTI, CUDA

- ▶ **문제** 기존 Adam 기반 3D 객체 탐지는 점추정만 가능하여 파라미터 불확실성 추정·다중 모드 탐색 한계 → 베이지안 샘플링 기반 대안 탐색

	▶ 방법 KITTI + OpenPCDet + CT-Stack 백본 + PointPillars 아키텍처 + GClou 손실 환경 고정. Adam 을 기준 모델로 두고 SGMCMC 계열을 동일 조건으로 적용(80 epoch, batch 8, OneCycle LR)해 비교 ▶ 결과 Adam 65.15% vs SGHMC 49.59% (BEV AP Moderate) — 이 과제에서는 적응적 학습률·확률적 탐색보다 결정적임을 확인. SGMCMC 계열 내에서는 모멘텀 기반 SGHMC가 무작위 보행 방식(SGLD 25.67%) 대비 뚜렷한 우위 ▶ 시사점 최저 손실(SGHMC 0.813)과 최고 성능(Adam)이 불일치 → 손실 최소화와 과업 성능 보장이 다를 수 확인, Adam+SGHMC 하이브리드를 향후 과제로 제시
2025. 개인	AWSGLD-TNTM 을 활용한 미국 자율주행·자동차 TBT 규제 트렌드 분석 ▶ 문제 미국 Federal Register 다년간 규제 문서의 LDA 한계 극복 → AWSGLD-TNTM 적용으로 K=8 토픽 도출, 연도별 토픽 강도 및 네트워크 구축 ▶ 결과 LDA 대비 Topic Coherence 약 37% 향상(0.42 → 0.5743), Topic Diversity 0.82 로 토픽 중복도 감소. 팬데믹 영향 유예기(2020~21) → 환경·화학 규제 강화(2022~23) → 연비·디지털 안전 확산기(2024~25, TBT 통보 각 212 건·203 건)의 3 단계 규제 패러다임 정량 규명 ▶ 시사점 국내 자율주행·자동차 산업의 TBT 대응 전략 수립을 위한 데이터 근거 제공
2023. 팀 2 명	GAN 기반 손글씨 폰트 생성 및 로봇팔 제어 다가치 로봇 소모임 (역할 분담 없이 공동 진행) 활용: TensorFlow, GAN(zi2zi, pix2pix), RoboDK, WLKATA Mirobot ▶ 문제 WLKATA Mirobot 내장 Drawing 기능은 도형·간단한 글씨만 가능 → 임의의 한글 손글씨를 학습·생성해 로봇팔이 쓰게 하는 통합 파이프라인 시도 ▶ 방법 25 종 폰트 × 한글 글자 75,000 장 이미지(128×256 px)로 zi2zi 기반 GAN(pix2pix + AC-GAN + DTN Constant Loss) 사전학습 후 직접 작성한 210 자로 Transfer Learning ▶ 결과 손글씨 스타일 이미지 생성 성공 ▶ 개선 방향 WLKATA Studio API 와 RoboDK 간 호환 문제 → OpenCV 기반 이미지→경로 변환으로 해결하는 방향 도출
2025. 개인	SAMC 알고리즘 R 패키지화 (3 종 백엔드) 활용: R, Rcpp/C, reticulate/Python ▶ 담당 R 패키지 빌드 구조 구성 담당 ▶ 방법 확률적 근사 몬테카를로(SAMC) 알고리즘을 순수 R · Rcpp 를 통한 C 연결 reticulate 를 통한 Python 연결 세 형태로 각각 패키지화 ▶ 결과 devtools::install 로 설치·호출 가능한 R 패키지 3 종 완성. 동일 알고리즘의 세 구현 방식별 차이 정리
2024. 팀 2 명	베이지안 강수예보 정확도 분석 (베이지안 갱신·검정) 학부 PBL · 기상청 강수 확률· 강수 유무 데이터 18 만 건 ▶ 문제 기상청 예보 정확도는 90%에 가까우나 실제 강수 유무 적중률은 40~60%대에 머무름 → 확률 기반의 예보 신뢰도 평가 접근 필요 ▶ 담당 사전확률 설계, 사후확률 갱신, 베이지안 검정, 결론 담당 (팀원 2 명, 데이터 수집·전처리 공동) ▶ 방법 세종시 2023 년 18 만 건으로 예보 시간·강수확률별 결합분포 구성. 사전확률 설계 → 베이지안 갱신 → 베이즈 팩터 검정

	▶ 결과 강수확률 60% 이하는 사후확률 0 에 수렴, 70-79%는 88, 90-100%는 95. BF 검정으로 임계 강수확률 60% 도출 — 예보 신뢰도 정량 평가의 기반 데이터 제공
2025.03. – 2025.09. 팀 2 명	파인튜닝과 CAG(Context-Augmented Generation) 결합을 통한 대화형 AI 성능 개선 연구: 기후정책 사례 분석 ▶ 담당 에코업혁신융합대학사업단 학부생 연구원 프로그램 대학원생 멘토 — 연구 주제 구체화 · 방법론(QLoRA · CAG) 선정 · 실험 설계와 평가 지표 검토를 멘티 1 명과 공동 수행 ▶ 방법 QLoRA 4bit 양자화로 도메인 적합성을 높이고, 외부 문서를 캐시에 선적재(Key-Value)해 검색 지연 없이 응답하는 CAG 를 결합한 FT+CAG 구조 제안 ▶ 결과 질문 5 개 × 5 회 반복 실행, BLEU · ROUGE · BERTScore · CHRF · METEOR · TER 6 종 지표에서 FT 단독 대비 품질 · 일관성 우수 확인 · 2025 에코업 진학박람회 포스터 발표
2025. 개인	강화학습 기반 피카츄 배구 Agent 학습 활용: gymnasium ▶ 문제 규칙 기반 하드코딩된 상대 AI 를 상대로 스스로 배구 전략(공 위치 추적·점프·파워히트)을 학습하는 강화학습 agent 설계 ▶ 방법 gymnasium PykachuVolleyball 환경. 관측이 432×304×3 RGB 로 표 기반 학습 직접 사용 불가 → 공·플레이어 좌표를 20px 격자로 이산화한 4-tuple 상태 정의. 총 18 개 이산 행동(좌우·상하·파워히트 조합), Epsilon-Greedy 1.0→0.1. 승 +15/패 -10 희소 보상에 랠리·이동·타격·근접 항 더해 밀집 보상 재설계 ▶ 결과 초기 4000+ 에피소드에서는 전략 미형성, 5000+ 에피소드부터 점프·이동·파워히트 정교화 확인 ▶ 개선 방향 상태 정의에 공 속도를 추가해 Markov 성질 확보
대외활동 및 리더십	
2025.01.	미국 UNLV 4 주 글로벌 연수 + CES 2025 현장 참관 미국 라스베가스 UNLV · 임베디드 AI 및 머신러닝 과목 수강 · 팀 실습 · CES 2025 및 현지 대학 참관
학부·석사 기간	AI·데이터 학회 및 산업 컨퍼런스 지속 참여 ▶ 학술 한국자료분석학회(KDAS) 포스터 발표(장려상, 2026) · 한국통계학회 등 청강 ▶ 산업 LG AI · SK AI Summit · GenCon · AI 포럼 등 참관 — LLM · 자율주행 · 데이터 플랫폼 세션
2022. – 2023. 팀	마케팅 서포터즈 4 건 ▶ 예규레이션 (백종원의 예산시장 살리기) 5 인 팀 리더 — 구구통닭 매장 홍보 담당, 인생극장 형식 영상 단일 2,500 회 · 콘텐츠 29 건 총 3,671 회 ▶ KU_KEY (세종캠퍼스 현장실습지원센터) 1·2 기 — 홍보 콘텐츠 카테고리 설계, 기업 소개 카드 제작 ▶ 사야컴퍼니 맥스달튼 · 프랑코 폰타나 전시 — 티켓 증정 이벤트 기획·운영, 홍보 콘텐츠 제작