

경력기술서

김다연

dayun0405@gmail.com | 포트폴리오 kim-da-yeon.github.io | GitHub Kim-Da-yeon



Summary

- KCI 등재지 한국자료분석학회지(JKDAS) 제 1 저자 논문 2 편 게재
- SCI 급 학술지 1 편 2026.09. 투고 예정 (심사 전)

- NRF 석사과정생연구장려금 연구책임자(PI) 선정, BNTM 확장 연구를 제 1 저자로 진행 중
- LLM(LoRA 어댑터)·토크 모델(모수화)·샘플러(추론기)·3D 탐지(손실·최적화기) 구조 분석 후 구성요소 단위 교체·재설계
- 자율주행·모빌리티·스마트팜 등 실제 도메인 프로젝트로 문제 정의부터 결과 해석까지 수행

학력

2025.03. - 현재	고려대학교 일반대학원 · 빅데이터사이언스학과 석사과정 졸업예정: 2027.02. · 석사 학위논문: BNTM with AWSGHMC (SCI 투고)
2021.03. - 2025.02.	고려대학교 세종캠퍼스 · 빅데이터사이언스학부 학사 융합전공: 자율주행시스템학과

실무 경험

2023.12. - 2024.03. 팀 2 명	JERESFARM · 데이터분석 인턴 스마트팜 도메인 · 활용: Python, scikit-learn, statsmodels, LGBM 상황 작물 생육 데이터가 하루 1 회 사람이 줄자로 직접 측정(18 개 개체, 20 일 관측)에 그쳐 종속변수 관측 절대 부족. 사내에 데이터 분석 전담 인력이 없어 외부 자문 병행 및 자체 조사로 분석 수행 담당 최적 환경 도출과 데이터 구축을 위한 센서 환경 세팅 방안 결정 담당 (팀원 2 명 공동 진행) 시계열 분석 ARIMA·VAR·VECM 여러 시계열 기법으로 최적 생장 환경 도출 시도. 결측 구간 보간 후 유의성 검정으로 독립변수 유의성 제약 조건을 정량 검증. Lasso 회귀로 유의 변수 15 개 후보 추출, Y 관측 부족의 구조적 한계를 결론에 명시 공공 데이터 확장 현장 데이터 한계 근거로 농촌진흥청 공공 데이터 재접근 → 6 개 모델(DT, SVM, K-NN, Bagging, RF, LGBM) 비교하여 6 종 작물 다중 분류. LGBM 최종 선정 — Test F1 0.81 이지만 Train-Test 격차가 세 앙상블 중 가장 작아 과적합 위험 최소 결과 도출 Feature Importance 로 온도>일사량>CO2 순 영향력 규명, Partial Dependence Plot 으로 온도 25°C·CO2 400ppm 등 변수별 임계 구간 도출 후속 활동 다음 작물 딸기의 정확한 측정을 위해 회사 사람들과 함께 딸기 농장 사전 조사, 카메라 센서 구성 방식 협의. 데이터 한계의 원인을 측정 설계 단계로 규명
---------------------------------	--

연구 참여

2025. - 2026.	TNTM 을 활용한 임베디드 시스템 문서의 주제 흐름 분석
---------------	----------------------------------

연구책임자 (석사과정생연구장려금) · RS-2025-25437035

▶ 성과 관련 논문 1 편 투고 예정

2024. - 2027.

베이지안 추론을 위한 적응적 가중 SGMCMC 알고리즘

참여연구원 (한국연구재단) · RS-2024-00352792

▶ 기여 2 차년도(2025-2026) 연구 수행 전담 — 샘플러 구현, 실험 설계·수행, 결과 분석

▶ 성과 제 1 저자 논문 3 편(게재 2 · 투고 예정 1), 학회 발표 1 건

2025. - 2026.

초격차산업기반표준전문인력양성

참여연구원 (KIAT, 표준학 융합전공) · RS-2025-02215617

▶ 기여 표준학 융합전공 이수와 함께 표준 관련 프로젝트 3 건 중 2 건 수행 (1 건 진행 예정)

▶ 성과 LLM 국제 메타데이터 표준화, 미국 자율주행·자동차 TBT 규제 분석

논문

2025. - 2026.

Fixed-K Shrinkage BNTM with AWSGHMC Inference (2026.09. 투고 예정 · 심사 전)

Kim, D. & Cheon, S. (제 1 저자) · 석사 학위논문

- ▶ 담당 연구 가설 수립부터 모델 설계, 시뮬레이션 데이터 생성, 평가 지표 정의, 샘플러 구현, 실험 수행, 논문 작성까지 지도교수 자문 하에 전 과정 수행
- ▶ 문제 정의 선행 연구(JKDAS 28(1), AWSGLD)에서 남은 두 근본 한계 — 토픽 수 K 사전 고정, 노이즈 환경에서 이점 상쇄 — 를 문제 정의로 삼아 확장
- ▶ WHY Logistic-Normal 모수화 + Sparse Dirichlet Prior + AWSGHMC 하이브리드 추론을 선택한 이유: (1) Simplex 제약이 경사 기반 추론의 근본 걸림돌, Logistic-Normal 변환으로 무제약 공간에서 처리 가능 (2) K 사전 고정 문제를 데이터가 결정하게 하려면 희소 사전분포가 이론적으로 가장 안전 (3) 이산 잠재변수·연속 모수를 각각 다른 방식으로 처리해야 로컬 트랩 극복
- ▶ 결과 토픽 모델은 정답 라벨이 없어 성능 검증이 어렵다는 한계가 있음. 파라미터 중첩·희소 토픽·토픽 수 변동 등 까다로운 조건을 통제한 시뮬레이션 데이터를 직접 설계해 Ground-truth 기반 검증 체계를 구축(LDA·HTMM·TNTM·BNTM 전반에 재사용 가능). 설계한 5 개 환경 (Ktrue 8~40) 전부에서 활성 토픽 수를 정확히 복원(Keff=Ktrue, 10 seed 편차 0). 예: Ktrue=20 환경에서 AWSGHMC 20.0 vs SGHMC 15.4·SGLD 14.7(과소), MH 23.4(과다). 토픽-단어 Hellinger 0.09~0.17(SGLD 계열 0.40~0.65), Sentence Accuracy 전 환경 1.00. 시뮬레이션 검증 통과 후 FAERS·NTSB 실제 코퍼스에 적용

2026.

AWSGLD 를 이용한 전이 네트워크 토픽 모델 추론

Kim, D. & Cheon, S. (제 1 저자) · JKDAS 28(1), 109-121

- ▶ 문제 TNTM 은 문장 수를 모델링하지만 Simplex 제약으로 경사 기반 추론이 어려워 → 고차원 다중 모드 사후분포에서 로컬 트랩 발생
- ▶ 방법 TNTM 에 AWSGLD 적용 — 사후분포를 구간별 적응 가중해 다중 모드 사후 평탄화, 로컬 트랩 탈출 및 대규모 데이터 확장성 확보
- ▶ 결과 원본 데이터에서 SGD 대비 토픽 다양성 2 배(0.48→0.96), 노이즈 50 개 조건 SGLD 대비 Perplexity 약 10 배 우수 — Coherence·Diversity·Perplexity 종합 비교로 검증

2025.

자율주행 도메인에서 LoRA 기반 sLLM 파인튜닝 연구

Kim, D., Cheon, S. & Joo, A. (제 1 저자)

JKDAS 27(3), 769-780 · LoRA 파인튜닝

- ▶ **문제** 도메인 특화 sLLM 의 응답 품질 개선 필요, 전체 파라미터 파인튜닝은 임베디드 환경 자원 부담 큼
- ▶ **WHY** Phi-4-mini(3.8B)는 임베디드 자원 제약, LoRA 는 자원 효율과 도메인 적응의 균형 때문에 선정. 파인튜닝 vs 검색 증강 트레이드오프가 핵심 의사결정 지점이라 RAG 와 정량 비교로 검증
- ▶ **결과** BDD-X 자율주행 데이터셋(주행 영상 6,970 개·주석 26,228 개)으로 LoRA 파인튜닝, 전체 파라미터의 약 0.01%만 조정. 동일 조건 RAG(k=1) 대비 ROUGE-1 0.0888 → 0.1495 향상, 응답 시간 평균 1.145 초. Traffic violations 7 만 건 확장 실험 Accuracy 0.745·Macro F1 0.731

수상

2026.

한국자료분석학회 하계학술대회 포스터논문 부문 장려상

Fixed-K Shrinkage BNTM with AWSGLD Inference (제 1 저자)

발표 시점 AWSGLD 버전, 이후 AWSGHMC 로 확장

- ▶ **내용** 논문 「Fixed-K Shrinkage BNTM」 의 발표 시점 버전 (상세는 논문 항목 참조)
- ▶ **성공** 시뮬레이션·실제 코퍼스 양쪽에서 우수성 정량 입증

2023.

팀 3 명

통계학술제 최우수상 — 택시 수요 분석을 통한 택시 서비스 개선 방안 마련

고려대학교 빅데이터사이언스학부 · 담당: QGIS 시각화 · 분석 코드 구현

- ▶ **문제** 택시 요금 인상 후 기사·이용자 동반 이탈로 이용률 하락, 자치구별 수요·공급 불균형 해소 데이터 기반 배차 전략 부재
- ▶ **방법** 서울시 6 종 공공 데이터 병합, 계층적 군집분석(Ward.D) + 3 변수 증감 조합, QGIS 로 자치구별 공간 분포 시각화 담당, 공차율 웹 인터페이스 제작
- ▶ **핵심 결과** 25 개 자치구를 8 개 조합 중 6 개 군집으로 배정 (B·G 공집합) — 강남·서초(전 지표 상승), 중구(관광·업무 특성), 저조 지역(광진·중랑·도봉 등)별 차별화된 배차·서비스 전략 제안

2023.

팀 2 명

미래모빌리티 및 세종지역혁신 아이디어 공모전 장려상

Smart Green-STOP (친환경 스마트 정류소) · (3D 구현 담당) · 주관: 세종특별자치시

- ▶ **담당** 3D 구현 담당. 팀원과 서로 아이디어를 제시하고 실현 가능성을 함께 검토하는 방식으로 진행
- ▶ **아이디어 제안** 정류소 운영 비용 마련 방안으로 압전 에너지 하베스팅(승객 발자국 에너지 수집) + 태양광 발전 결합 방식 제안
- ▶ **결과** IoT 센서·압전 하베스팅·태양광 결합 친환경 스마트 정류소 모델 완성 — 도시 모빌리티 데이터 수집 인프라 문제 해결을 위한 저전력·자가발전 데이터 수집 노드 컨셉 설계

연구 프로젝트

2025.

팀 4 명

대학 기숙사 운영 유형 분류 (대학알리미 공시 데이터)

2025 대학알리미 데이터 아이디어 공모전 참가작 (교육부·한국대학교육협의회, 미수상)

- ▶ **문제** 대학 기숙사 수용률이 5 년간 23.2~23.8%에 정체(2024 년 대학 23.4%, 전문대학 18.0%)되어 있으나, 대학별 운영 방식의 차이를 설명할 분류 기준이 부재
- ▶ **담당** 데이터 수집·전처리, 지표 정의 및 4 분면 분류 기준 설정, 카드뉴스 기획·디자인, 발표 담당 (팀 4 명). 수용률 = 수용가능인원/재학생×100, 이익률 = (수익총계-비용총계)/수익총계×100

	으로 정의
▶ 방법	수용률 30%·이익률 20%를 기준선으로 공공복지형·균형형·수익중심형·형식적 운영형 4 개 유형 분류. 공립은 전부 형식적 운영형, 국립·국립대법인은 대부분 공공복지형, 특별법국립은 균형형 비중이 높음을 지역·설립구분별로 확인
▶ 팀 분석	팀원이 수행한 이항 로지스틱 회귀에서 인건비·운영비가 높을수록 수익형 확률이 낮고, 재학생 수·경쟁률이 높을수록 수익형 확률이 높게 나타남
▶ 결과	경쟁률 문제(시설 확충·입사 기준 개선·수익 재투자)와 비용 문제(예산 투명화·학생 참여 운영·인력 효율 분석)로 나눠 6 개 개선안 제시

2025.
개인

국제 메타데이터 표준 통합 LLM 기반 그래프 증강 추천시스템

수업 프로젝트 · 활용: LLM (GPT/LLaMA/Gemma), LightGCN

- ▶ 문제 LLM(LLMRec)이 생성한 메타데이터를 활용하는 과정에서, LLM 산출물 특유의 표면형 비일관성(USA·United States·America 혼재)이 시스템 간 상호운용성을 해치는 문제를 발견
- ▶ 방법 국제 표준(ISO 3166-1 alpha-2, BCP 47) 정규화 레이어 설계. 필드별 형식 적합률 지표 정의. Netflix 17,366 건 대상 정규화 후 LightGCN 추천 성능 유지 여부를 seed 10 회 반복으로 검증
- ▶ 추천 실험 정규화 전후 임베딩으로 LightGCN 추천 성능을 seed 10 회 반복 측정하고 recall@k · ndcg@k 를 대응표본 t-검정으로 비교. LLMRec 이 생성한 Netflix 메타데이터 17,366 건을 학습 · 평가에 사용
- ▶ 결과 표준 적합률 0.484 → 0.914 로 향상. country 표면형 1,166 개 → 표준 코드 57 개, language 326 → 52 개. 상호운용성 0 → 80.3%. column-shift 724 건 자동 검출. LightGCN 추천 성능 유지 확인(7 개 지표 전부 $p > 0.05$) — 정규화 이후 하위 태스크 성능 손실 없음을 입증하여 데이터 품질·상호운용성 개선을 핵심 기여로 확정

2024. - 2025.
팀 2 명

sLLM + Advanced RAG 를 활용한 SONY 브랜드 AI 설명서 챗봇

활용: LangChain, Chroma, bge-m3, KoAlpaca-llama-7b, Streamlit

- ▶ 문제 제품별 설명서 PDF 가 분리되어 사용자가 해당 문서·페이지를 직접 탐색해야 함. sLLM 은 할루시네이션 한계
- ▶ 방법 PyMuPDF 페이지 단위 로드, 청크 500/overlap 50, bge-m3 임베딩 + Chroma 영속화. 유사도 top-5 후 제품명 필터($\cos \geq 0.7$), Re-rank 로 질의 관련도 순 재정렬 — 긴 컨텍스트 중간에 놓인 근거가 반영되지 않는 문제 대응. KoAlpaca-llama-7b 생성, 페이지 번호 반환. 검색 실패 시 Tavily 웹 검색 fallback. Streamlit 웹 인터페이스
- ▶ 결과 SONY 6 개 제품(카메라·헤드폰·스피커) 매뉴얼 기반 챗봇 구현. 답변마다 근거 청크의 파일명·페이지 번호 반환으로 출처 추적
- ▶ 개선 방향 정량 평가·한국어 특화 임베딩 도입·필터 임계 튜닝을 고도화 방향으로 도출

2025.
개인

SGMCMC 기반 3D 객체 탐지 모델 최적화

수업 프로젝트 · 활용: PyTorch, OpenPCDet, KITTI, CUDA

- ▶ 문제 기존 Adam 기반 3D 객체 탐지는 점추정만 가능하여 파라미터 불확실성 추정·다중 모드 탐색 한계 → 베이지안 샘플링 기반 대안 탐색
- ▶ 방법 KITTI + OpenPCDet + CT-Stack 백본 + PointPillars 아키텍처 + GCIoU 손실 환경 고정. Adam 을 기존 모델로 두고 SGMCMC 계열을 동일 조건으로 적용(80 epoch, batch 8, OneCycle LR)해 비교
- ▶ 결과 Adam 65.15% vs SGHMC 49.59% (BEV AP Moderate) — 이 과제에서는 적응적 학습률·확률적 탐색보다 결정적임을 확인. SGMCMC 계열 내에서는 모멘텀 기반 SGHMC 가

	무작위 보행 방식(SGLD 25.67%) 대비 뚜렷한 우위 ▶ 시사점 최저 손실(SGHMC 0.813)과 최고 성능(Adam)이 불일치 → 손실 최소화와 과업 성능 보장이 다름을 확인, Adam+SGHMC 하이브리드를 향후 과제로 제시
2025. 개인	AWSGLD-TNTM 을 활용한 미국 자율주행·자동차 TBT 규제 트렌드 분석 ▶ 문제 미국 Federal Register 원문 160 건의 LDA 한계 극복 → AWSGLD-TNTM 적용으로 K=8 토픽 도출, 연도별 토픽 강도 및 네트워크 구축 ▶ 결과 LDA 대비 Topic Coherence 약 37% 향상(0.42 → 0.5743), Topic Diversity 0.82 로 토픽 중복도 감소. 팬데믹 영향 유예기(2020~21) → 환경·화학 규제 강화(2022~23) → 연비·디지털 안전 확산기(2024~25, TBT 통보 각 212 건·203 건)의 3 단계 규제 패러다임 정량 규명 ▶ 시사점 국내 자율주행·자동차 산업의 TBT 대응 전략 수립을 위한 데이터 근거 제공
2023. 팀 2 명	GAN 기반 손글씨 폰트 생성 및 로봇팔 제어 다가치 로봇 소모임 (역할 분담 없이 공동 진행) 활용: TensorFlow, GAN(zi2zi, pix2pix), RoboDK, WLKATA Mirobot ▶ 문제 WLKATA Mirobot 내장 Drawing 기능은 도형·간단한 글씨만 가능 → 임의의 한글 손글씨를 학습·생성해 로봇팔이 쓰게 하는 통합 파이프라인 시도 ▶ 방법 25 종 폰트 × 한글 글자 75,000 장 이미지(128×256 px)로 zi2zi 기반 GAN(pix2pix + AC-GAN + DTN Constant Loss) 사전학습 후 직접 작성한 210 자로 Transfer Learning ▶ 결과 손글씨 스타일 이미지 생성 성공 ▶ 개선 방향 WLKATA Studio API 와 RoboDK 간 호환 문제 → OpenCV 기반 이미지→경로 변환으로 해결하는 방향 도출
2025. 개인	SAMC 알고리즘 R 패키지화 (3 종 백엔드) 활용: R, Rcpp/C, reticulate/Python ▶ 담당 R 패키지 빌드 구조 구성 담당 ▶ 방법 확률적 근사 몬테카를로(SAMC) 알고리즘을 순수 R · Rcpp 를 통한 C 연결 reticulate 를 통한 Python 연결 세 형태로 각각 패키지화 ▶ 결과 devtools::install 로 설치·호출 가능한 R 패키지 3 종 완성. 동일 알고리즘의 세 구현 방식별 차이 정리
2024. 팀 2 명	베이지안 강수예보 정확도 분석 (베이지안 갱신·검정) 학부 PBL · 기상청 강수 확률 · 강수 유무 데이터 18 만 건 ▶ 문제 기상청 예보 정확도는 90%에 가까우나 실제 강수 유무 적중률은 40~60%대에 머무름 → 확률 기반의 예보 신뢰도 평가 접근 필요 ▶ 담당 사전확률 설계, 사후확률 갱신, 베이지안 검정, 결론 담당 (팀원 2 명, 데이터 수집·전처리 공동) ▶ 방법 세종시 2023 년 18 만 건으로 예보 시간·강수확률별 결합분포 구성. 사전확률 설계 → 베이지안 갱신 → 베이지 팩터 검정 ▶ 결과 강수확률 60% 이하의 사후확률 0 에 수렴, 70-79%는 88, 90-100%는 95. BF 검정으로 임계 강수확률 60% 도출 — 예보 신뢰도 정량 평가의 기반 데이터 제공
2025.03. - 2025.09.	파인튜닝과 CAG(Context-Augmented Generation) 결합을 통한 대화형 AI 성능 개선 연구: 기후정책 사례 분석

팀 2 명	▶ 담당 에코업혁신융합대학사업단 학부생 연구원 프로그램 대학원생 멘토 — 연구 주제 구체화 · 방법론(QLoRA · CAG) 선정 · 실험 설계와 평가 지표 검토를 멘티 1 명과 공동 수행 ▶ 방법 QLoRA 4bit 양자화로 도메인 적합성을 높이고, 외부 문서를 캐시에 선적재(Key-Value)해 검색 지연 없이 응답하는 CAG 를 결합한 FT+CAG 구조 제안 ▶ 결과 질문 5 개 × 5 회 반복 실행, BLEU · ROUGE · BERTScore · CHRF · METEOR · TER 6 중 지표에서 FT 단독 대비 품질 · 일관성 우수 확인 · 2025 에코업 진학박람회 포스터 발표
-------	--

2025.
개인

강화학습 기반 피카츄 배구 Agent 학습

- 활용: gymnasium
- ▶ **문제** 규칙 기반 하드코딩된 상대 AI 를 상대로 스스로 배구 전략(공 위치 추적·점프·파워히트)을 학습하는 강화학습 agent 설계
 - ▶ **방법** gymnasium PykachuVolleyball 환경. 관측이 432×304×3 RGB 로 표 기반 학습 직접 사용 불가 → 공·플레이어 좌표를 20px 격자로 이산화한 4-tuple 상태 정의. 총 18 개 이산 행동(좌우·상하·파워히트 조합), Epsilon-Greedy 1.0→0.1. 승 +15/패 -10 희소 보상에 랠리·이동·타격·근접 항 더해 밀집 보상 재설계
 - ▶ **결과** 초기 4000+ 에피소드에서는 전략 미형성, 5000+ 에피소드부터 점프·이동·파워히트 정교화 확인
 - ▶ **개선 방향** 상태 정의에 공 속도를 추가해 Markov 성질 확보

대외활동 및 리더십

2025.01.

미국 UNLV 4 주 글로벌 연수 + CES 2025 현장 참관

미국 라스베이가스 UNLV · 임베디드 AI 및 머신러닝 과목 수강 · 팀 실습 · CES 2025 및 현지 대학 참관

학부·석사 기간

AI·데이터 학회 및 산업 컨퍼런스 지속 참여

- ▶ **학술** 한국자료분석학회(KDAS) 포스터 발표(장려상, 2026) · 한국통계학회 등 청강
- ▶ **산업** LG AI · SK AI Summit · GenCon · AI 포럼 등 참관 — LLM · 자율주행 · 데이터 플랫폼 세션

2022. - 2023. ·
팀

마케팅 서포터즈 4 건

- ▶ 예규레이션 (백종원의 예산시장 살리기) 5 인 팀 리더 — 구구통닭 매장 홍보 담당, 인생극장 형식 영상 단일 2,500 회 · 콘텐츠 29 건 총 3,671 회
- ▶ KU_KEY (세종캠퍼스 현장실습지원센터) 1·2 기 — 홍보 콘텐츠 카테고리 설계, 기업 소개 카드 제작
- ▶ 사야컴퍼니 맥스달튼 · 프랑코 폰타나 전시 — 티켓 증정 이벤트 기획·운영, 홍보 콘텐츠 제작

기술 능력

프로그래밍·도구: Python, R, SQL, Git, GPU Computing (CUDA), ROS · Autoware (학부 실습)

ML/DL: PyTorch, TensorFlow, scikit-learn, Transformers (LoRA/QLoRA)

샘플러 · 모델 구조: SGLD · SGHMC · AWSGLD · AWSGHMC · MH-within-Gibbs · SAMC 직접 구현 — 토픽 모델(LDA · HTMM · TNTM · BNTM) · sLLM(LoRA/QLoRA) · 3D 탐지(PointPillars · GCIoU) · 추천(LightGCN) 구성요소 교체

데이터 처리·시각화: Pandas, Matplotlib, Seaborn, ggplot2, QGIS

자격증·어학: ADsP (데이터분석 준전문가, 2023.11)