경력기술서

김다연



abcde0405@naver.com | 포트폴리오 kim-da-yeon.github.io | GitHub Kim-Da-yeon

핵심 요약

토픽 모델 BNTM과 샘플러를 직접 설계해 정답 토픽 수를 모의실험 환경 5종 모두 정확히 복원한 ML Researcher입니다.

경험 1. 새 토픽 모델 BNTM 설계 · 모의실험 데이터 생성 | perplexity 41.6% 감소 · 토픽 수 정확 복원

- 실데이터(FAERS) 문서 완성 perplexity HTMM 54.99 → BNTM 32.13, 정답 20토픽 환경의 추정 토픽 수 SGHMC 15.4개 → AWSGHMC 20.0개(SCI급 투고 예정 · 포스터논문 장려상)
- 기존 모델의 한계를 보완한 새 모델 설계 · 정답을 아는 모의실험 데이터 생성기(환경 5종) 제작 · 샘플러 구현 · 논문 작성까지 제1저자로 수행

경험 2. 3D 객체 탐지 SGMCMC 적용 | 최적화기 5종 비교 · BEV AP Adam 65.15% · SGHMC 49.59%

- KITTI · PointPillars에서 SGLD · SGHMC · SGNHT를 직접 구현해 Adam · SGD와 같은 조건으로 비교, SGMCMC 중에서는 SGHMC가 가장 높음
- SGNHT의 기울기 폭발 · 소실을 온도 탐색으로 확인 · 과목 A+

경험 3. 스마트팜 데이터 분석 인턴 | 검정으로 데이터 한계 확인 · 후속 측정 설계 제안

- 생육 데이터(개체 18개 · 20일)로는 영향요인을 규명할 수 없음을 검정으로 확인하고 후속 센서 · 카메라 배치와 측정 항목을 현업과 협의해 제안
- 데이터 분석팀이 없는 회사에서 지도교수님 조언을 받고 현업 팀원들에게 분석 내용을 설명하며 진행

학력

2025.03 – 2027.02 (졸업예정)
고려대학교 일반대학원 빅데이터사이언스학과 석사과정

2021.03 – 2025.02
고려대학교 세종캠퍼스 빅데이터사이언스학부 학사 · 융합전공 자율주행시스템학과 · 표준학

실무 경험

2023.12 – 2024.04
인턴 2명

JERESFARM · 데이터 분석 인턴

스마트팜 Python · statsmodels(VAR · VECM) · scikit-learn · Lasso

> **분석 인력이 없던 농장에서 생육 데이터(개체 18개 · 20일)로는 영향요인을 규명할 수 없음을 검정으로 확인하고, 후속 센서 · 카메라 배치와 측정 항목을 현업과 협의해 제안**

문제	센서 변수 29개에 비해 생육 크기는 개체 18개 · 20일 · 하루 1회 줄자 측정. 사내 데이터 분석 인력 없음
협업	데이터 분석팀이 없는 회사에 학부생 인턴 2명으로 합류. 데이터 쪽은 지도교수님께 조언을 구하고 현업 팀원들에게 분석 내용을 설명하며 진행. 소통에 시간이 오래 걸렸지만 서로 다른 도메인을 배움
분석	로그 차분 후 ADF 정상성 확인. VAR에서 유의수준 0.05의 유의 변수 없음 → 공적분 확인 후 VECM 재검정. Lasso(α=1) 변수 17개, 테스트 R^2 0.99
한계→해결	테스트 개체가 2개뿐이라 R^2 0.99는 신뢰할 수 없다고 판단, 원인을 종속변수 관측 부족으로 규명 → 다음 작물(딸기) 농장 사전 조사 · 센서 · 카메라 배치와 측정 항목 협의
다시 한다면	모델링 전에 개체별 센서와 시간대가 맞는 데이터를 먼저 확보

2024 1학기
팀 3명

환경에 따른 최적 작물 예측 (JERESFARM 인턴 후속)

통계학과 머신러닝 PBL · 결과 · 코드 농장 전달 Python · Pandas · scikit-learn · LightGBM · Feature Importance · PDP

> **농촌진흥청 공공 데이터(원본 827,080건, 학습 · 평가 90,000건)로 작물 5종과 랜덤 클래스 분류 모델 6개를 비교, Test F1 상위 앙상블 3개 중 격차가 가장 작은 LightGBM(Test 0.81, 작물 5종 평균 약 0.77, 격차 0.03 vs Bagging 0.17 · RF 0.21)을 선정하고 결과와 코드를 JERESFARM에 전달**

문제 인턴 때 생육 영향요인을 규명하지 못한 문제를 수업 PBL에서 공공 데이터로 다시 정의 → 환경으로 작물을 예측하면 작물별 최적 환경과 토지에 맞는 작물을 함께 찾을 수 있음

해결 공통 환경변수 5개 선정, 원본 827,080건을 239,192건으로 정제, 클래스별 15,000건으로 맞춰 Decision Tree · SVM · K-NN · Bagging · Random Forest · LightGBM 비교

결과 Train → Test F1 LightGBM 0.84 → 0.81 · Bagging 0.98 → 0.82 · RF 1.00 → 0.79. 영향력 온도 > 일사량 > CO_2, 임계 구간은 작물별로 다름(예: 참외 · 오이 25°C)

다시 한다면 토양 등 환경 변수와 작물 데이터 추가. 환경 변수 5개만으로 작물 적합성을 판단할 수 있는지가 남은 의문

대표 연구 성과 순

2025 – 2026
제1저자 · 공저 2인

Fixed-K Shrinkage Bayesian Transition Network Topic Model with AWSGHMC Inference

SCI급 학술지 투고 예정 Python · NumPy · SG-MCMC(AWSGHMC · SGHMC · SGLD) · MH-within-Gibbs · 베이지안 추론

> **기존 토픽 모델의 한계를 보완한 새 토픽 모델 BNTM과 샘플러 AWSGHMC를 직접 설계하고, 정답을 아는 모의실험 데이터(환경 5종)를 생성해 검증 · 실데이터(FAERS) 문서 완성 perplexity를 HTMM 54.99 → 32.13(41.6%↓)으로 낮추고, 정답 20토픽 환경의 추정 토픽 수를 SGHMC 15.4개 → AWSGHMC 20.0개로 정확 복원 · 포스터논문 장려상**

목표 ① 문장 순서가 있는 텍스트를 LDA · HTMM보다 잘 설명하는 모델 ② 멀티모달 사후분포를 안정적으로 추정하는 샘플러. 샘플러를 고정하고 모델을, 모델을 고정하고 샘플러를 바꿔 각각 검증

문제 LDA는 문장 순서를 무시하고 HTMM은 전이를 값 하나로 요약, TNTM은 토픽 수를 미리 정하고 확률 단체 제약으로 경사 기반 추론이 어려움. 선행 연구(AWSGLD-TNTM)에서도 seed에 따라 토픽 구조가 크게 달라져 원인을 모델 구조로 판단

내 역할 모델 · 샘플러 · 모의실험 데이터 생성기 설계, 구현, 실험, 논문 작성. 지도교수 교신

해결 Logistic-Normal 모수화(Simplex 제약 제거) + Sparse Dirichlet Prior(활성 토픽 수를 데이터가 결정) + AWSGHMC(멀티모달 사후분포의 로컬 트랩 탈출)를 결합한 새 모델 BNTM과 샘플러를 설계

검증 설계 토픽 모델은 정답 라벨이 없어 결과 검증이 어려움 → 정답 토픽 · 전이 · 비중을 정해 둔 모의실험 데이터 생성기를 직접 설계. 환경마다 어려움 하나만 키운 5종(기본 · 초과 용량 K 40 · 다수 토픽 20 · 소표본 200건 · 대규모 10,000건)

모델 비교 5개 환경 모두 BNTM의 문서 완성 perplexity가 모든 관찰 길이에서 HTMM보다 낮고 LDA보다 크게 낮음(40토픽 환경 HTMM 대비 약 20포인트)

샘플러 비교 AWSGHMC만 5개 환경 모두 K 정확 복원. 다수 토픽 환경(정답 20)에서 SGHMC 15.4 · SGLD 14.7 · MH 23.4, 토픽-단어 Hellinger 거리 0.09~0.17로 최소

실데이터 문서 완성 perplexity FAERS 이상반응 보고서 14,316건 BNTM 32.13 · HTMM 54.99 · LDA 78.23, NTSB 항공사고 서술문 17,733건 472.1 · 498.5 · 1,090.7. 같은 모델에서 샘플러 비교 시 AWSGHMC가 두 데이터 모두 perplexity 최저(FAERS는 전체 배치 MH 32.30과 근접, MH는 반복당 비용이 큼)

한계→해결 모의실험 기준으로 맞춘 샘플러 설정이 실데이터의 큰 에너지 범위에서 작동하지 않음(한 구간에 갇힘) → 구간 폭을 데이터 에너지 범위에 비례하도록 바꿔 정상화

다시 한다면 수동으로 조정한 에너지 구간 폭을 말뭉치에 맞춰 자동으로 정하는 규칙부터 만듦

포스터

2025 – 2026
연구책임자 · 제1저자

전이 네트워크 토픽 모델을 이용한 임베디드 기술의 성장 예측

한국연구재단 석사과정생연구장려금 과제 성과 · 투고 예정 Python · GPU 샘플러 · Google BigQuery(SQL) · OpenAlex · L2 로지스틱 회귀

> **논문 초록 114,066건 · 미국 특허 21,028건(BigQuery SQL로 직접 추출)으로 3년 뒤 성장할 기술 토픽을 예측해 AUC 논문 0.876 · 특허 0.746(무작위 0.5, 토픽 모델까지 기준연도별 재추정 시 0.828 · 0.691), 성장 이유를 토픽 전이로 설명**

목표 임베디드 분야에서 3년 뒤 크게 성장할 기술 토픽을 정확히 예측하고, 성장 이유를 문장 사이의 토픽 전이 구조로 설명

문제 기존 연구는 토픽 비중 · 키워드 · 인용 · 특허 지표를 썼고, 신경망 예측은 정확해도 성장 이유를 설명하기 어려움. 기존 TNTM은 전이행렬이 전 기간에 하나뿐

내 역할 데이터 수집 · 정제 · GPU 샘플러 구현 · 변수 정의 · 평가 설계 · 논문 작성

해결 연도별 전이행렬을 계층 사전분포로 묶어 TNTM 확장(K=40, AWSGLD). 전이 네트워크에서 유입 · 자기전이 · 유입 출처 · 구조 변화 변수 8개를 직접 정의하고 데이터 변수 14개와 함께 예측 모형 구성

데이터 Google BigQuery 공개 특허 데이터셋에서 SQL로 미국 특허 21,028건(524,424문장)을, OpenAlex에서 임베디드 관련 12개 구문으로 논문 초록 114,066건을 직접 추출 · 정제

결과 문서 완성 perplexity 논문 TNTM 1172 · HTMM 1223 · LDA 2149. 성장 기준을 상위 10% · 30%로 바꿔도 AUC 논문 0.896 · 0.881 유지. 유입 증가(+0.31) · 자기전이(−0.28)가 주요 계수 → 다른 토픽에서 문장이 넘어오는 토픽이 성장

한계→해결 시점을 섞은 교차검증은 미래 정보가 섞여 성능이 부풂 → 과거 자료로만 학습하는 rolling-origin 평가(논문 13개 · 특허 11개 결과연도). 토픽 모델까지 기준연도마다 다시 추정해 기준연도 이후 문헌을 빼도 AUC 논문 0.828 · 특허 0.691

2025 – 2026
제1저자

AWSGLD를 이용한 전이 네트워크 토픽 모델 추론

한국자료분석학회지 28(1) 109–121 게재 Python · AWSGLD · TNTM

> **TNTM 추론을 MH-Gibbs + AWSGLD로 바꿔 IMDB 리뷰 1,000문장 실험에서 토픽 다양성 SGD 0.48 → AWSGLD 0.96(SGLD도 0.96), 문장마다 무작위 단어 50개를 넣은 조건의 perplexity는 SGLD보다 약 8배 낮음 (m=30)**

목표 TNTM의 추론을 확률적 기울기 기반 표본추출로 대체해, 잡음이 있는 텍스트에서도 토픽 전이 구조를 추정

내 역할 추론 수식 유도, 구현, 실험, 논문 작성. 지도교수 교신

해결 문장 토픽은 MH-Gibbs, 전이행렬 · 단어-토픽 분포는 AWSGLD로 추론. 추론에 필요한 미분식을 유도해 구현하고, 문장마다 무작위 단어 0 · 50 · 100개를 넣어 SGD · SGLD와 비교

한계→해결 토픽 수 K를 미리 정해야 하고 잡음이 커지면 이점이 줄어듦 → 후속 연구 BNTM에서 희소 사전분포와 AWSGHMC로 해결

논문 DOI

2025
제1저자

자율주행 도메인에서 LoRA 기반 sLLM 파인튜닝 연구

한국자료분석학회지 27(3) 769–780 게재 PyTorch · Transformers · PEFT(LoRA) · Phi-4-mini · RAG

> **자율주행 판단을 설명하는 LoRA FT-Driver(Phi-4-mini 3.8B, 파라미터 0.01% 학습)를 제안해 RAG 대비 ROUGE-1 0.0888 → 0.1495(68.4%↑), 교통법규 위반 분류 Accuracy RAG 최고 0.540 → 0.745**

목표 자율주행 차량이 내린 판단을 사람이 이해할 수 있게 설명하는 실시간 응답 시스템

문제 RAG는 도메인 간 일반화는 좋지만 특정 도메인 안에서 정확성 · 응답 일관성이 떨어지고, 차량 내 임베디드 자원에서는 전체 파라미터 파인튜닝이 부담

내 역할 모델 선정, LoRA 학습 설계, RAG 비교 실험, 논문 작성

해결 BDD-X(주행 설명 주석 26,228개)로 LoRA 파인튜닝, RAG와 같은 조건에서 정량 비교

결과 ROUGE-1 0.0888 → 0.1495(68.4%↑), 응답 시간 1.145초(RAG k=1 1.099초). 교통법규 위반 유형 분류(약 7만 건, 재학습 없이 프롬프트 예시 방식)로 넓힌 실험에서 Accuracy 0.745 · Macro F1 0.731(RAG 최고 0.540 · 0.532)

다시 한다면 학습 데이터의 양과 범위가 제한적이었으므로 주석 자동화와 멀티모달 데이터셋 구성부터 진행

논문 DOI

프로젝트 직무 관련 · 성과 순

2025
개인

3D 객체 탐지 최적화를 위한 SGMCMC 기법 적용

수업 프로젝트(A+) PyTorch · CUDA · OpenPCDet · KITTI · PointPillars · SGLD · SGHMC · SGNHT · Adam

> **KITTI 3D 객체 탐지에서 SGMCMC 3종을 직접 구현해 Adam · SGD와 같은 조건으로 비교, BEV AP Adam 65.15% > SGHMC 49.59% > SGD 49.07%로 기존 Adam의 우위를 확인 · 과목 A+**

문제 점추정 최적화기는 파라미터 불확실성을 다루지 못함 → GCIoU 손실을 에너지 함수로 두고 SGLD · SGHMC · SGNHT 업데이트식을 유도 · 구현

해결 KITTI + OpenPCDet + CT-Stack 백본 + PointPillars, 80 epoch · batch 8 · OneCycle LR을 고정하고 최적화기만 교체 → 성능 차이를 최적화기 차이로 해석

발견 이론상 가장 안정적인 혼합을 기대한 SGNHT가 최하위. 속도와 thermostat 두 곳에 잡음이 더해져 온도 1e-3 이상에서 기울기 폭발, 1e-4 이하에서 업데이트 소실. 이 설정에서는 적응적 학습률을 쓰는 Adam이 가장 현실적이라고 결론

결과 BEV AP(Moderate) Adam 65.15% > SGHMC 49.59% > SGD 49.07% > SGLD 25.67% ≈ SGNHT 25.37%. SGHMC는 학습 손실 0.813으로 최저였지만 성능은 2위, Adam은 손실 1.149로 4위인데 성능 1위

한계 온도 6단계(1e-5 ~ 1) 탐색으로 유효 범위(1e-5 부근)를 찾았지만 이 구간에서도 검출 성능은 만족스럽지 못함

다시 한다면 Adam의 적응적 갱신과 SGHMC의 불확실성 추정을 결합하고 층별 온도 조절을 시험

저장소

2025
개인

강화학습 기반 피카츄 배구 Agent 학습

석사 수업 프로젝트(인공지능이해와응용, A+) Python · gymnasium · Q-learning

> **RGB 관측을 좌표 격자 상태로 바꾸고 보상을 다시 설계해 10,000 에피소드 동안 평균 보상 −2.27 → 5.68(+7.95), 규칙 기반 AI를 이기는 구간 반복 · 과목 A+**

목표 하드코딩된 상대를 이기도록 Q-learning으로 학습시키며, 하이퍼파라미터 · 보상 설정에 따라 학습이 어떻게 달라지는지 확인

해결 432×304×3 관측을 20px 격자 4-tuple 상태로 이산화, 이산 행동 18개. 보상을 직접 설계해 승 +15 / 패 −10, 이동 거리당 +0.01, step마다 +0.1, 공 충돌 +1.0, 공과의 거리 역수 +0.1/dist로 확정, ε는 1.0에서 0.1까지 감소

한계 평균 보상은 8,000 에피소드 전까지 오르다 감소. 보상 편차가 크고 같은 경로로 지는 패턴 반복, 공이 네트에 걸릴 때 반발력이 정확히 작동하지 않음

저장소

2025.09 – 12
개인

국제 메타데이터 표준 통합 LLM 기반 그래프 증강 추천시스템

수업 프로젝트(A+) · KIAT 표준전문인력양성 과제 성과 Python · LLM(LLMRec) · LightGCN · ISO 3166-1 · BCP 47 · 대응표본 t-검정

> **LLM이 만든 메타데이터를 국제 표준으로 정규화해 표준 적합률 48.4% → 91.4%(43.0%p↑), 상호운용성 80.3%, 추천 성능 유의한 저하 없음 · 과목 A+**

문제 LLMRec으로 만든 Netflix 메타데이터(17,366건)에서 같은 국가가 USA · United States · America로 나뉘어 시스템 간 결합 불가

해결 ISO 3166-1 alpha-2 · BCP 47 정규화 레이어 설계, 필드별 형식 적합률 측정

결과 country 표면형 1,166개 → 57개(95%↓), language 326개 → 52개(84%↓), column-shift 724건 자동 검출. LightGCN 10 seed 반복 · 대응표본 t-검정에서 Recall · NDCG · Precision 6개 지표 모두 $p > 0.05$

다시 한다면 사후 정규화 대신 구조화 출력으로 생성 시점에 표준 강제. 약 20%는 생성 단계 문제라 사후 정규화로 해결되지 않음

저장소

2025.03 – 2025.09
대학원생 멘토 · 멘티 1명

파인튜닝과 CAG 결합 대화형 AI 성능 개선 연구 (기후정책)

에코업혁신융합대학사업단 학부생 연구원 프로그램 · 포스터 발표 QLoRA(4bit) · CAG(KV 캐시) · BLEU · ROUGE · BERTScore · CHRF · METEOR · TER

> **파인튜닝 모델에 문서를 KV 캐시로 미리 올리는 CAG를 붙여 BLEU-1 0.235 → 0.600(2.6배), TER 318.7 → 76.9(75.9%↓), 반복 생성 편차 79% 감소**

문제	파인튜닝 단독 모델은 근거 문서를 인용하지 못하고, 학습 범위 밖 질문에 사실과 다른 답을 냄
내 역할	대학원생 멘토로 연구 주제 구체화 · 방법론 선정 · 실험 설계 · 지표 검토를 멘티와 함께 수행
해결	QLoRA 4bit 파인튜닝 + CAG 구조를 제안
결과	기업 기후정책 문서 질문 5개 × 5회 생성, 8개 지표 모두 FT+CAG 우세(ROUGE-L 0.265 → 0.525, BERTScore 0.867 → 0.910). 표준편차 BLEU-1 0.160 → 0.033(79%↓) · TER 130.4 → 2.7(98%↓)로 같은 질문에 같은 답

연구과제 참여

2025 – 2026 **TNTM을 활용한 임베디드 시스템 문서의 주제 흐름 분석** · 연구책임자 · 한국연구재단 석사과정생연구장려금 · RS-2025-25437035 → 「전이 네트워크 토픽 모델을 이용한 임베디드 기술의 성장 예측」 제1저자 투고 예정

2024 – 2027 **베이지안 추론을 위한 적응적 가중 SGMCMC 알고리즘** · 참여연구원 · 한국연구재단 · RS-2024-00352792 · 2차년도 샘플러 구현 · 실험 설계 · 결과 분석 전담 → 제1저자 논문 4편(게재 2 · 투고 예정 2)

2025 – 2026 **초격차산업기반표준전문인력양성** · 참여연구원 · KIAT · RS-2025-02215617 · 표준 프로젝트 2건(메타데이터 표준 정규화, TBT 규제 분석)

수상

2026 **한국자료분석학회 하계학술발표대회 포스터논문 장려상** · Fixed-K Shrinkage Bayesian Transition Network Topic Model Inference with AWSGLD · 제1저자

2023 **고려대학교 빅데이터사이언스학부 통계학술제 최우수상** · 택시 수요 분석 · 팀 3명

2023 **미래모빌리티 및 세종지역혁신 아이디어 공모전 장려상** · Smart Green-STOP(압전 · 태양광 자가발전 스마트 정류소) · 3D 구현 담당 · 세종특별자치시

활동 · 리더십

2025.03 – 현재 **DLM연구실 대표** · 구성원 간 소통 · 세미나 일정 · 공지 공유, 공동 연구 자원 · 안전 사항 관리

2025.03 – 09 **학부생 연구원 프로그램 대학원생 멘토** · 에코업혁신융합대학사업단 · 멘티 1명과 연구 주제 구체화 · 방법론 선정 · 실험 설계를 함께 진행해 포스터 발표까지 완료

2023 · 2025 **Python · Excel 실습 멘토** · 디지털리터러시(Python, 2025.03 – 12) · 글로벌역량멘토링(Excel, 2023.03 – 06) 수업에서 실습 오류 해결 · 기초 개념 설명

2023.02 – 07 **예큐레이션(예산시장) 마케팅 서포터즈 5인 팀장** · 팀장 중심 업무 배분을 팀원별 자율 기획 · 실행 방식으로 바꿔 참여도 개선, 인스타그램 21건 · 유튜브 8건 제작, 팔로워 375명 · 대표 영상 조회 2,523회

2024.12 – 2025.01 **미국 UNLV 해외연수 · CES 2025 참관** · AI+IoT Communication 과정 수료, 다양한 국적의 학생들과 토론 · 발표

2021.09 – 2022.06 **뮤지컬 동아리 '캐스팅' 의상 · 분장팀장** · 팀원 3명과 배우 14명의 공연 준비 일정 조율

기술

언어 · 도구	Python(Pandas), R, SQL(MySQL · Google BigQuery), Git, CUDA, Excel
ML · DL	PyTorch, TensorFlow, scikit-learn, Transformers, PEFT(LoRA · QLoRA), OpenPCDet, LangChain, Chroma
통계 · 추론	SGLD · SGHMC · AWSGLD · AWSGHMC · MH-within-Gibbs 구현, 시계열(VAR · VECM), 베이지안 검정
자격	ADsP(데이터분석 준전문가, 2023.11) · OPIc IM1(2026.09)