경력기술서

# 김다연

dayun0405@gmail.com | 포트폴리오 kim-da-yeon.github.io | GitHub Kim-Da-yeon



## 핵심 요약

**Python을 기반으로 LLM 파인튜닝 · 검색/캐시 증강과 문장 단위 토픽 모델을 구현하고 비교해 온 빅데이터사이언스 석사과정 지원자입니다.**

**경험 1. 자율주행 sLLM LoRA 파인튜닝 | ROUGE-1 68.4% 향상 · 학술지 게재**

- 자율주행 판단 설명의 정확 · 일관된 응답을 목표로 LoRA FT-Driver(Phi-4-mini 3.8B, 파라미터 0.01% 학습)를 제안, RAG 대비 ROUGE-1 0.0888 → 0.1495 · 교통법규 분류 Accuracy 0.505 → 0.745
- 모델 선정 · 학습 · RAG 비교 실험 · 논문 작성(KCI 제1저자)

**경험 2. 파인튜닝 + 캐시 증강 생성(CAG) | BLEU-1 2.6배 · TER 75.9% 감소**

- QLoRA 파인튜닝 모델에 문서를 KV 캐시로 미리 올리는 CAG를 결합해 8개 지표 모두 개선, 반복 생성 편차 79% 감소
- 대학원생 멘토로 연구 주제 · 방법론 · 실험 설계를 멘티와 함께 수행

**경험 3. 임베디드 기술 성장 예측 | AUC 논문 0.876 · 특허 0.746**

- Google BigQuery에서 SQL로 미국 특허 21,028건을, OpenAlex에서 논문 초록 114,066건을 직접 추출해 3년 뒤 성장할 기술 토픽 예측
- 한국연구재단 과제 연구책임자로 데이터 수집 · GPU 샘플러 구현 · 미래 정보를 막는 rolling-origin 평가 설계

**경험 4. 토픽 모델 · MCMC 샘플러 설계 | perplexity 41.6% 감소 · 토픽 수 정확 복원**

- 실데이터(FAERS) 문서 완성 perplexity HTMM 54.99 → BNTM 32.13, 정답 20토픽 환경의 추정 토픽 수 SGHMC 15.4개 → AWSGHMC 20.0개(SCI급 투고 예정 · 포스터논문 장려상)
- 모델 설계 · 모의실험 데이터 생성기 · 샘플러 구현 · 논문 작성까지 제1저자로 수행

**경험 5. LLM 생성 메타데이터 국제 표준 정규화 | 형식 적합률 43.0%p 개선**

- LLM(LLMRec)이 생성한 Netflix 메타데이터 17,366건을 ISO 3166-1 · BCP 47로 정규화해 형식 적합률을 48.4%에서 91.4%로 개선하고 필드 밀림 오류 724건 자동 검출, 추천 성능 손실 없음을 검정으로 확인
- ISO · BCP 47 기반 정규화 규칙과 오류 검출 파이프라인 단독 구현 · 과목 A+

## 학력

| | |
|---|---|
| 2025.03 – 2027.02 (졸업예정) | **고려대학교 일반대학원 빅데이터사이언스학과 석사과정** |
| 2021.03 – 2025.02 | **고려대학교 세종캠퍼스 빅데이터사이언스학부 학사** · 융합전공 자율주행시스템학과 · 표준학 |

## 연구과제 참여

| | |
|---|---|
| 2025 – 2026 | **TNTM을 활용한 임베디드 시스템 문서의 주제 흐름 분석** · 연구책임자 · 한국연구재단 석사과정생연구장려금 · RS-2025-25437035 → 「전이 네트워크 토픽 모델을 이용한 임베디드 기술의 성장 예측」 제1저자 투고 예정 |
| 2024 – 2027 | **베이지안 추론을 위한 적응적 가중 SGMCMC 알고리즘** · 참여연구원 · 한국연구재단 · RS-2024-00352792 · 2차년도 샘플러 구현 · 실험 설계 · 결과 분석 전담 → 제1저자 논문 4편(게재 2 · 투고 예정 2) |
| 2025 – 2026 | **초격차산업기반표준전문인력양성** · 참여연구원 · KIAT · RS-2025-02215617 · 표준 프로젝트 2건(메타데이터 표준 정규화, TBT 규제 분석) |

## 수상

| | |
|---|---|
| 2026 | **한국자료분석학회 하계학술대회 포스터논문 장려상** · Fixed-K Shrinkage BNTM with AWSGLD Inference · 제1저자 |

2023 **고려대학교 빅데이터사이언스학부 통계학술제 최우수상** · 택시 수요 분석 · 팀 3명

2023 **미래모빌리티 및 세종지역혁신 아이디어 공모전 장려상** · Smart Green-STOP(압전 · 태양광 자가발전 스마트 정류소) · 3D 구현 담당 · 세종특별자치시

## 대표 연구 성과 순

2025
제1저자

### 자율주행 도메인에서 LoRA 기반 sLLM 파인튜닝 연구

**한국자료분석학회지 27(3) 769–780 게재** PyTorch · Transformers · PEFT(LoRA) · Phi-4-mini · RAG

> **자율주행 판단을 설명하는 정확 · 일관된 실시간 응답을 목표로 LoRA FT-Driver(Phi-4-mini 3.8B, 파라미터 0.01% 학습)를 제안해 RAG 대비 ROUGE-1 0.0888 → 0.1495(68.4%↑), 교통법규 위반 분류 Accuracy 0.505 → 0.745**

| | |
|---|---|
| 목표 | 자율주행 차량이 내린 판단을 사람이 이해할 수 있게 설명하는, 정확하고 일관된 실시간 응답 시스템 |
| 문제 | RAG는 도메인 간 일반화는 좋지만 특정 도메인 안에서 정확성 · 응답 일관성이 떨어지고, 차량 내 임베디드 자원에서는 전체 파라미터 파인튜닝이 부담 |
| 해결 | BDD-X 주행 설명 주석 26,228개로 LoRA 파인튜닝, RAG(k=1)와 같은 조건에서 정량 비교 |
| 결과 | ROUGE-1 0.0888 → 0.1495(68.4%↑), 응답 시간 1.145초(RAG k=1 1.099초). 교통법규 위반 유형 분류(약 7만 건)로 넓힌 실험에서 Accuracy 0.745 · Macro F1 0.731(RAG k=1 0.505 · 0.492) |

2025 – 2026
연구책임자 · 제1저자

### 전이 네트워크 토픽 모델을 이용한 임베디드 기술의 성장 예측

**한국연구재단 석사과정생연구장려금 과제 성과 · 투고 예정** Python · GPU 샘플러 · Google BigQuery(SQL) · OpenAlex · L2 로지스틱 회귀

> **논문 초록 114,066건 · 미국 특허 21,028건(BigQuery SQL로 직접 추출)으로 3년 뒤 성장할 기술 토픽을 예측해 AUC 논문 0.876 · 특허 0.746(무작위 0.5), 성장 이유를 토픽 전이로 설명**

| | |
|---|---|
| 목표 | 임베디드 분야에서 3년 뒤 크게 성장할 기술 토픽을 정확히 예측하고, 성장 이유를 문장 사이의 토픽 전이 구조로 설명 |
| 문제 | 기존 연구는 토픽 비중 · 키워드 · 인용 · 특허 지표를 썼고, 신경망 예측은 정확해도 성장 이유를 설명하기 어려움. 기존 TNTM은 전이행렬이 전 기간에 하나뿐 |
| 해결 | 연도별 전이행렬을 계층 사전분포로 묶어 TNTM 확장(K=40, AWSGLD). 전이 네트워크에서 유입 · 자기전이 · 유입 출처 · 구조 변화 변수 8개를 직접 정의하고 데이터 변수 14개와 함께 예측 모형 구성 |
| 결과 | 문서 완성 perplexity 논문 TNTM 1172 · HTMM 1223 · LDA 2149. 성장 기준을 상위 10% · 30%로 바꿔도 AUC 논문 0.896 · 0.881 유지. 유입 증가(+0.31) · 자기전이(−0.28)가 주요 계수 → 다른 토픽에서 문장이 넘어오는 토픽이 성장 |
| 한계→해결 | 시점을 섞은 교차검증은 미래 정보가 섞여 성능이 부풂 → 과거 자료로만 학습하는 rolling-origin 평가(논문 13개 · 특허 11개 결과연도). 토픽 모델까지 기준연도마다 다시 추정해 기준연도 이후 문헌을 빼도 AUC 논문 0.828 · 특허 0.691 |
| 데이터 | Google BigQuery 공개 특허 데이터셋에서 SQL로 미국 특허 21,028건(524,424문장)을, OpenAlex에서 임베디드 관련 12개 구문으로 논문 초록 114,066건을 직접 추출 · 정제 |
| 담당 | 데이터 수집 · 정제 · GPU 샘플러 구현 · 변수 정의 · 평가 설계 · 논문 작성 |

2025 – 2026
개인 연구 · 제1저자

### Fixed-K Shrinkage Bayesian Transition Network Topic Model with AWSGHMC Inference

**SCI급 학술지 투고 예정** Python · NumPy · SG-MCMC(AWSGHMC · SGHMC · SGLD) · MH-within-Gibbs · 베이지안 추론

> **문장 사이의 토픽 전이를 다루는 토픽 모델(BNTM)과 샘플러(AWSGHMC)를 제안해 실데이터(FAERS) 문서 완성 perplexity를 HTMM 54.99 → 32.13(41.6%↓)으로 낮추고, 정답 20토픽 환경의 추정 토픽 수를 SGHMC 15.4개 → AWSGHMC 20.0개로 정확 복원 · 포스터논문 장려상**

| | |
|---|---|
| 목표 | ① 문장 순서가 있는 텍스트를 LDA · HTMM보다 잘 설명하는 모델 ② 다봉 사후분포를 안정적으로 추정하는 샘플러. 샘플러를 고정하고 모델을, 모델을 고정하고 샘플러를 바꿔 각각 검증 |
| 문제 | LDA는 문장 순서를 무시하고 HTMM은 전이를 값 하나로 요약, TNTM은 토픽 수를 미리 정하고 확률 단체 제약으로 경사 기반 추론이 어려움. 선행 연구(AWSGLD-TNTM)에서도 seed에 따라 토픽 구조가 크게 달라져 원인을 모델 구조로 판단 |
| 해결 | Logistic-Normal 모수화(Simplex 제약 제거) + Sparse Dirichlet Prior(활성 토픽 수를 데이터가 결정) + AWSGHMC(다봉 사후분포의 로컬 트랩 탈출)로 모델과 샘플러를 다시 설계 |
| 검증 설계 | 토픽 모델은 정답 라벨이 없어 결과 검증이 어려움 → 정답 토픽 · 전이 · 비중을 정해 둔 모의실험 데이터 생성기를 직접 설계. 환경마다 어려움 하나만 키운 5종(기본 · 초과 용량 K 40 · 다수 토픽 20 · 소표본 200건 · 대규모 10,000건) |
| 모델 비교 | 5개 환경 모두 BNTM의 문서 완성 perplexity가 모든 관찰 길이에서 HTMM보다 낮고 LDA보다 크게 낮음(40 토픽 환경 HTMM 대비 약 20포인트) |
| 샘플러 비교 | AWSGHMC만 5개 환경 모두 K 정확 복원. 다수 토픽 환경(정답 20)에서 SGHMC 15.4 · SGLD 14.7 · MH 23.4, 토픽-단어 Hellinger 거리 0.09~0.17로 최소 |
| 실데이터 | 문서 완성 perplexity FAERS 이상반응 보고서 14,316건 BNTM 32.13 · HTMM 54.99 · LDA 78.23, NTSB 항공사고 서술문 17,733건 472.1 · 498.5 · 1,090.7. 같은 모델에서 샘플러 비교 시 AWSGHMC가 두 데이터 모두 perplexity · 최저 에너지 1위 |
| 한계→해결 | 모의실험 기준으로 맞춘 샘플러 설정이 실데이터의 큰 에너지 범위에서 작동하지 않음(한 구간에 갇힘) → 구간 폭을 데이터 에너지 범위에 비례하도록 바꿔 정상화 |

2025 – 2026
제1저자

### AWSGLD를 이용한 전이 네트워크 토픽 모델 추론

**한국자료분석학회지 28(1) 109–121 게재** Python · AWSGLD · TNTM

> **TNTM 추론을 MH-Gibbs + AWSGLD로 바꿔 잡음 텍스트에서도 안정적 · 해석 가능한 토픽 전이 구조를 추정: IMDB 리뷰 1,000문장 실험에서 토픽 다양성 SGD 0.48 → AWSGLD 0.96(2배), 문장마다 무작위 단어 50개를 넣은 조건의 perplexity는 SGLD보다 약 10배 낮음**

| | |
|---|---|
| 목표 | TNTM의 추론을 확률적 기울기 기반 표본추출로 대체해, 다양한 텍스트 환경에서 안정적이고 해석 가능한 토픽 전이 구조를 추정 |
| 해결 | 문장 토픽은 MH-Gibbs, 전이행렬 · 단어-토픽 분포는 AWSGLD로 추론. TNTM 원 논문에 없는 추론 수식을 유도해 구현하고, 문장마다 무작위 단어 0 · 50 · 100개를 넣어 SGD · SGLD와 비교 |
| 한계→해결 | 토픽 수 K를 미리 정해야 하고 잡음이 커지면 이점이 줄어듦 → 후속 연구 BNTM에서 희소 사전분포와 AWSGHMC로 해결 |

## 실무 경험

2023.12 – 2024.04
팀 2명

### JERESFARM · 데이터 분석 인턴

**스마트팜** Python · statsmodels(ARIMA · VAR · VECM) · scikit-learn · LGBM

> **분석 인력이 없던 농장에서 생육 데이터(개체 18개 · 20일)로는 영향요인을 규명할 수 없음을 검정으로 확인하고, 후속 센서 · 카메라 배치와 측정 항목을 현업과 협의해 제안 → 인턴 종료 후 공공 데이터 작물 분류 모델(Test F1 0.81)로 이어 농장에 전달**

| | |
|---|---|
| 문제 | 센서 변수 29개에 비해 생육 크기는 개체 18개 · 20일 · 하루 1회 줄자 측정. 사내 데이터 분석 인력 없음 |
| 분석 | 로그 차분 후 ADF 정상성 확인. VAR에서 유의수준 0.05의 유의 변수 없음 → 공적분 확인 후 VECM 재검정. Linear · Ridge · Lasso 테스트 $R^2$ 0.36 · 0.51 · 0.99, Lasso 변수 17개 |
| 한계→해결 | 테스트 데이터가 10%뿐이라 $R^2$ 0.99는 과적합으로 판단, 원인을 종속변수 관측 부족으로 규명 → 다음 작물(딸기) 농장 사전 조사 · 센서 · 카메라 배치와 측정 항목 협의, 인턴 종료 후 공공 데이터로 작물 분류 과제를 새로 정의 (아래 프로젝트) |
| 배운 점 | 모델보다 측정 설계가 먼저. 최고 점수보다 일반화 격차로 모델 선택 |

2024.05 – 2024.06
개인

### 환경조건 기반 작물 분류 모델 (JERESFARM 인턴 후속)

**인턴 종료 후 개인 프로젝트 · 결과 · 코드 농장 전달** Python · Pandas · scikit-learn · LightGBM · Feature Importance · PDP

> **농촌진흥청 공공 데이터 827,080건으로 작물 분류 모델 6개 중 F1 격차가 가장 작은 LightGBM(Test 0.81, 격차 0.03 vs Bagging 0.17 · RF 0.21)을 고르고, 온도 25°C · $CO_2$ 400ppm 임계 구간을 도출해 결과와 코드를 JERESFARM에 전달**

| | |
|---|---|
| 문제 | 인턴 때 생육 영향요인을 규명하지 못한 문제를 공공 데이터로 다시 정의 → 환경으로 작물을 예측하면 작물별 최적 환경과 토지에 맞는 작물을 함께 찾을 수 있음 |
| 해결 | 공통 환경변수 5개 선정 · 결측과 클래스 구성 정리, Decision Tree · SVM · K-NN · Bagging · Random Forest · LightGBM 비교 |
| 결과 | Train → Test F1 LightGBM 0.84 → 0.81 · Bagging 0.98 → 0.82 · RF 1.00 → 0.79. 영향력 온도 > 일사량 > $CO_2$ |

## 프로젝트 직무 관련 · 성과 순

2025.03 – 2025.09
대학원생 멘토 · 멘티 1명

### 파인튜닝과 CAG 결합 대화형 AI 성능 개선 연구 (기후정책)

**에코업혁신융합대학사업단 학부생 연구원 프로그램 · 포스터 발표** QLoRA(4bit) · CAG(KV 캐시) · BLEU · ROUGE · BERTScore · CHRF · METEOR · TER

> **파인튜닝 모델에 문서를 KV 캐시로 미리 올리는 CAG를 붙여 BLEU-1 0.235 → 0.600(2.6배), TER 318.7 → 76.9(75.9%↓), 반복 생성 편차 79% 감소**

| | |
|---|---|
| 문제 | 파인튜닝 단독 모델은 근거 문서를 인용하지 못하고, 학습 범위 밖 질문에 사실과 다른 답을 냄 |
| 해결 | QLoRA 4bit 파인튜닝 + CAG 구조를 제안. 연구 주제 구체화 · 방법론 선정 · 실험 설계 · 지표 검토를 멘티와 함께 수행 |
| 결과 | 기업 기후정책 문서 질문 5개 × 5회 생성, 8개 지표 모두 FT+CAG 우세(ROUGE-L 0.265 → 0.525, BERTScore 0.867 → 0.910). 표준편차 BLEU-1 0.160 → 0.033(79%↓) · TER 130.4 → 2.7(98%↓)로 같은 질문에 같은 답 |

2025.09 – 12
개인

### 국제 메타데이터 표준 통합 LLM 기반 그래프 증강 추천시스템

**수업 프로젝트(A+) · KIAT 표준전문인력양성 과제 성과** Python · LLM(LLMRec) · LightGCN · ISO 3166-1 · BCP 47 · 대응표본 t-검정

> **LLM이 만든 메타데이터를 국제 표준으로 정규화해 표준 적합률 48.4% → 91.4%(43.0%p↑), 상호운용성 0% → 80.3%, 추천 성능 손실 없음 · 과목 A+**

**동기** LLM이 생성한 데이터는 같은 의미를 매번 다른 표현으로 쓰고 국제 표준 코드를 따르지 않을 것이라 예상하여 시작하였습니다.

**문제** LLMRec으로 만든 Netflix 메타데이터(17,366건)에서 같은 국가가 USA · United States · America로 나뉘어 시스템 간 결합 불가

**해결** ISO 3166-1 alpha-2 · BCP 47 정규화 레이어와 필드별 형식 적합률 지표 설계

**결과** country 표면형 1,166개 → 57개(95%↓), language 326개 → 52개(84%↓), column-shift 724건 자동 검출. LightGCN 10 seed 반복 · 대응표본 t-검정에서 recall@k · ndcg@k 7개 지표 모두 p > 0.05

2024 – 2025
팀 2명 · 파이프라인 전 구간

### sLLM + Advanced RAG 기반 SONY 제품 설명서 챗봇

LangChain · Chroma · bge-m3 · Re-rank · KoAlpaca-7B · Tavily · Streamlit

> **제품 7종 설명서를 한 창구에서 검색하고 답변마다 파일명 · 페이지 번호를 반환하는 RAG 챗봇 구현, 반환 페이지를 원문과 대조해 출처 확인**

**문제** 좋은 카메라를 샀지만 설명서가 길어 기능을 쓰지 못하는 문제에서 시작. 설명서는 제품별 PDF로 흩어져 있고 sLLM은 사실과 다른 답을 낼 수 있음

**해결** 페이지 단위 청킹(500/50) · bge-m3 · Chroma, 제품명 필터(cos ≥ 0.7) 후 Re-rank로 긴 컨텍스트 중간 근거 누락 대응, 검색 실패 시 Tavily 웹 검색

**한계→해결** 7B 모델 답변이 매끄럽지 않음 → 원인을 모델 크기 · 프롬프트 · 청크 경계 · 중복 출처로 분석. 도메인 적응은 후속 LoRA 파인튜닝 연구, 파인튜닝 모델의 출처 부재는 FT+CAG 연구로 이어서 다룸

2025
개인

### AWSGLD-TNTM 기반 미국 자율주행 · 자동차 TBT 규제 분석

**KIAT 표준전문인력양성 과제 성과** Python · AWSGLD-TNTM · LDA

> **미국 Federal Register 규제 원문에 AWSGLD-TNTM을 적용해 LDA 대비 Topic Coherence 0.42 → 0.5743(약 37%↑), 규제 흐름을 3단계로 정리**

**문제** 통보문 요약만으로는 규제 방향을 판단할 수 없고, LDA는 잡음 토픽이 상위에 나옴

**결과** K=8, Topic Diversity 0.82. 팬데믹 유예기(2020–21) → 환경 · 화학 규제 강화(2022–23) → 연비 · 디지털 안전 확산기(2024–25, TBT 통보 212건 · 203건)

2024.09 – 12
개인 · 기획부터 검증까지

### 자전거 대여 시스템 데이터베이스 설계

**수업 프로젝트** MySQL · SQL · E-R 모델링 · PHP

> **요구사항 7개 항목을 4개 릴레이션으로 설계하고 삽입 · 갱신 · 삭제 연산으로 3NF를 검증, PHP 웹 화면과 연동**

**결과** 회원 삭제 시 대여 기록이 함께 지워지도록 ON DELETE CASCADE 적용. 웹 화면에서의 삽입 · 갱신 · 삭제가 DB에 반영되는 것을 확인

**한계→해결** 데이터는 직접 만든 소량 샘플 → 성능 대신 삽입 · 갱신 · 삭제 연산으로 정규화 조건을 확인하는 데 집중

**배운 점** 중복과 갱신 이상은 쿼리에서 보정하지 않고 스키마 설계 단계에서 제거

## 활동 · 리더십

2025.03 – 현재 **DLM연구실 대표** · 구성원 간 소통 · 세미나 일정 · 공지 공유, 공동 연구 자원 · 안전 사항 관리

2025.03 – 09 **학부생 연구원 프로그램 대학원생 멘토** · 에코업혁신융합대학사업단 · 멘티 1명과 연구 주제 구체화 · 방법론 선정 · 실험 설계를 함께 진행해 포스터 발표까지 완료

2023 · 2025 **Python · Excel 실습 멘토** · 디지털리터러시(Python, 2025.03 – 12) · 글로벌역량멘토링(Excel, 2023.03 – 06) 수업에서 실습 오류 해결 · 기초 개념 설명

2023.02 – 12 **예큐레이션(예산시장) 마케팅 서포터즈 5인 팀장** · 팀장 중심 업무 배분을 팀원별 자율 기획 · 실행 방식으로 바꿔 참여도 개선, 인스타그램 21건 · 유튜브 8건 제작, 팔로워 375명 · 대표 영상 조회 2,523회

| | |
|---|---|
| 2024.12 – 2025.01 | **미국 UNLV 해외연수 · CES 2025 참관** · 현지 학생과 임베디드 AI · 머신러닝 PBL 공동 과제 수행 |
| 2021.09 – 2022.06 | **뮤지컬 동아리 '캐스팅' 의상 · 분장팀장** · 팀원 3명과 배우 14명의 공연 준비 일정 조율 |

## 기술

| | |
|---|---|
| 언어 · 도구 | Python(Pandas), R, SQL(MySQL · Google BigQuery), Git, CUDA, Excel |
| ML · DL | PyTorch, TensorFlow, scikit-learn, Transformers, PEFT(LoRA · QLoRA), OpenPCDet, LangChain, Chroma |
| 통계 · 추론 | SGLD · SGHMC · AWSGLD · AWSGHMC · MH-within-Gibbs 구현, 시계열(ARIMA · VAR · VECM), 베이지안 검정 |
| 자격 | ADsP(데이터분석 준전문가, 2023.11) · OPIc IM1(2026.09) |