



dayun0405@korea.ac.kr | 포트폴리오 kim-da-yeon.github.io | GitHub Kim-Da-yeon

Summary

KCI 등재지 한국자료분석학회지(JKDAS) 제1저자 논문 2편 게재, SCI급 학술지 1편 2026.09. 투고 예정

NRF 석사과정생연구장려금 연구책임자(PI) 선정, BNTM 확장 연구를 제1저자로 진행 중

정형·비정형 데이터 전반에 회귀·머신러닝·베이지안·딥러닝·LLM·토픽 모델링 적용

자율주행·모빌리티·스마트팜 등 실제 도메인 프로젝트로 문제 정의부터 결과 해석까지 수행

기술 능력

프로그래밍·도구: Python, R, SQL, Git, GPU Computing (CUDA)

ML/DL: PyTorch, TensorFlow, scikit-learn, Transformers (LoRA/QLoRA)

데이터 처리·시각화: Pandas, Matplotlib, Seaborn, ggplot2, QGIS

자격증·어학: ADsP (데이터분석 준전문가)

학력

2025.03. – 현재 고려대학교 일반대학원 · 빅데이터사이언스학과 석사과정

졸업예정: 2027.02. · 석사 학위논문: BNTM with AWSGHMC (SCI 투고)

2021.03. – 2025.02. 고려대학교 세종캠퍼스 · 빅데이터사이언스학부 학사

융합전공: 자율주행시스템학과

실무 경험

2023.12. – 2024.03. JERESFARM · 데이터 사이언티스트 인턴

스마트팜 도메인 · 팀 2명 · 활용 기술: Python, scikit-learn, statsmodels, LGBM

▶ 담당: 데이터 분석 팀 소속으로 최적 환경 도출 및 데이터 구축을 위한 센서 환경 세팅 방안 마련

- ▶ 시계열 분석: ARIMA·VAR·VECM 여러 시계열 기법으로 최적 성장 환경 도출 시도. 결측 구간 보간 후 유의성 검정으로 독립변수 유의성 제약 조건을 정량 검증. Lasso 회귀로 유의 변수 15개 후보 추출, Y 관측 부족의 구조적 한계를 결론에 명시
- ▶ 상황: 작물 생육 데이터가 하루 1회 줄자로 직접 측정(18개 개체, 20일 관측)에 그쳐 종속변수 관측 부족
→ 공공 데이터 확장 현장 데이터 한계 근거로 농촌진흥청 공공 데이터 재접근
→ 6개 모델(DT, SVM, K-NN, Bagging, RF, LGBM) 비교하여 6종 작물 다중 분류. LGBM 최종 선정
Test F1 0.81이지만 Train-Test 격차가 세 앙상블 중 가장 작아 과적합 위험 최소
- ▶ 결과: 도출 Feature Importance로 온도>일사량>CO2 순 영향력 규명, Partial Dependence Plot으로 온도 25°C·CO2 400ppm 등 변수별 임계 구간 도출
- ▶ 후속 활동: 다음 작물 딸기의 정확한 측정을 위해 회사 사람들과 함께 딸기 농장 사전 조사, 카메라 센서 구성 방식 협의. 데이터 한계의 원인을 측정 설계 단계로 규명

연구 참여

2025. – 2026.	TNTM을 활용한 임베디드 시스템 문서의 주제 흐름 분석 연구책임자 (석사과정생연구장려금) · RS-2025-25437035 ▶ 성과: 관련 논문 1편 투고 예정 (TNTM을 임베디드 시스템 문서 도메인에 적용한 주제 흐름 분석 연구)
2024. – 2027.	베이지안 추론을 위한 적응적 가중 SGMCMC 알고리즘 참여연구원 (한국연구재단) · RS-2024-00352792 ▶ 성과: KCI 논문 2편 게재 — AWSGLD를 이용한 전이 네트워크 토픽 모델 추론 (JKDAS 28), 자율주행 도메인에서 LoRA 기반 sLLM 파인튜닝 연구 (JKDAS 27) ▶ SCI 논문 1편 투고 예정 — Fixed-K Shrinkage BNTM with AWSGHMC Inference (석사 학위논문, 영문) ▶ 학회 발표 1건 — 한국자료분석학회 하계학술대회 포스터 (2026, 장려상 수상)
2025. – 2026.	초격차산업기반표준전문인력양성 참여연구원 (KIAT, 표준학 융합전공) · RS-2025-02215617 ▶ 성과: 프로젝트 2건 — 국제 메타데이터 표준 통합 LLM 기반 그래프 증강 추천시스템, AWSGLD-TNTM 활용 미국 자율주행·자동차 TBT 규제 트렌드 분석

연구실 활동

2025. – 현재	인지심리 도메인 방법론 사전 학습·실습 지도교수 연구실 예정 프로젝트 준비 활용: Few-shot/Zero-shot Learning, sLLM, Contextualized Sentence Embedding ▶ 배경 지도교수 연구실에서 인지심리 도메인 프로젝트 예정. 사업 선정·본격 착수 이전부터 관련 방법론을 자율
------------	---

학습·실습으로 사전 준비

- ▶ 학습 내용: ① 소량 데이터 학습 기법(Few-shot/Zero-shot) 실습 ② sLLM 기반 챗봇 실습 ③ Contextualized Sentence Embedding(CSE) 실습 — 문맥 기반 의미 유사도 분석
- ▶ 상태: 학습·실습 단계, 사업 선정 이후 본 프로젝트 착수 예정

논문

2025. – 2026.

Fixed-K Shrinkage BNTM with AWSGHMC Inference (2026.09. SCI 투고 예정)

Kim, D. & Cheon, S. (제1저자) · 석사 학위논문 · 활용: Python, PyTorch, NumPy, SciPy

- ▶ 문제 정의: 선행 연구(JKDAS 28(1), AWSGLD)에서 남은 두 근본 한계 — 토픽 수 K 사전 고정, 노이즈 환경에서 이점 상쇄 — 를 문제 정의로 삼아 확장
- ▶ 판단(WHY): Logistic-Normal 모수화 + Sparse Dirichlet Prior + AWSGHMC 하이브리드 추론을 선택한 이유: (1) Simplex 제약이 경사 기반 추론의 근본 걸림돌, Logistic-Normal 변환으로 무제약 공간에서 처리 가능 (2) K 사전 고정 문제를 데이터가 결정하게 하려면 희소 사전분포가 이론적으로 가장 안전 (3) 이산 잠재변수·연속 모수를 각각 다른 방식으로 처리해야 로컬 트랩 극복
- ▶ 결과: 모의실험($K_{\text{true}}=30$)에서 30개 진짜 토픽 정확 복원 (Sentence Accuracy 1.00, 파라미터 복원 오차 0.09). 다른 샘플러(MH 28.9·SGHMC 19.6·SGLD 14.7)는 로컬 트랩에 갇혀 14~19개만 복원. FAERS·NTSB·모의실험 세 도메인 모두에서 AWSGHMC 최저 에너지 도달

2026.

AWSGLD를 이용한 전이 네트워크 토픽 모델 추론

Kim, D. & Cheon, S. (제1저자) · JKDAS 28(1), 109–121 · 활용: Python, PyTorch

- ▶ 문제: TNTM은 문장 수를 모델링하지만 Simplex 제약으로 경사 기반 추론이 어려워 → 고차원 다중 모드 사후분포에서 로컬 트랩 발생
- ▶ 방법: TNTM에 AWSGLD 적용 — 사후분포를 구간별 적응 가중해 다중 모드 사후 평탄화, 로컬 트랩 탈출 및 대규모 데이터 확장성 확보
- ▶ 결과: 원본 데이터에서 SGD 대비 토픽 다양성 2배($0.48 \rightarrow 0.96$), 노이즈 50개 조건 SGLD 대비 Perplexity 약 10배 우수 — Coherence·Diversity·Perplexity 종합 비교로 검증

2025.

자율주행 도메인에서 LoRA 기반 sLLM 파인튜닝 연구

Kim, D., Cheon, S. & Joo, A. (제1저자)

JKDAS 27(3), 769–780 · 활용: Python, PyTorch, LoRA

- ▶ 문제: 도메인 특화 sLLM의 응답 품질 개선 필요, 전체 파라미터 파인튜닝은 임베디드 환경 자원 부담 큼
- ▶ 판단(WHY): Phi-4-mini(3.8B) 선정 이유는 임베디드 환경 자원 제약 대응, LoRA 선정 이유는 자원 효율과 도메인 파인튜닝의 균형. 검증 방식으로 RAG와 정량 비교를 선택한 것은 파인튜닝 vs 검색 증강의 트레이드오프가 핵심 의사결정 지점이기 때문
- ▶ 결과: BDD-X 자율주행 데이터셋(주행 영상 6,970개·주석 26,228개)으로 LoRA 파인튜닝, 전체 파라미터의 약 0.01%만 조정. 동일 조건 RAG($k=1$) 대비 ROUGE-1 $0.0888 \rightarrow 0.1495$ 향상, 응답 시간 평균 1.145초. Traffic

수상

2026.	한국자료분석학회 하계학술대회 포스터논문 부문 장려상 Fixed-K Shrinkage BNTM with AWSGLD Inference (제1저자) 발표 시점 AWSGLD 버전, 이후 AWSGHMC로 확장 · 활용: Python, PyTorch, NumPy ▶ 내용: TNTM의 토픽 수 고정·Simplex 제약 한계 극복 → Logistic-Normal 모수화로 활성 토픽 수 자동 결정, AWSGLD로 다중 모드 사후분포 로컬 트랩 완화 ▶ 성과: 시뮬레이션·실제 코퍼스에서 다양한 조건(파라미터 중첩·희소 토픽) 대비 우수성 정량 입증
2023.	통계학술제 최우수상 — 택시 수요 분석을 통한 택시 서비스 개선 방안 마련 고려대학교 빅데이터사이언스학부 · 팀 3명 · 담당: QGIS 시각화·분석 코드 구현 · 활용: Python, R, QGIS ▶ 문제: 택시 요금 인상 후 기사·이용자 동반 이탈로 이용률 하락, 자치구별 수요·공급 불균형 해소 데이터 기반 배차 전략 부재 ▶ 방법: 서울시 6종 공공 데이터 병합, 계층적 군집분석(Ward.D) + 3변수 증감 조합, QGIS로 자치구별 공간 분포 시각화 담당, 공차율 웹 인터페이스 제작 ▶ 핵심 결과: 25개 자치구를 8개 조합 중 6개 군집으로 배정 (B·G 공집합) — 강남·서초(전 지표 상승), 중구(관광·업무 특성), 저조 지역(광진·중랑·도봉 등)별 차별화된 배차·서비스 전략 제안
2023.	미래모빌리티 및 세종지역혁신 아이디어 공모전 장려상 Smart Green-STOP (친환경 스마트 정류소) · 팀 2명 (3D 구현 담당) · 주관: 세종특별자치시 ▶ 담당: 3D 구현 담당. 팀원과 서로 아이디어를 제시하고 실현 가능성을 함께 검토하는 방식으로 진행 ▶ 아이디어 제안: 정류소 운영 비용 마련 방안으로 압전 에너지 하베스팅(승객 발자국 에너지 수집) + 태양광 발전 결합 방식 제안 ▶ 결과: IoT 센서·압전 하베스팅·태양광 결합 친환경 스마트 정류소 모델 완성 — 도시 모빌리티 데이터 수집 인프라 문제 해결을 위한 저전력·자가발전 데이터 수집 노드 컨셉 설계

연구 프로젝트

2025. · 개인	SGMCMC 기반 3D 객체 탐지 모델 최적화 수업 프로젝트 · 활용: PyTorch, OpenPCDet, KITTI, CUDA ▶ 문제: 기존 Adam 기반 3D 객체 탐지는 점추정만 가능하여 파라미터 불확실성 추정·다중 모드 탐색 한계 → 베이지안 샘플링 기반 대안 탐색 ▶ 방법: KITTI + OpenPCDet + CT-Stack 백본 + PointPillars 아키텍처 + GClou 손실 환경 고정. Adam을 기준 모델로 두고 SGMCMC 계열을 동일 조건으로 적용(80 epoch, batch 8, OneCycle LR)해 비교 ▶ 결과: Adam 65.15% vs SGHMC 49.59% (BEV AP Moderate) — 이 과제에서는 적응적 학습률·확률적
------------	--

탐색보다 결정적임을 확인. SGMCMC 계열 내에서는 모멘텀 기반 SGHMC가 무작위 보행 방식인 SGLD와 노이즈가 큰 SGNHT 대비 뚜렷한 우위

- ▶ 시사점: 최저 손실(SGHMC 0.813)과 최고 성능(Adam)이 불일치 → 손실 최소화와 과업 성능 보장이 다름을 확인, Adam+SGHMC 하이브리드를 향후 과제로 제시

2025. · 개인

AWSGLD-TNTM을 활용한 미국 자율주행·자동차 TBT 규제 트렌드 분석

활용: Python, PyTorch, NumPy

- ▶ 문제: 미국 Federal Register 다년간 규제 문서의 LDA 한계 극복 → AWSGLD-TNTM 적용으로 K=8 토픽 도출, 연도별 토픽 강도 및 네트워크 구축
- ▶ 결과: LDA 대비 Topic Coherence 약 37% 향상(0.42 → 0.5743), Topic Diversity 0.82로 토픽 중복도 감소. 팬데믹 영향 유예기(2020~21) → 환경·화학 규제 강화(2022~23) → 연비·디지털 안전 확산기(2024~25, TBT 통보 각 212건·203건)의 3단계 규제 패러다임 정량 규명
- ▶ 시사점: 국내 자율주행·자동차 산업의 TBT 대응 전략 수립을 위한 데이터 근거 제공

2025. · 팀 4명

대학 기숙사 운영 유형 분류 (대학알리미 공시 데이터)

2025 대학알리미 데이터 아이디어 공모전 참가작 (교육부·한국대학교육협의회, 미수상)

활용: Python, 공공데이터, 이항 로지스틱 회귀

- ▶ 문제: 대학 기숙사 수용률이 5년간 23.2~23.8%에 정체(2024년 대학 23.4%, 전문대학 18.0%)되어 있으나, 대학별 운영 방식의 차이를 설명할 분류 기준이 부재
- ▶ 담당: 데이터 수집·전처리, 지표 정의 및 4분면 분류 기준 설정, 카드뉴스 기획·디자인, 발표 담당 (팀 4명).
 $\text{수용률} = \text{수용가능인원} / \text{재학생} \times 100$, $\text{이익률} = (\text{수익총계} - \text{비용총계}) / \text{수익총계} \times 100$ 으로 정의
- ▶ 방법: 수용률 30%·이익률 20%를 기준으로 공공복지형·균형형·수익중심형·형식적 운영형 4개 유형 분류. 공립은 전부 형식적 운영형, 국립·국립대법인은 대부분 공공복지형, 특별법국립은 균형형 비중이 높음을 지역·설립구분별로 확인
- ▶ 분석: 이항 로지스틱 회귀에서 인건비·운영비가 높을수록 수익형 확률이 낮고, 재학생 수·경쟁률이 높을수록 수익형 확률이 높게 나타남
- ▶ 결과: 경쟁률 문제(시설 확충·입사 기준 개선·수익 재투자)와 비용 문제(예산 투명화·학생 참여 운영·인력 효율 분석)로 나눠 6개 개선안 제시

2025. · 개인

국제 메타데이터 표준 통합 LLM 기반 그래프 증강 추천시스템

수업 프로젝트 · 활용: Python, LLM (GPT/LLaMA/Gemma), LightGCN

- ▶ 문제: LLM은 통제 어휘가 아닌 자유 텍스트 생성. 같은 국가가 USA·United States·America로 분산되어 시스템 간 결합 불가
- ▶ 방법: 국제 표준(ISO 3166-1 alpha-2, BCP 47) 정규화 레이어 설계. 필드별 형식 적합률 지표 정의. Netflix 17,366건 대상 정규화 후 LightGCN 추천 성능 유지 여부를 seed 10회 반복으로 검증
- ▶ 결과: 표준 적합률 0.484 → 0.914로 향상. country 표면형 1,166개 → 표준 코드 57개, language 326 →

52개. 상호운용성 0 → 80.3%. column-shift 724건 자동 검출. LightGCN 추천 성능 유지 확인(7개 지표 전부 $p > 0.05$) — 정규화 이후 하위 태스크 성능 손실 없음을 입증하여 데이터 품질·상호운용성 개선을 핵심 기여로 확정

2024. · 팀 2명

sLLM + Advanced RAG를 활용한 SONY 브랜드 AI 설명서 챗봇

활용: Python, LangChain, Chroma, Streamlit, KoAlpaca-llama-7b, bge-m3, PyMuPDF, Tavily

- ▶ 문제: 제품별 설명서 PDF가 분리되어 사용자가 해당 문서·페이지를 직접 탐색해야 함. sLLM은 할루시네이션 한계
- ▶ 방법: PyMuPDF 페이지 단위 로드, 청크 500/overlap 50, bge-m3 임베딩 + Chroma 영속화. 유사도 top-5 후 제품명 필터($\cos \geq 0.7$). KoAlpaca-llama-7b 생성, 페이지 번호 반환. 검색 실패 시 Tavily 웹 검색 fallback. Streamlit 웹 인터페이스
- ▶ 결과: SONY 7개 제품(카메라·헤드폰·스피커) 매뉴얼 기반 챗봇 구현. 답변마다 근거 청크의 파일명·페이지 번호 반환으로 출처 추적
- ▶ 개선 방향: 정량 평가·한국어 특화 임베딩 도입·필터 임계 튜닝을 고도화 방향으로 도출

2023. · 팀 2명

GAN 기반 손글씨 폰트 생성 및 로봇팔 제어

다가치 로봇 소모임 (역할 분담 없이 공동 진행)

활용: Python, TensorFlow, GAN(zi2zi, pix2pix), RoboDK, WLKATA Mirobot

- ▶ 문제: WLKATA Mirobot 내장 Drawing 기능은 도형·간단한 글씨만 가능 → 임의의 한글 손글씨를 학습·생성해 로봇팔이 쓰게 하는 통합 파이프라인 시도
- ▶ 방법: 25종 폰트 × 한글 글자 75,000장 이미지(128×256 px)로 zi2zi 기반 GAN(pix2pix + AC-GAN + DTN Constant Loss) 사전학습, 직접 작성한 210자 손글씨로 Transfer Learning
- ▶ 결과: 손글씨 스타일 이미지 생성 성공
- ▶ 개선 방향: WLKATA Studio API와 RoboDK 코드 간 호환 문제를 OpenCV 기반 이미지→경로 변환 방식으로 해결하는 방향 도출

2025. · 개인

SAMC 알고리즘 R 패키지화 (3종 백엔드)

활용: R, Rcpp/C, reticulate/Python, devtools

- ▶ 담당: R 패키지 빌드 구조 구성 담당
- ▶ 방법: 확률적 근사 몬테카를로(SAMC) 알고리즘을 순수 R · Rcpp를 통한 C 연결, reticulate를 통한 Python 연결 세 형태로 각각 패키지화
- ▶ 결과: devtools::install로 설치·호출 가능한 R 패키지 3종 완성. 동일 알고리즘의 세 구현 방식별 차이 정리

2024. · 팀 2명

베이지안 강수예보 정확도 분석 (베이지안 갱신·검정)

학부 PBL · 활용: Python, 베이지안 통계 · 기상청 강수 확률·강수 유무 데이터 18만 건

- ▶ 문제: 기상청 예보 정확도는 90%에 가까우나 실제 강수 유무 적중률은 40~60%대에 머무름 → 확률 기반의 예보 신뢰도 평가 접근 필요

- ▶ 담당: 사전확률 설계, 사후확률 갱신, 베이지안 검정, 결론 담당 (팀원 2명, 데이터 수집·전처리 공동)
- ▶ 방법: 세종시 2023년 1년치 데이터(18만 건)로 예보 시간·강수 확률별 결합분포 구성. 삼각분포 등 사전지식 기반 사전확률 설계, 베이지안 갱신으로 사후확률 도출, 베이지안 팩터(BF)로 강수 여부 검정
- ▶ 결과: 강수확률 60% 이하는 사후확률 0에 수렴, 60-69%는 50, 70-79%는 88(Forecast 커질수록 감소), 90-100%는 95로 뚜렷. BF 검정으로 Forecast 10-40 구간의 임계 강수 확률 60% 도출 — 기상청 예보 신뢰도 정량 평가의 기반 데이터 제공

2025. · 개인

강화학습 기반 피카츄 배구 Agent 학습

활용: Python, gymnasium, 표 기반 Q-learning, Epsilon-Greedy

- ▶ 문제: 규칙 기반 하드코딩된 상대 AI를 상대로 스스로 배구 전략(공 위치 추적·점프·파워히트)을 학습하는 강화학습 agent 설계
- ▶ 방법: gymnasium PykachuVolleyball 환경. 관측이 432×304×3 RGB로 표 기반 학습 직접 사용 불가 → 공·플레이어 좌표를 20px 격자로 이산화한 4-tuple 상태 정의. 총 18개 이산 행동(좌우·상하·파워히트 조합), Epsilon-Greedy 1.0→0.1. 승 +15/패 -10 희소 보상에 캘리·이동·타격·근접 항 더해 밀집 보상 재설계
- ▶ 결과: 초기 4000+ 에피소드에서는 전략 미형성, 5000+ 에피소드부터 점프·이동·파워히트 정교화 확인
- ▶ 개선 방향: 상태 정의에 공 속도 추가로 Markov 성질 확보

2023. · 개인

자전거 대여 시스템 데이터베이스 설계

수업 프로젝트 · 활용: MySQL, SQL

- ▶ 문제: 자전거 대여 서비스 요구사항 기반 데이터 무결성·조회 효율 확보 필요
- ▶ 방법: E-R 다이어그램 기반 논리·물리 모델 설계, 정규화 적용, 복합 SQL 쿼리(JOIN, 서브쿼리, 집계함수) 구현
- ▶ 결과: 일반 운영 시나리오(대여·반납·회원 관리) 처리 검증, 정규화를 통한 중복·이상 방지

대외활동 및 리더십

2025.01.

미국 UNLV 4주 글로벌 연수 + CES 2025 현장 참관

AI+IoT Communication 트랙 수료 · 다국적 참가자 협업 · 자율주행·로보틱스·온디바이스 AI 산업 동향 조사

학부·석사 기간

AI·데이터 학회 및 산업 컨퍼런스 지속 참여

학문·산업 양면 최신 동향 파악 · 발표자로 학술 커뮤니티 참여

- ▶ 학술: 한국자료분석학회(KDAS) 하계학술대회 포스터 발표(장려상, 2026) 및 청강자 지속 참여, 한국통계학회 등 국내 통계 학회 청강
- ▶ 산업: LG AI 관련 컨퍼런스, SK AI Summit, GenCon, AI 포럼 등 국내 주요 대기업·기관 AI 컨퍼런스 다수 참여 — LLM·자율주행·데이터 플랫폼 세션 참관

2025. – 2026.

연구실 대표

2022. – 2025.

학습 멘토 (Python / 미적분학 / Excel)

프로그래밍·수학 개념 실습 중심 전달 · 개별 상담을 통한 학습 지속성 지원

2022. – 2023. · 팀

마케팅 서포터즈 4건

- ▶ 예큐레이션 (백종원의 예산시장) 5인 팀 리더 — Instagram·YouTube 콘텐츠 29건 제작, 총 조회수 3,671회
 - ▶ KU_KEY (세종캠퍼스 현장실습지원센터) 1·2기 — 홍보 콘텐츠 카테고리 설계, 기업 소개 카드·시즌 콘텐츠 제작
 - ▶ 사야컴퍼니 맥스달튼 전시 · 프랑코 폰타나 전시 — 티켓 증정 이벤트 기획·운영, 카드뉴스·포토존 등 홍보 콘텐츠 제작
-