

경력기술서 · 김다연 (Dayeon Kim)

dayun0405@korea.ac.kr | Portfolio: kim-da-yeon.github.io | GitHub: github.com/Kim-Da-yeon

Summary

- KCI 등재지 한국자료분석학회지(JKDAS) 제1저자 논문 2편 게재, SCI급 학술지 1편 2026.09. 투고 예정
- NRF 석사과정생연구장려금 연구책임자(PI) 선정, BNTM 확장 연구를 제1저자로 진행 중
- 정형·비정형 데이터 전반에 회귀·머신러닝·베이지안·딥러닝·LLM·토픽 모델링 적용
- 자율주행·모빌리티·스마트팜 등 실제 도메인 프로젝트로 문제 정의부터 결과 해석까지 수행

기술 능력

프로그래밍·도구: Python, R, SQL, Git, GPU Computing (CUDA)

ML/DL: PyTorch, TensorFlow, scikit-learn, Transformers (LoRA/QLoRA)

데이터 처리·시각화: Pandas, Matplotlib, Seaborn, ggplot2, QGIS

자격증·어학: ADsP (데이터분석 준전문가)

학력

고려대학교 일반대학원 · 빅데이터사이언스학과 석사과정

2025.03. – 현재

졸업예정: 2027.02. · 석사 학위논문: BNTM with AWSGHMC (SCI 투고)

고려대학교 세종캠퍼스 · 빅데이터사이언스학부 학사

2021.03. – 2025.02.

융합전공: 자율주행시스템학과

실무 경험

JERESFARM · 데이터 사이언티스트 인턴

2023.12. – 2024.03.

스마트팜 도메인 · 팀 2명 · 활용 기술: Python, scikit-learn, statsmodels, LGBM

- ▶ **상황** 작물 생육 데이터가 하루 1회 사람이 줄자로 직접 측정(18개 개체, 20일 관측)에 그쳐 종속변수 관측 절대 부족. 회사에 데이터 분석팀 부재로 외부 자문 병행 및 자체 조사로 분석 수행
- ▶ **담당** 데이터 분석 팀 소속으로 최적 환경 도출 및 데이터 구축을 위한 센서 환경 세팅 방안 결정 담당 (팀원 2명 공동 진행)
- ▶ **시계열 분석** ARIMA·VAR·VECM 여러 시계열 기법으로 최적 생장 환경 도출 시도. 결측 구간 보간 후 유의성 검정으로 독립변수 유의성 제약 조건을 정량 검증. Lasso 회귀로 유의 변수 15개 후보 추출, Y 관측 부족의 구조적 한계를 결론에 명시
- ▶ **공공 데이터 확장** 현장 데이터 한계 근거로 농촌진흥청 공공 데이터 재접근 → 6개 모델(DT, SVM, K-NN, Bagging, RF, LGBM) 비교하여 6종 작물 다중 분류. LGBM 최종 선정 — Test F1 0.81이지만 Train-Test 격차가 세 앙상블 중 가장 작아 과적합 위험 최소화
- ▶ **결과 도출** Feature Importance로 온도>일사량>CO2 순 영향력 규명, Partial Dependence Plot으로 온도 25°C·CO2 400ppm 등 변수별 임계 구간 도출
- ▶ **후속 활동** 다음 작물 딸기의 정확한 측정을 위해 회사 사람들과 함께 딸기 농장 사전 조사, 카메라 센서 구성 방식 협의. 데이터 한계의 원인을 측정 설계 단계로 규명

연구 참여

TNTM을 활용한 임베디드 시스템 문서의 주제 흐름 분석

2025. – 2026.

연구책임자 (석사과정생연구장려금) · RS-2025-25437035

- ▶ **성과** 관련 논문 1편 투고 예정 (TNTM을 임베디드 시스템 문서 도메인에 적용한 주제 흐름 분석 연구)

베이지안 추론을 위한 적응적 가중 SGMCMC 알고리즘

2024. – 2027.

참여연구원 (한국연구재단) · RS-2024-00352792

- ▶ **성과** KCI 논문 2편 게재 — AWSGLD를 이용한 전이 네트워크 토픽 모델 추론 (JKDAS 28), 자율주행 도메인에서 LoRA 기반 sLLM 파인튜닝 연구 (JKDAS 27)
- ▶ SCI 논문 1편 투고 예정 — Fixed-K Shrinkage BNTM with AWSGHMC Inference (석사 학위논문, 영문)

- ▶ 학회 발표 1건 — 한국자료분석학회 하계학술대회 포스터 (2026, 장려상 수상)

초격차산업기반표준전문인력양성

2025. – 2026.

참여연구원 (KIAT, 표준학 융합전공) · RS-2025-02215617

- ▶ **성과** 프로젝트 2건 — 국제 메타데이터 표준 통합 LLM 기반 그래프 증강 추천시스템, AWSGLD-TNTM 활용 미국 자율주행·자동차 TBT 규제 트렌드 분석

연구실 활동

인지심리 도메인 방법론 사전 학습·실습

2025. – 현재

지도교수 연구실 예정 프로젝트 준비 · 활용: Few-shot/Zero-shot Learning, sLLM, Contextualized Sentence Embedding

- ▶ **배경** 지도교수 연구실에서 인지심리 도메인 프로젝트 예정. 사업 선정·본격 착수 이전부터 관련 방법론을 자율 학습·실습으로 사전 준비
- ▶ **학습 내용** ① 소량 데이터 학습 기법(Few-shot/Zero-shot) 실습 ② sLLM 기반 챗봇 실습 ③ Contextualized Sentence Embedding(CSE) 실습 — 문맥 기반 의미 유사도 분석
- ▶ **상태** 학습·실습 단계, 사업 선정 이후 본 프로젝트 착수 예정

논문

Fixed-K Shrinkage BNTM with AWSGHMC Inference (2026.09. SCI 투고 예정)

2025. –

2026.

Kim, D. & Cheon, S. (제1저자) · 석사 학위논문 · 활용: Python, PyTorch, NumPy, SciPy

- ▶ **문제 정의** 선행 연구(JKDAS 28(1), AWSGLD)에서 남은 두 근본 한계 — 토픽 수 K 사전 고정, 노이즈 환경에서 이점 상쇄 — 를 문제 정의로 삼아 확장
- ▶ **판단(WHY)** Logistic-Normal 모수화 + Sparse Dirichlet Prior + AWSGHMC 하이브리드 추론을 선택한 이유:
(1) Simplex 제약이 경사 기반 추론의 근본 걸림돌, Logistic-Normal 변환으로 무제약 공간에서 처리 가능 (2) K 사전 고정 문제를 데이터가 결정하게 하려면 희소 사전분포가 이론적으로 가장 안전 (3) 이산 잠재변수·연속 모

수를 각각 다른 방식으로 처리해야 로컬 트랩 극복

- ▶ **결과** 모의실험($K_{\text{true}}=30$)에서 30개 진짜 토픽 정확 복원 (Sentence Accuracy 1.00, 파라미터 복원 오차 0.09). 다른 샘플러(MH 28.9·SGHMC 19.6·SGLD 14.7)는 로컬 트랩에 갇혀 14~19개만 복원.
FAERS·NTSB·모의실험 세 도메인 모두에서 AWSGHMC 최저 에너지 도달

AWSGLD를 이용한 전이 네트워크 토픽 모델 추론

2026.

Kim, D. & Cheon, S. (제1저자) · JKDAS 28(1), 109–121 · 활용: Python, PyTorch

- ▶ **문제** TNTM은 문장 수를 모델링하지만 Simplex 제약으로 경사 기반 추론이 어려워 → 고차원 다중 모드 사후분포에서 로컬 트랩 발생
- ▶ **방법** TNTM에 AWSGLD 적용 — 사후분포를 구간별 적응 가중해 다중 모드 사후 평탄화, 로컬 트랩 탈출 및 대규모 데이터 확장성 확보
- ▶ **결과** 원본 데이터에서 SGD 대비 토픽 다양성 2배($0.48 \rightarrow 0.96$), 노이즈 50개 조건 SGLD 대비 Perplexity 약 10배 우수 — Coherence·Diversity·Perplexity 종합 비교로 검증

자율주행 도메인에서 LoRA 기반 sLLM 파인튜닝 연구

2025.

Kim, D., Cheon, S. & Joo, A. (제1저자) · JKDAS 27(3), 769–780 · 활용: Python, PyTorch, LoRA

- ▶ **문제** 도메인 특화 sLLM의 응답 품질 개선 필요, 전체 파라미터 파인튜닝은 임베디드 환경 자원 부담 큼
- ▶ **판단(WHY)** Phi-4-mini(3.8B) 선정 이유는 임베디드 환경 자원 제약 대응, LoRA 선정 이유는 자원 효율과 도메인 파인튜닝의 균형. 검증 방식으로 RAG와 정량 비교를 선택한 것은 파인튜닝 vs 검색 증강의 트레이드오프가 핵심 의사결정 지점이기 때문
- ▶ **결과** BDD-X 자율주행 데이터셋(주행 영상 6,970개·주석 26,228개)으로 LoRA 파인튜닝, 전체 파라미터의 약 0.01%만 조정. 동일 조건 RAG($k=1$) 대비 ROUGE-1 0.0888 → 0.1495 향상, 응답 시간 평균 1.145초. Traffic violations 7만 건 확장 실험 Accuracy 0.745·Macro F1 0.731

한국자료분석학회 하계학술대회 포스터논문 부문 장려상

2026.

Fixed-K Shrinkage BNTM with AWSGLD Inference (제1저자) · 발표 시점 AWSGLD 버전, 이후 AWSGHMC로 확장 · 활용: Python, PyTorch, NumPy

- ▶ **내용** TNTM의 토픽 수 고정·Simplex 제약 한계 극복 → Logistic-Normal 모수화로 활성 토픽 수 자동 결정, AWSGLD로 다중 모드 사후분포 로컬 트랩 완화
- ▶ **성과** 시뮬레이션·실제 코퍼스에서 다양한 조건(파라미터 중첩·희소 토픽) 대비 우수성 정량 입증

통계학술제 최우수상 — 택시 수요 분석을 통한 택시 서비스 개선 방안 마련

2023.

고려대학교 빅데이터사이언스학부 · 팀 3명 · 담당: QGIS 시각화·분석 코드 구현 · 활용: Python, R, QGIS

- ▶ **문제** 택시 요금 인상 후 기사·이용자 동반 이탈로 이용률 하락, 자치구별 수요·공급 불균형 해소 데이터 기반 배차 전략 부재
- ▶ **방법** 서울시 6종 공공 데이터 병합, 계층적 군집분석(Ward.D) + 3변수 증감 조합, QGIS로 자치구별 공간 분포 시각화 담당, 공차율 웹 인터페이스 제작
- ▶ **핵심 결과** 25개 자치구를 8개 조합 중 6개 군집으로 배정 (B·G 공집합) — 강남·서초(전 지표 상승), 중구(관광·업무 특성), 저조 지역(광진·중랑·도봉 등)별 차별화된 배차·서비스 전략 제안

미래모빌리티 및 세종지역혁신 아이디어 공모전 장려상

2023.

Smart Green-STOP (친환경 스마트 정류소) · 팀 2명 (3D 구현 담당) · 주관: 세종특별자치시

- ▶ **담당** 3D 구현 담당. 팀원과 서로 아이디어를 제시하고 실현 가능성을 함께 검토하는 방식으로 진행
- ▶ **아이디어 제안** 정류소 운영 비용 마련 방안으로 압전 에너지 하베스팅(승객 발자국 에너지 수집) + 태양광 발전 결합 방식 제안
- ▶ **결과** IoT 센서·압전 하베스팅·태양광 결합 친환경 스마트 정류소 모델 완성 — 도시 모빌리티 데이터 수집 인프라 문제 해결을 위한 저전력·자가발전 데이터 수집 노드 컨셉 설계

SGMCMC 기반 3D 객체 탐지 모델 최적화

2025. · 개인

수업 프로젝트 · 활용: PyTorch, OpenPCDet, KITTI, CUDA

- ▶ **문제** 기존 Adam 기반 3D 객체 탐지는 점추정만 가능하여 파라미터 불확실성 추정·다중 모드 탐색 한계 → 베이 지안 샘플링 기반 대안 탐색
- ▶ **방법** KITTI + OpenPCDet + CT-Stack 백본 + PointPillars 아키텍처 + GIoU 손실 환경 고정. Adam을 기준 모델로 두고 SGMCMC 계열을 동일 조건으로 적용(80 epoch, batch 8, OneCycle LR)해 비교
- ▶ **결과** Adam 65.15% vs SGHMC 49.59% (BEV AP Moderate) — 이 과제에서는 적응적 학습률·확률적 탐색보다 결정적임을 확인. SGMCMC 계열 내에서는 모멘텀 기반 SGHMC가 무작위 보행 방식(SGLD 25.67%) 대비 뚜렷한 우위
- ▶ **시사점** 최저 손실(SGHMC 0.813)과 최고 성능(Adam)이 불일치 → 손실 최소화과 과업 성능 보장이 다를 수 있음, Adam+SGHMC 하이브리드를 향후 과제로 제시

AWSGLD-TNTM을 활용한 미국 자율주행·자동차 TBT 규제 트렌드 분석

2025. · 개인

활용: Python, PyTorch, NumPy

- ▶ **문제** 미국 Federal Register 다년간 규제 문서의 LDA 한계 극복 → AWSGLD-TNTM 적용으로 K=8 토픽 도출, 연도별 토픽 강도 및 네트워크 구축
- ▶ **결과** LDA 대비 Topic Coherence 약 37% 향상(0.42 → 0.5743), Topic Diversity 0.82로 토픽 중복도 감소. 팬데믹 영향 유예기(2020~21) → 환경·화학 규제 강화(2022~23) → 연비·디지털 안전 확산기(2024~25, TBT 통보 각 212건·203건)의 3단계 규제 패러다임 정량 규명
- ▶ **시사점** 국내 자율주행·자동차 산업의 TBT 대응 전략 수립을 위한 데이터 근거 제공

국제 메타데이터 표준 통합 LLM 기반 그래프 증강 추천시스템

2025. · 개인

수업 프로젝트 · 활용: Python, LLM (GPT/LLaMA/Gemma), LightGCN

- ▶ **문제** LLM은 통제 어휘가 아닌 자유 텍스트 생성. 같은 국가가 USA·United States·America로 분산되어 시스

템 간 결합 불가

- ▶ **방법** 국제 표준(ISO 3166-1 alpha-2, BCP 47) 정규화 레이어 설계. 필드별 형식 적합률 지표 정의. Netflix 17,366건 대상 정규화 후 LightGCN 추천 성능 유지 여부를 seed 10회 반복으로 검증
- ▶ **결과** 표준 적합률 0.484 → 0.914로 향상. country 표면형 1,166개 → 표준 코드 57개, language 326 → 52개. 상호운용성 0 → 80.3%. column-shift 724건 자동 검출. LightGCN 추천 성능 유지 확인(7개 지표 전부 $p > 0.05$) — 정규화 이후 하위 태스크 성능 손실 없음을 입증하여 데이터 품질·상호운용성 개선을 핵심 기여로 확정

sLLM + Advanced RAG를 활용한 SONY 브랜드 AI 설명서 챗봇

2024. – 2025. · 개인

활용: Python, LangChain, Chroma, Streamlit, KoAlpaca-llama-7b, bge-m3, PyMuPDF, Tavily

- ▶ **문제** 제품별 설명서 PDF가 분리되어 사용자가 해당 문서·페이지를 직접 탐색해야 함. sLLM은 할루시네이션 한계
- ▶ **방법** PyMuPDF 페이지 단위 로드, 청크 500/overlap 50, bge-m3 임베딩 + Chroma 영속화. 유사도 top-5 후 제품명 필터($\cos \geq 0.7$). KoAlpaca-llama-7b 생성, 페이지 번호 반환. 검색 실패 시 Tavily 웹 검색 fallback. Streamlit 웹 인터페이스
- ▶ **결과** SONY 7개 제품(카메라·헤드폰·스피커) 매뉴얼 기반 챗봇 구현. 답변마다 근거 청크의 파일명·페이지 번호 반환으로 출처 추적
- ▶ **개선 방향** 정량 평가·한국어 특화 임베딩 도입·필터 임계 튜닝을 고도화 방향으로 도출

GAN 기반 손글씨 폰트 생성 및 로봇팔 제어

2023. · 팀 2명

다가치 로봇 소모임 (역할 분담 없이 공동 진행) · 활용: Python, TensorFlow, GAN(zi2zi, pix2pix), RoboDK, WLKATA Mirobot

- ▶ **문제** WLKATA Mirobot 내장 Drawing 기능은 도형·간단한 글씨만 가능 → 임의의 한글 손글씨를 학습·생성해 로봇팔이 쓰게 하는 통합 파이프라인 시도
- ▶ **방법** 25종 폰트 × 한글 글자 75,000장 이미지(128×256 px)로 zi2zi 기반 GAN(pix2pix + AC-GAN + DTN Constant Loss) 사전학습, 직접 작성한 210자 손글씨로 Transfer Learning

▶ **결과** 손글씨 스타일 이미지 생성 성공

▶ **개선 방향** WLKATA Studio API와 RoboDK 코드 간 호환 문제를 OpenCV 기반 이미지→경로 변환 방식으로 해결하는 방향 도출

SAMC 알고리즘 R 패키지화 (3종 백엔드)

2025. · 개인

활용: R, Rcpp/C, reticulate/Python, devtools

▶ **담당** R 패키지 빌드 구조 구성 담당

▶ **방법** 확률적 근사 몬테카를로(SAMC) 알고리즘을 순수 R · Rcpp를 통한 C 연결 · reticulate를 통한 Python 연결 세 형태로 각각 패키지화

▶ **결과** devtools::install로 설치·호출 가능한 R 패키지 3종 완성. 동일 알고리즘의 세 구현 방식별 차이 정리

베이지안 강수예보 정확도 분석 (베이지안 갱신·검정)

2024. · 팀 2명

학부 PBL · 활용: Python, 베이지안 통계 · 기상청 강수 확률·강수 유무 데이터 18만 건

▶ **문제** 기상청 예보 정확도는 90%에 가까우나 실제 강수 유무 적중률은 40~60%대에 머무름 → 확률 기반의 예보 신뢰도 평가 접근 필요

▶ **담당** 사전확률 설계, 사후확률 갱신, 베이지안 검정, 결론 담당 (팀원 2명, 데이터 수집·전처리 공동)

▶ **방법** 세종시 2023년 1년치 데이터(18만 건)로 예보 시간·강수 확률별 결합분포 구성. 삼각분포 등 사전지식 기반 사전확률 설계, 베이지안 갱신으로 사후확률 도출, 베이지안 팩터(BF)로 강수 여부 검정

▶ **결과** 강수확률 60% 이하는 사후확률 0에 수렴, 60-69%는 50, 70-79%는 88(Forecast 커질수록 감소), 90-100%는 95로 뚜렷. BF 검정으로 Forecast 10-40 구간의 임계 강수 확률 60% 도출 — 기상청 예보 신뢰도 정량 평가의 기반 데이터 제공

강화학습 기반 피카츄 배구 Agent 학습

2025. · 개인

활용: Python, gymnasium, 표 기반 Q-learning, Epsilon-Greedy

- ▶ **문제** 규칙 기반 하드코딩된 상대 AI를 상대로 스스로 배구 전략(공 위치 추적·점프·파워히트)을 학습하는 강화학습 agent 설계
- ▶ **방법** gymnasium PykachuVolleyball 환경. 관측이 $432 \times 304 \times 3$ RGB로 표 기반 학습 직접 사용 불가 → 공·플레이어 좌표를 20px 격자로 이산화한 4-tuple 상태 정의. 총 18개 이산 행동(좌우·상하·파워히트 조합), Epsilon-Greedy 1.0→0.1. 승 +15/패 -10 희소 보상에 랠리·이동·타격·근접 항 더해 밀집 보상 재설계
- ▶ **결과** 초기 4000+ 에피소드에서는 전략 미형성, 5000+ 에피소드부터 점프·이동·파워히트 정교화 확인
- ▶ **개선 방향** 상태 정의에 공 속도 추가로 Markov 성질 확보

자전거 대여 시스템 데이터베이스 설계

2023. · 개인

수업 프로젝트 · 활용: MySQL, SQL

- ▶ **문제** 자전거 대여 서비스 요구사항 기반 데이터 무결성·조회 효율 확보 필요
- ▶ **방법** E-R 다이어그램 기반 논리·물리 모델 설계, 정규화 적용, 복합 SQL 쿼리(JOIN, 서브쿼리, 집계함수) 구현
- ▶ **결과** 일반 운영 시나리오(대여·반납·회원 관리) 처리 검증, 정규화를 통한 중복·이상 방지

잡은 배달 음식 섭취가 건강에 미치는 영향 분석

2023. · 개인

데이터마이닝 수업 · 활용: Python, 로지스틱 회귀, 군집분석

- ▶ **요약** 국민 건강 데이터 활용, 배달 음식 섭취 빈도와 건강 지표(BMI·혈압·콜레스테롤 등)의 관계를 다변량 회귀·군집분석으로 분석

대외활동 및 리더십

미국 UNLV 4주 글로벌 연수 + CES 2025 현장 참관

2025.01.

AI+IoT Communication 트랙 수료 · 다국적 참가자 협업 · 자율주행·로보틱스·온디바이스 AI 산업 동향 조사

AI·데이터 학회 및 산업 컨퍼런스 지속 참여

학부·석사 기간

학문·산업 양면 최신 동향 파악 · 발표자로 학술 커뮤니티 참여

- ▶ **학술** 한국자료분석학회(KDAS) 하계학술대회 포스터 발표(장려상, 2026) 및 청강자 지속 참여, 한국통계학회 등 국내 통계 학회 청강
- ▶ **산업** LG AI 관련 컨퍼런스, SK AI Summit, GenCon, AI 포럼 등 국내 주요 대기업·기관 AI 컨퍼런스 다수 참여
— LLM·자율주행·데이터 플랫폼 세션 참관

연구실 대표

2025. – 2026.

연구실 안전관리·장비 운영 및 세미나 일정 조율

학습 멘토 (Python / 미적분학 / Excel)

2022. – 2025.

프로그래밍·수학 개념 실습 중심 전달 · 개별 상담을 통한 학습 지속성 지원

예규레이션(백종원의 예산시장) · KU_KEY(현장실습지원센터) 서포터즈

2023.

예규레이션 5인 팀 리더 (Instagram·YouTube 조회수 3,671회) · KU_KEY 1·2기 콘텐츠 카테고리 설계