경력기술서

김다연

dayun0405@gmail.com | 포트폴리오 kim-da-yeon.github.io | GitHub Kim-Da-yeon



핵심 요약

Python, R, SQL을 기반으로 토픽 모델 · 샘플러 설계, LLM 파인튜닝, 통계 · 머신러닝 분석을 수행해 온 빅데이터사이언스 석사과정 지원자입니다.

경험 1. 토픽 모델 · MCMC 샘플러 설계 | 모의실험 5종 토픽 수 정확 복원

- 토픽 수를 데이터로 정하는 토픽 모델과 AWSGHMC 샘플러를 설계해, 실데이터 2종(FAERS · NTSB)에서 HTMM · LDA보다 낮은 perplexity 달성(SCI급 투고 예정)
- 모델 설계 · 모의실험 데이터 생성기 · 샘플러 구현 · 논문 작성까지 제1저자로 수행

경험 2. 임베디드 기술 성장 예측 | AUC 논문 0.876 · 특허 0.746

- Google BigQuery에서 SQL로 미국 특허 21,028건을, OpenAlex에서 논문 초록 114,066건을 직접 추출해 3년 뒤 성장할 기술 토픽 예측
- 한국연구재단 과제 연구책임자로 데이터 수집 · GPU 샘플러 구현 · 미래 정보를 막는 rolling-origin 평가 설계

경험 3. 자율주행 sLLM LoRA 파인튜닝 | ROUGE-1 68.4% 향상 · 학술지 게재

- Phi-4-mini(3.8B)를 파라미터 0.01%만 학습하는 LoRA로 BDD-X 주행 설명 26,228개에 맞춰 같은 조건 RAG 대비 ROUGE-1 0.0888 → 0.1495
- 모델 선정 · 학습 · RAG 비교 실험 · 논문 작성(KCI 제1저자)

경험 4. LLM 생성 데이터 정합성 검증 | 형식 적합률 43.0%p 개선

- Netflix 메타데이터 17,366건의 형식 적합률을 48.4%에서 91.4%로 개선하고 필드 밀림 오류 724건 자동 검출, 추천 성능 손실 없음을 검정으로 확인
- ISO · BCP 47 기반 정규화 규칙과 오류 검출 파이프라인 단독 구현 · 과목 A+

경험 5. 스마트팜 데이터 분석 인턴 | 분석 한계 검증 및 후속 수집 방향 제안

- 생육 · 환경 데이터의 결측과 관측 구조를 검토해 기존 데이터만으로는 신뢰할 만한 영향요인을 규명하기 어렵다는 한계 확인
- 공공 데이터로 대체 분석(Test F1 0.81)하고, 현장 조사 · 현업 협의로 후속 센서 · 카메라 배치와 측정 항목 검토

학력

2025.03 – 2027.02 (졸업예정)	**고려대학교 일반대학원 빅데이터사이언스학과 석사과정**
2021.03 – 2025.02	**고려대학교 세종캠퍼스 빅데이터사이언스학부 학사** · 융합전공 자율주행시스템학과 · 표준학

연구과제 참여

2025 – 2026	**TNTM을 활용한 임베디드 시스템 문서의 주제 흐름 분석** · 연구책임자 · 한국연구재단 석사과정생연구장려금 · RS-2025-25437035 → 「전이 네트워크 토픽 모델을 이용한 임베디드 기술의 성장 예측」 제1저자 투고 예정
2024 – 2027	**베이지안 추론을 위한 적응적 가중 SGMCMC 알고리즘** · 참여연구원 · 한국연구재단 · RS-2024-00352792 · 2차년도 샘플러 구현 · 실험 설계 · 결과 분석 전담 → 제1저자 논문 4편(게재 2 · 투고 예정 2)
2025 – 2026	**초격차산업기반표준전문인력양성** · 참여연구원 · KIAT · RS-2025-02215617 · 표준 프로젝트 2건(메타데이터 표준 정규화, TBT 규제 분석)

수상

2026 **한국자료분석학회 하계학술대회 포스터논문 장려상** · Fixed-K Shrinkage BNTM with AWSGLD Inference · 제1저자

2023 **고려대학교 빅데이터사이언스학부 통계학술제 최우수상** · 택시 수요 분석 · 팀 3명

2023 **미래모빌리티 및 세종지역혁신 아이디어 공모전 장려상** · Smart Green-STOP(압전 · 태양광 자가발전 스마트 정류소) · 3D 구현 담당 · 세종특별자치시

대표 연구 성과 순

2025 – 2026
개인 연구 · 제1저자

Fixed-K Shrinkage BNTM with AWSGHMC Inference

SCI급 학술지 투고 예정 Python · NumPy · SG-MCMC(AWSGHMC · SGHMC · SGLD) · MH-within-Gibbs · 베이지안 추론

> **토픽 수를 데이터로 정하는 토픽 모델과 샘플러를 설계해, 직접 설계한 모의실험 데이터 5종 모두에서 토픽 수를 정확히 복원(10 seed)하고 실데이터 2종에서 perplexity 최저 달성**

문제	선행 연구(AWSGLD-TNTM)는 토픽 수 K를 미리 정해야 하고, seed와 설정에 따라 토픽 구조가 크게 달라짐. 학습률 · 하이퍼파라미터 · prior 조정으로 해결되지 않아 원인을 모델 구조로 판단
해결	Logistic-Normal 모수화(Simplex 제약 제거) + Sparse Dirichlet Prior(활성 토픽 수를 데이터가 결정) + AWSGHMC(다봉 사후분포의 로컬 트랩 탈출)로 모델과 샘플러를 다시 설계
검증 설계	토픽 모델은 정답 라벨이 없어 결과 검증이 어려움 → 정답 토픽 · 전이 · 비중을 정해 둔 모의실험 데이터 생성기를 직접 설계. 환경마다 어려움 하나만 키운 5종(기본 · 초과 용량 K 40 · 다수 토픽 20 · 소표본 200건 · 대규모 10,000건)
결과	AWSGHMC만 5개 환경 모두 K 정확 복원. 다수 토픽 환경(정답 20)에서 SGHMC 15.4 · SGLD 14.7 · MH 23.4, 토픽-단어 Hellinger 거리 0.09~0.17로 최소
실데이터	문서 완성 perplexity FAERS 이상반응 보고서 14,316건 BNTM 32.13 · HTMM 54.99 · LDA 78.23, NTSB 항공사고 서술문 17,733건 472.1 · 498.5 · 1,090.7. 같은 모델에서 샘플러 비교 시 AWSGHMC가 두 데이터 모두 perplexity · 최저 에너지 1위
한계→해결	모의실험 기준으로 맞춘 샘플러 설정이 실데이터의 큰 에너지 범위에서 작동하지 않음(한 구간에 갇힘) → 구간 폭을 데이터 에너지 범위에 비례하도록 바꿔 정상화
배운 점	모델이 맞는지는 정답을 아는 데이터로 먼저 확인해야 함. 생성기와 평가 지표는 LDA · HTMM · TNTM · BNTM 비교에 그대로 재사용

2025 – 2026
연구책임자 · 제1저자

전이 네트워크 토픽 모델을 이용한 임베디드 기술의 성장 예측

한국연구재단 석사과정생연구장려금 과제 성과 · 투고 예정 Python · GPU 샘플러 · Google BigQuery(SQL) · OpenAlex · L2 로지스틱 회귀

> **논문 초록 114,066건 · 미국 특허 21,028건(BigQuery SQL로 직접 추출)으로 3년 뒤 성장할 기술 토픽을 예측해 AUC 논문 0.876 · 특허 0.746, 성장 이유를 토픽 전이로 설명**

문제	기존 TNTM은 전 기간에 전이행렬이 하나뿐이라 전이 구조의 연도별 변화를 볼 수 없음
해결	연도별 전이행렬을 계층 사전분포로 묶어 TNTM 확장(K=40, AWSGLD). 전이 네트워크에서 유입 · 자기전이 · 유입 출처 · 구조 변화 변수 8개를 직접 정의하고 데이터 변수 14개와 함께 예측 모형 구성
결과	문서 완성 perplexity 논문 TNTM 1172 · HTMM 1223 · LDA 2149. 성장 기준을 상위 10% · 30%로 바꿔도 AUC 논문 0.896 · 0.881 유지. 유입 증가(+0.31) · 자기전이(−0.28)가 주요 계수 → 다른 토픽에서 문장이 넘어오는 토픽이 성장
한계→해결	시점을 섞은 교차검증은 미래 정보가 섞여 성능이 부풂 → 과거 자료로만 학습하는 rolling-origin 평가(논문 13개 · 특허 11개 결과연도). 토픽 모델까지 기준연도마다 다시 추정해 기준연도 이후 문헌을 빼도 AUC 논문 0.828 · 특허 0.691
데이터	Google BigQuery 공개 특허 데이터셋에서 SQL로 미국 특허 21,028건(524,424문장)을, OpenAlex에서 임베디드 관련 12개 구문으로 논문 초록 114,066건을 직접 추출 · 정제
담당	데이터 수집 · 정제 · GPU 샘플러 구현 · 변수 정의 · 평가 설계 · 논문 작성

2025
제1저자

자율주행 도메인에서 LoRA 기반 sLLM 파인튜닝 연구

한국자료분석학회지 27(3) 769–780 게재 PyTorch · Transformers · PEFT(LoRA) · Phi-4-mini · RAG

> **Phi-4-mini(3.8B)를 파라미터 0.01%만 학습하는 LoRA로 자율주행 도메인에 맞춰, 같은 조건 RAG 대비 ROUGE-1 0.0888 → 0.1495(68.4%↑)**

문제 임베디드 환경에서는 전체 파라미터 파인튜닝의 자원 부담이 큼. 파인튜닝과 검색 증강 중 무엇을 쓸지가 핵심 결정

해결 BDD-X 주행 설명 주석 26,228개로 LoRA 파인튜닝, RAG(k=1)와 같은 조건에서 정량 비교

결과 ROUGE-1 0.0888 → 0.1495(68.4%↑), 평균 응답 시간 1.145초. 교통법규 분류(약 7만 건)로 넓힌 실험에서 Accuracy 0.745 · Macro F1 0.731

2025 – 2026
제1저자

AWSGLD를 이용한 전이 네트워크 토픽 모델 추론

한국자료분석학회지 28(1) 109–121 게재 Python · AWSGLD · TNTM

> **Simplex 제약 때문에 경사 기반 추론이 어려운 TNTM에 AWSGLD를 적용해 SGD 대비 토픽 다양성 0.48 → 0.96(2배), 잡음 조건에서 SGLD 대비 perplexity 약 10배 개선**

해결 TNTM 원 논문에 없는 추론 수식을 유도해 구현. 사후분포를 에너지 구간별로 가중해 다봉 사후분포를 평탄화

한계→해결 토픽 수 K를 미리 정해야 하고 잡음이 커지면 이점이 줄어듦 → 후속 연구 BNTM에서 희소 사전분포와 AWSGHMC로 해결

실무 경험

2023.12 – 2024.04
팀 2명

JERESFARM · 데이터 분석 인턴

스마트팜 Python · statsmodels(ARIMA · VAR · VECM) · scikit-learn · LGBM

> **현장 생육 데이터로는 결론을 낼 수 없음을 검정으로 확인하고, 공공 데이터로 과제를 다시 정해 Test F1 0.81 모델과 환경 임계값을 도출, 다음 작물의 센서 측정 설계까지 연결**

문제 센서 변수 29개에 비해 생육 크기는 개체 18개 · 20일 · 하루 1회 줄자 측정. 사내 데이터 분석 인력 없음

분석 로그 차분 후 ADF 정상성 확인. VAR에서 유의수준 0.05의 유의 변수 없음 → 공적분 확인 후 VECM 재검정. Linear · Ridge · Lasso 테스트 R^2 0.36 · 0.51 · 0.99, Lasso 변수 17개

한계→해결 테스트 데이터가 10%뿐이라 R^2 0.99는 과적합으로 판단, 원인을 종속변수 관측 부족으로 규명 → ① 농촌진흥청 공공 데이터로 작물별 최적 환경과 토지에 맞는 작물을 찾는 6종 작물 다중 분류로 전환 ② 다음 작물(딸기) 농장 사전 조사 · 카메라 센서 구성 협의

결과 모델 6종(DT · SVM · K-NN · Bagging · RF · LGBM) 비교, Train–Test 격차가 가장 작은 LGBM 선정 (Test F1 0.81). 영향력 온도 > 일사량 > CO_2, 임계 구간 온도 25°C · CO_2 400ppm

배운 점 모델보다 측정 설계가 먼저. 최고 점수보다 일반화 격차로 모델 선택

프로젝트 직무 관련 · 성과 순

2025
개인

국제 메타데이터 표준 통합 LLM 기반 그래프 증강 추천시스템

수업 프로젝트(A+) · KIAT 표준전문인력양성 과제 성과 Python · LLM(LLMRec) · LightGCN · ISO 3166-1 · BCP 47 · 대응표본 t-검정

> **LLM이 만든 메타데이터를 국제 표준으로 정규화해 표준 적합률 48.4% → 91.4%(43.0%p↑), 상호운용성 0% → 80.3%, 추천 성능 손실 없음 · 과목 A+**

문제 LLMRec으로 만든 Netflix 메타데이터(17,366건)에서 같은 국가가 USA · United States · America로 나뉘어 시스템 간 결합 불가

해결 ISO 3166-1 alpha-2 · BCP 47 정규화 레이어와 필드별 형식 적합률 지표 설계

결과 country 표면형 1,166개 → 57개(95%↓), language 326개 → 52개(84%↓), column-shift 724건 자동 검출. LightGCN 10 seed 반복 · 대응표본 t-검정에서 recall@k · ndcg@k 7개 지표 모두 $p > 0.05$

배운 점 성능이 오르지 않아도 손실이 없음을 검정으로 보이면 데이터 품질이 기여가 됨

2025.03 – 2025.09
대학원생 멘토 · 멘티 1명

파인튜닝과 CAG 결합 대화형 AI 성능 개선 연구 (기후정책)

에코업혁신융합대학사업단 학부생 연구원 프로그램 · 포스터 발표 QLoRA(4bit) · CAG(KV 캐시) · BLEU · ROUGE · BERTScore · CHRF · METEOR · TER

> **파인튜닝 모델에 문서를 KV 캐시로 미리 올리는 CAG를 붙여 BLEU-1 0.235 → 0.600(2.6배), TER 318.7 → 76.9(75.9%↓), 반복 생성 편차 79% 감소**

문제 파인튜닝 단독 모델은 근거 문서를 인용하지 못하고, 학습 범위 밖 질문에 사실과 다른 답을 냄

해결 QLoRA 4bit 파인튜닝 + CAG 구조를 제안. 연구 주제 구체화 · 방법론 선정 · 실험 설계 · 지표 검토를 멘티와 함께 수행

결과 기업 기후정책 문서 질문 5개 × 5회 생성, 8개 지표 모두 FT+CAG 우세(ROUGE-L 0.265 → 0.525, BERTScore 0.867 → 0.910). 표준편차 BLEU-1 0.160 → 0.033(79%↓) · TER 130.4 → 2.7(98%↓)로 같은 질문에 같은 답

2025
개인

3D 객체 탐지 최적화를 위한 SGMCMC 기법 적용

수업 프로젝트(A+) PyTorch · CUDA · OpenPCDet · KITTI · PointPillars · SGLD · SGHMC · SGNHT

> **KITTI 3D 객체 탐지에서 SGMCMC 3종을 같은 조건으로 비교해, 모멘텀으로 기울기 잡음을 줄인 SGHMC가 BEV AP 49.59%로 최고(SGLD 대비 23.9%p↑)임을 확인 · 과목 A+**

문제 점추정 최적화기는 파라미터 불확실성을 다루지 못함 → GCIoU 손실을 에너지 함수로 두고 SGLD · SGHMC · SGNHT 업데이트식을 유도 · 구현

해결 KITTI + OpenPCDet + CT-Stack 백본 + PointPillars, 80 epoch · batch 8 · OneCycle LR을 고정하고 최적화기만 교체 → 성능 차이를 샘플러 차이로 해석

결과 BEV AP(Moderate) SGHMC 49.59% > SGD 49.07% > SGLD 25.67% ≈ SGNHT 25.37%. SGHMC는 학습 손실도 0.813으로 최저

발견 이론상 가장 안정적인 혼합을 기대한 SGNHT가 최하위. 속도와 thermostat 두 곳에 잡음이 더해져 온도 1e-3 이상에서 기울기 폭발, 1e-4 이하에서 업데이트 소실 → 잡음을 모멘텀으로 평균내는 SGHMC가 가장 안정적

한계→해결 온도에 극도로 민감한 문제를 온도 6단계(1e-5 ~ 1) 탐색으로 유효 범위(1e-5 부근)를 찾아 학습시키고, 남은 민감도는 층별 온도 조절로 줄이는 방향 제시

배운 점 대규모 모델에서는 이론적으로 정교한 샘플러보다 기울기 잡음을 안정적으로 제어하는 구조가 성능을 좌우

2025
개인

강화학습 기반 피카츄 배구 Agent 학습

석사 수업 프로젝트(인공지능이해와응용, A+) Python · gymnasium · Q-learning

> **RGB 관측을 좌표 격자 상태로 바꾸고 보상을 다시 설계해 10,000 에피소드 동안 평균 보상 −2.27 → 5.68(+7.95), 규칙 기반 AI를 이기는 구간 반복 · 과목 A+**

목표 하드코딩된 상대를 이기도록 Q-learning으로 학습시키며, 하이퍼파라미터 · 보상 설정에 따라 학습이 어떻게 달라지는지 확인

해결 432×304×3 관측을 20px 격자 4-tuple 상태로 이산화, 이산 행동 18개. 보상을 직접 설계 · 수정해 승 +15 / 패 −10, 이동 거리당 +0.01, step마다 +0.1, 공 충돌 +1.0, 공과의 거리 역수 +0.1/dist로 확정, ε는 1.0에서 ×0.995씩 줄여 0.1

한계→해결 보상 편차가 크고 같은 경로로 지는 패턴 반복 → 상태에 공의 속도가 없어 Markov 성질이 깨진 것이 원인으로 보고 속도 추가를 개선안으로 설계

2023

팀 3명 · QGIS 시각화 · 분석 코드

택시 수요 분석을 통한 택시 서비스 개선 방안

통계학술제 최우수상 R · 계층적 군집분석(Ward.D) · QGIS · 공공 데이터 병합

> **데이터 5건을 직접 구해 병합하고 공차율 지표를 설계해 서울 25개 자치구를 6개 군집으로 나누고, 군집별 문제와 배차 전략을 제안해 통계학술제 최우수상**

준비	선행 자료 조사와 뉴욕 택시 데이터를 분석한 교수님 자문 → 택시 수요 · 공급 비교에는 대중교통 공급과 유동인구를 함께 봐야 한다고 판단
해결	빅데이터캠퍼스(택시운영분석 · 표준노드아이디DB) · 국가공간정보포털(행정구역) · 서울 열린데이터광장(유동인구 2종)에서 데이터 5건 병합. 요일별 승차건수, 면적당 대중교통 분포율, 유동인구 대비 역 · 정류장 분포 계산, 공차율 지표 설계 후 3개 변수 증감 조합 + 계층적 군집분석
결과	군집별 문제(대중교통 부족 · 인구 대비 교통수단 부족 등) 정의와 배차 전략: 강남 · 서초(전 지표 상승), 중구(관광 · 업무), 저조 지역(광진 · 중랑 · 도봉 등). QGIS 지도와 공차율 조회 웹 화면 제작
한계→해결	데이터가 실시간이 아니라 공차율 화면을 서비스로 운영할 수 없음 → 실시간 데이터 없이 적용할 수 있는 자치구 군집별 배차 · 서비스 전략으로 정리

협업 · 리더십

2025.03 – 09 **학부생 연구원 프로그램 대학원생 멘토** · 에코업혁신융합대학사업단 · 멘티 1명과 연구 주제 구체화 · 방법론 선정 · 실험 설계를 함께 진행해 포스터 발표까지 완료

2022 – 2023 **마케팅 서포터즈 4건 · 예큐레이션(예산시장) 5인 팀 리더** · 팀 콘텐츠 기획과 이벤트 운영을 이끌어 콘텐츠 29건 총 조회 3,671회, 영상 단일 2,500회 · KU_KEY 1 · 2기 · 사야컴퍼니 전시 2건

기술

언어 · 도구	Python, R, SQL, Git, CUDA
ML · DL	PyTorch, TensorFlow, scikit-learn, Transformers, PEFT(LoRA · QLoRA), OpenPCDet, LangChain, Chroma
통계 · 추론	SGLD · SGHMC · AWSGLD · AWSGHMC · MH-within-Gibbs 구현, 시계열(ARIMA · VAR · VECM), 베이지안 검정
자격	ADsP(데이터분석 준전문가, 2023.11)