이력서

김다연

abcde0405@naver.com | 포트폴리오 kim-da-yeon.github.io | GitHub Kim-Da-yeon



핵심 요약

논문 초록 114,066건과 특허 21,028건을 직접 추출해 3년 뒤 성장 기술을 예측한(AUC 0.876 · 0.746) Data Scientist입니다.

경험 1. 서울시 택시 수요 · 공급 분석 | 통계학술제 최우수상

- 공공 데이터 6종을 병합해 25개 자치구를 6개 군집으로 분류하고 공차율 웹과 택시 서비스 개선 방향 제시

경험 2. 임베디드 기술 성장 예측 | AUC 논문 0.876 · 특허 0.746

- Google BigQuery에서 SQL로 미국 특허 21,028건을, OpenAlex에서 논문 초록 114,066건을 직접 추출해 3년 뒤 성장할 기술 토픽 예측(토픽 모델까지 기준연도별 재추정 시 0.828 · 0.691)

경험 3. 스마트팜 데이터 분석 인턴 | 검정으로 데이터 한계 확인 · 후속 측정 설계 제안

- 생육 데이터(개체 18개 · 20일)로는 영향요인을 규명할 수 없음을 검정으로 확인하고 후속 센서 · 카메라 배치와 측정 항목을 현업과 협의해 제안

학력

2025.03 – 2027.02 (졸업예정) **고려대학교 일반대학원 빅데이터사이언스학과 석사과정**

2021.03 – 2025.02 **고려대학교 세종캠퍼스 빅데이터사이언스학부 학사** · 융합전공 자율주행시스템학과 · 표준학

실무 경험

2023.12 – 2024.04 (인턴 2명)

JERESFARM · 데이터 분석 인턴

스마트팜 Python · statsmodels(VAR · VECM) · scikit-learn · Lasso

분석 인력이 없던 농장에서 생육 데이터(개체 18개 · 20일)로는 영향요인을 규명할 수 없음을 검정으로 확인하고, 후속 센서 · 카메라 배치와 측정 항목을 현업과 협의해 제안

2024 1학기 (팀 3명)

환경에 따른 최적 작물 예측 (JERESFARM 인턴 후속)

통계학과 머신러닝 PBL · 결과 · 코드 농장 전달 Python · Pandas · scikit-learn · LightGBM · Feature Importance · PDP

농촌진흥청 공공 데이터(원본 827,080건, 학습 · 평가 90,000건)로 작물 5종과 랜덤 클래스 분류 모델 6개를 비교, Test F1 상위 앙상블 3개 중 격차가 가장 작은 LightGBM(Test 0.81, 작물 5종 평균 약 0.77, 격차 0.03 vs Bagging 0.17 · RF 0.21)을 선정하고 결과와 코드를 JERESFARM에 전달

연구 · 논문

2025 – 2026 (연구책임자 · 제1저자)

전이 네트워크 토픽 모델을 이용한 임베디드 기술의 성장 예측

한국연구재단 석사과정생연구장려금 과제 성과 · 투고 예정 Python · GPU 샘플러 · Google BigQuery(SQL) · OpenAlex · L2 로지스틱 회귀

논문 초록 114,066건 · 미국 특허 21,028건(BigQuery SQL로 직접 추출)으로 3년 뒤 성장할 기술 토픽을 예측해 AUC 논문 0.876 · 특허 0.746(무작위 0.5, 토픽 모델까지 기준연도별 재추정 시 0.828 · 0.691), 성장 이유를 토픽 전이로 설명

수행 연도별 전이행렬을 계층 사전분포로 묶어 TNTM 확장(K=40, AWSGLD). 전이 네트워크에서 유입 · 자기전이 · 유입 출처 · 구조 변화 변수 8개를 직접 정의하고 데이터 변수 14개와 함께 예측 모형 구성

2025 – 2026 (제1저자 · 공저 2인)

Fixed-K Shrinkage Bayesian Transition Network Topic Model with AWSGHMC Inference

SCI급 학술지 투고 예정 Python · NumPy · SG-MCMC(AWSGHMC · SGHMC · SGLD) · MH-within-Gibbs · 베이지안 추론

기존 토픽 모델의 한계를 보완한 새 토픽 모델 BNTM과 샘플러 AWSGHMC를 직접 설계하고, 정답을 아는 모의실험 데이터(환경 5종)를 생성해 검증 · 실데이터(FAERS) 문서 완성 perplexity를 HTMM 54.99 → 32.13(41.6%↓)으로 낮추고, 정답 20토픽 환경의 추정 토픽 수를 SGHMC 15.4개 → AWSGHMC 20.0개로 정확 복원 · 포스터논문 장려상

수행 Logistic-Normal 모수화(Simplex 제약 제거) + Sparse Dirichlet Prior(활성 토픽 수를 데이터가 결정) + AWSGHMC(멀티모달 사후분포의 로컬 트랩 탈출)를 결합한 새 모델 BNTM과 샘플러를 설계

포스터

2025 – 2026
제1저자

AWSGLD를 이용한 전이 네트워크 토픽 모델 추론

한국자료분석학회지 28(1) 109–121 게재 Python · AWSGLD · TNTM

TNTM 추론을 MH-Gibbs + AWSGLD로 바꿔 IMDB 리뷰 1,000문장 실험에서 토픽 다양성 SGD 0.48 → AWSGLD 0.96(SGLD도 0.96), 문장마다 무작위 단어 50개를 넣은 조건의 perplexity는 SGLD보다 약 8배 낮음(m=30)

수행 문장 토픽은 MH-Gibbs, 전이행렬 · 단어-토픽 분포는 AWSGLD로 추론. 추론에 필요한 미분식을 유도해 구현하고, 문장마다 무작위 단어 0 · 50 · 100개를 넣어 SGD · SGLD와 비교

논문 DOI

연구과제 참여

2025 – 2026 **TNTM을 활용한 임베디드 시스템 문서의 주제 흐름 분석** · 연구책임자 · 한국연구재단 석사과정생연구장려금 · RS-2025-25437035

2024 – 2027 **베이지안 추론을 위한 적응적 가중 SGMCMC 알고리즘** · 참여연구원 · 한국연구재단 · RS-2024-00352792 · 2차년도 샘플러 구현 · 실험 · 분석 전담

2025 – 2026 **초격차산업기반표준전문인력양성** · 참여연구원 · KIAT · RS-2025-02215617 · 표준 프로젝트 2건

수상

2026 **한국자료분석학회 하계학술발표대회 포스터논문 장려상** · Fixed-K Shrinkage Bayesian Transition Network Topic Model Inference with AWSGLD · 제1저자

2023 **고려대학교 빅데이터사이언스학부 통계학술제 최우수상** · 택시 수요 분석 · 팀 3명

2023 **미래모빌리티 및 세종지역혁신 아이디어 공모전 장려상** · Smart Green-STOP · 3D 구현 담당 · 세종특별자치시

프로젝트 직무 관련 · 성과 순

2023
팀 3명 · QGIS 시각화 · 분석 코드

택시 수요 분석을 통한 택시 서비스 개선 방안 마련

통계학술제 최우수상 R · 계층적 군집분석(Ward.D) · QGIS · 공공 데이터 병합

공공 데이터 6종을 직접 구해 병합하고 공차율 웹을 만들어 서울 25개 자치구를 6개 군집으로 나누고, 택시 서비스 개선 방향을 정리해 통계학술제 최우수상

포스터

2025
팀 4명 · 수집 · 지표 정의 · 발표

대학 기숙사 운영 유형 분류 (대학알리미 공시 데이터)

2025 대학알리미 데이터 아이디어 공모전 본선 진출(수상 없음) Python · 공시 데이터 전처리 · 지표 설계

수용률 · 이익률 지표를 정의해 대학 기숙사를 4개 운영 유형으로 분류하고 유형별 특징 · 6개 개선안을 제시, 공모전 본선 진출(수상 없음)

2024
팀 2명

베이지안 기법을 이용한 강수예보 정확도 분석

학부 베이지안 PBL(A+) Python · 베이지안 갱신 · 베이즈 팩터 검정

기상청 예보 약 18만 건(세종시 조치원읍)으로 강수확률을 사후확률로 다시 계산해, 10시간 예보에서 강수확률 70% 이상이면 비가 올 확률 0.82~0.95, 0~30%면 0에 가깝다는 판단 기준 도출 · 과목 A+

활동 · 리더십

2025.03 – 현재 **DLM연구실 대표** · 구성원 소통 · 세미나 · 공동 연구 자원 관리

2025.03 – 09 **학부생 연구원 프로그램 대학원생 멘토** · 멘티 1명과 연구 주제 · 방법론 · 실험 설계를 함께 진행해 포스터 발표까지 완료

기술

언어 · 자격	Python(Pandas), R, SQL(MySQL · Google BigQuery), Git, CUDA, Excel · ADsP(2023.11) · OPIc IM1(2026.09)
ML · DL	PyTorch, TensorFlow, scikit-learn, Transformers, PEFT(LoRA · QLoRA), OpenPCDet, LangChain, Chroma
통계 · 추론	SGLD · SGHMC · SGNHT · AWSGLD · AWSGHMC · MH-within-Gibbs 구현, 시계열(VAR · VECM), 베이지안 검정