이력서

# 김다연

dayun0405@gmail.com | 포트폴리오 kim-da-yeon.github.io | GitHub Kim-Da-yeon



## 핵심 요약

**Python, R, SQL을 기반으로 수요 · 공급 분석, 데이터 정합성 검증, 통계 · 머신러닝 모델링을 수행해 온 빅데이터사이언스 석사과정 지원자입니다.**

### 경험 1. 서울시 택시 수요 · 공급 분석 | 통계학술제 최우수상

- 서울시 공공데이터 6종을 활용해 25개 자치구를 6개 유형으로 분류하고 지역별 배차 · 서비스 전략 제안

### 경험 2. LLM 생성 데이터 정합성 검증 | 형식 적합률 43.0%p 개선

- Netflix 메타데이터 17,366건의 형식 적합률을 48.4%에서 91.4%로 개선하고 필드 밀림 오류 724건 자동 검출, 추천 성능 손실 없음을 검정으로 확인

### 경험 3. 스마트팜 데이터 분석 인턴 | 분석 한계 검증 및 후속 수집 방향 제안

- 생육 · 환경 데이터의 결측과 관측 구조를 검토해 기존 데이터만으로는 신뢰할 만한 영향요인을 규명하기 어렵다는 한계 확인

## 학력

2025.03 – 2027.02 (졸업예정) **고려대학교 일반대학원 빅데이터사이언스학과 석사과정**

2021.03 – 2025.02 **고려대학교 세종캠퍼스 빅데이터사이언스학부 학사** · 융합전공 자율주행시스템학과 · 표준학

## 연구 · 논문

2025 – 2026
연구책임자 · 제1저자

### 전이 네트워크 토픽 모델을 이용한 임베디드 기술의 성장 예측

**한국연구재단 석사과정생연구장려금 과제 성과 · 투고 예정** Python · GPU 샘플러 · Google BigQuery(SQL) · OpenAlex · L2 로지스틱 회귀

> **논문 초록 114,066건 · 미국 특허 21,028건(BigQuery SQL로 직접 추출)으로 3년 뒤 성장할 기술 토픽을 예측해 AUC 논문 0.876 · 특허 0.746, 성장 이유를 토픽 전이로 설명**

**한계→해결** 시점을 섞은 교차검증은 미래 정보가 섞여 성능이 부풂 → 과거 자료로만 학습하는 rolling-origin 평가(논문 13개 · 특허 11개 결과연도). 토픽 모델까지 기준연도마다 다시 추정해 기준연도 이후 문헌을 빼도 AUC 논문 0.828 · 특허 0.691

2025 – 2026
개인 연구 · 제1저자

### Fixed-K Shrinkage Bayesian Transition Network Topic Model with AWSGHMC Inference

**SCI급 학술지 투고 예정** Python · NumPy · SG-MCMC(AWSGHMC · SGHMC · SGLD) · MH-within-Gibbs · 베이지안 추론

> **문장 사이의 토픽 전이를 다루는 토픽 모델(BNTM)과 샘플러(AWSGHMC)를 제안해, 모의실험 5종 · 실데이터 2종에서 BNTM이 LDA · HTMM보다 문서 완성 perplexity가 낮고 AWSGHMC가 최저 에너지 도달 · 토픽 수 정확 복원 1위**

**한계→해결** 모의실험 기준으로 맞춘 샘플러 설정이 실데이터의 큰 에너지 범위에서 작동하지 않음(한 구간에 갇힘) → 구간 폭을 데이터 에너지 범위에 비례하도록 바꿔 정상화

2025
제1저자

### 자율주행 도메인에서 LoRA 기반 sLLM 파인튜닝 연구

**한국자료분석학회지 27(3) 769–780 게재** PyTorch · Transformers · PEFT(LoRA) · Phi-4-mini · RAG

> **자율주행 판단을 설명하는 정확 · 일관된 실시간 응답을 목표로 LoRA FT-Driver(Phi-4-mini 3.8B, 파라미터 0.01% 학습)를 제안해 RAG 대비 ROUGE-1 0.0888 → 0.1495(68.4%↑), 교통법규 위반 분류 Accuracy 0.505 → 0.745**

2025 – 2026
제1저자

### AWSGLD를 이용한 전이 네트워크 토픽 모델 추론

한국자료분석학회지 28(1) 109–121 게재 Python · AWSGLD · TNTM

> **TNTM 추론을 MH-Gibbs + AWSGLD로 바꿔 잡음 텍스트에서도 안정적 · 해석 가능한 토픽 전이 구조를 추정: IMDB 리뷰 1,000문장 실험에서 토픽 다양성 SGD 0.48 → AWSGLD 0.96(2배), 문장마다 무작위 단어 50개를 넣은 조건의 perplexity는 SGLD보다 약 10배 낮음**

한계→해결 토픽 수 K를 미리 정해야 하고 잡음이 커지면 이점이 줄어듦 → 후속 연구 BNTM에서 희소 사전분포와 AWSGHMC로 해결

## 실무 경험

2023.12 – 2024.04
팀 2명

### JERESFARM · 데이터 분석 인턴

스마트팜 Python · statsmodels(ARIMA · VAR · VECM) · scikit-learn · LGBM

> **현장 생육 데이터로는 결론을 낼 수 없음을 검정으로 확인하고, 공공 데이터로 과제를 다시 정해 Test F1 0.81 모델과 환경 임계값을 도출, 다음 작물의 센서 측정 설계까지 연결**

한계→해결 테스트 데이터가 10%뿐이라 $R^2$ 0.99는 과적합으로 판단, 원인을 종속변수 관측 부족으로 규명 → ① 농촌진흥청 공공 데이터로 작물별 최적 환경과 토지에 맞는 작물을 찾는 6종 작물 다중 분류로 전환 ② 다음 작물(딸기) 농장 사전 조사 · 카메라 센서 구성 협의

## 연구과제 참여

2025 – 2026 **TNTM을 활용한 임베디드 시스템 문서의 주제 흐름 분석** · 연구책임자 · 한국연구재단 석사과정생연구장려금 · RS-2025-25437035

2024 – 2027 **베이지안 추론을 위한 적응적 가중 SGMCMC 알고리즘** · 참여연구원 · 한국연구재단 · RS-2024-00352792 · 2차년도 샘플러 구현 · 실험 · 분석 전담

2025 – 2026 **초격차산업기반표준전문인력양성** · 참여연구원 · KIAT · RS-2025-02215617 · 표준 프로젝트 2건

## 수상

2026 **한국자료분석학회 하계학술대회 포스터논문 장려상** · Fixed-K Shrinkage BNTM with AWSGLD Inference · 제1저자

2023 **고려대학교 빅데이터사이언스학부 통계학술제 최우수상** · 택시 수요 분석 · 팀 3명

2023 **미래모빌리티 및 세종지역혁신 아이디어 공모전 장려상** · Smart Green-STOP · 3D 구현 담당 · 세종특별자치시

## 프로젝트 직무 관련 · 성과 순

2025
개인

### 국제 메타데이터 표준 통합 LLM 기반 그래프 증강 추천시스템

수업 프로젝트(A+) · KIAT 표준전문인력양성 과제 성과 Python · LLM(LLMRec) · LightGCN · ISO 3166-1 · BCP 47 · 대응표본 t-검정

> **LLM이 만든 메타데이터를 국제 표준으로 정규화해 표준 적합률 48.4% → 91.4%(43.0%p↑), 상호운용성 0% → 80.3%, 추천 성능 손실 없음 · 과목 A+**

2024
팀 2명

### 베이지안 기법을 이용한 강수예보 정확도 분석

학부 베이지안 PBL(A+) Python · 베이지안 갱신 · 베이즈 팩터 검정

> **기상청 예보 약 18만 건으로 강수확률을 사후확률로 다시 계산해, 강수확률 70% 이상이면 비가 올 확률 88~95%(베이즈 팩터 7.36 이상), 0~30%면 0에 가깝다는 판단 기준 도출 · 과목 A+**

한계→해결 50시간 예보는 사후확률이 낮고 신뢰구간이 넓음 → 결론을 신뢰구간이 좁은 10~30시간 예보로 한정

2023
개인

### 잦은 배달 음식 섭취가 건강에 미치는 영향

학부 수업 프로젝트(A+) R · 다중 로지스틱 회귀 · AIC 변수 선택 · K-means · 계층적 군집분석

> **2022 식품소비행태조사 6,366명으로 식사 방법별 건강 오즈비를 추정해 단체급식 1.25 · 일반식당 1.19 · 집밥 1.14 · 배달 0.80을 밝히고, 배달 빈도보다 식생활 습관이 건강에 더 크게 작용함을 확인 · 과목 A+**

2023
팀 3명 · QGIS 시각화 · 분석 코드

### 택시 수요 분석을 통한 택시 서비스 개선 방안

통계학술제 최우수상 R · 계층적 군집분석(Ward.D) · QGIS · 공공 데이터 병합

> **데이터 5건을 직접 구해 병합하고 공차율 지표를 설계해 서울 25개 자치구를 6개 군집으로 나누고, 군집별 문제와 배차 전략을 제안해 통계학술제 최우수상**

한계→해결 데이터가 실시간이 아니라 공차율 화면을 서비스로 운영할 수 없음 → 실시간 데이터 없이 적용할 수 있는 자치구 군집별 배차 · 서비스 전략으로 정리

## 협업 · 리더십

| | |
|---|---|
| 2025.03 – 09 | **학부생 연구원 프로그램 대학원생 멘토** · 멘티 1명과 연구 주제 구체화 · 방법론 선정 · 실험 설계를 함께 진행해 포스터 발표까지 완료 |
| 2022 – 2023 | **마케팅 서포터즈 4건 · 예큐레이션 5인 팀 리더** · 콘텐츠 기획과 이벤트 운영을 이끌어 콘텐츠 29건 총 조회 3,671회 |

## 기술

| | |
|---|---|
| 언어 · 자격 | Python, R, SQL, Git, CUDA · ADsP(데이터분석 준전문가, 2023.11) |
| ML · DL | PyTorch, TensorFlow, scikit-learn, Transformers, PEFT(LoRA · QLoRA), OpenPCDet, LangChain, Chroma |
| 통계 · 추론 | SGLD · SGHMC · SGNHT · AWSGLD · AWSGHMC · MH-within-Gibbs 구현, 시계열(ARIMA · VAR · VECM), 베이지안 검정 |