이력서

# 김다연

abcde0405@naver.com | 포트폴리오 kim-da-yeon.github.io | GitHub Kim-Da-yeon



## 핵심 요약

**Python, SQL, R을 활용한 데이터 전처리 · 통계 분석 및 예측 모델 연구 경험을 갖춘 빅데이터사이언스 석사과정 지원자입니다.**

### 경험 1. 서울시 택시 수요 · 공급 분석 | 통계학술제 최우수상

- 서울시 공공데이터 6종을 활용해 25개 자치구를 6개 유형으로 분류하고 지역별 배차 · 서비스 전략 제안

### 경험 2. 임베디드 기술 성장 예측 | AUC 논문 0.876 · 특허 0.746

- Google BigQuery에서 SQL로 미국 특허 21,028건을, OpenAlex에서 논문 초록 114,066건을 직접 추출해 3년 뒤 성장할 기술 토픽 예측

### 경험 3. 스마트팜 데이터 분석 인턴 | 후속 측정 설계 제안 · 작물 분류 F1 0.81

- 생육 데이터(개체 18개 · 20일)로는 영향요인을 규명할 수 없음을 검정으로 확인하고 후속 센서 · 카메라 배치와 측정 항목을 현업과 협의해 제안

## 학력

2025.03 – 2027.02 (졸업예정) **고려대학교 일반대학원 빅데이터사이언스학과 석사과정**

2021.03 – 2025.02 **고려대학교 세종캠퍼스 빅데이터사이언스학부 학사** · 융합전공 자율주행시스템학과 · 표준학

## 연구 · 논문

2025 – 2026
연구책임자 · 제1저자

### 전이 네트워크 토픽 모델을 이용한 임베디드 기술의 성장 예측

한국연구재단 석사과정생연구장려금 과제 성과 · 투고 예정 Python · GPU 샘플러 · Google BigQuery(SQL) · OpenAlex · L2 로지스틱 회귀

> **논문 초록 114,066건 · 미국 특허 21,028건(BigQuery SQL로 직접 추출)으로 3년 뒤 성장할 기술 토픽을 예측해 AUC 논문 0.876 · 특허 0.746(무작위 0.5), 성장 이유를 토픽 전이로 설명**

수행 연도별 전이행렬을 계층 사전분포로 묶어 TNTM 확장(K=40, AWSGLD). 전이 네트워크에서 유입 · 자기전이 · 유입 출처 · 구조 변화 변수 8개를 직접 정의하고 데이터 변수 14개와 함께 예측 모형 구성

2025 – 2026
개인 연구 · 제1저자

### Fixed-K Shrinkage Bayesian Transition Network Topic Model with AWSGHMC Inference

SCI급 학술지 투고 예정 Python · NumPy · SG-MCMC(AWSGHMC · SGHMC · SGLD) · MH-within-Gibbs · 베이지안 추론

> **기존 토픽 모델의 한계를 보완한 새 토픽 모델 BNTM과 샘플러 AWSGHMC를 직접 설계하고, 정답을 아는 모의실험 데이터(환경 5종)를 생성해 검증 · 실데이터(FAERS) 문서 완성 perplexity를 HTMM 54.99 → 32.13(41.6%↓)으로 낮추고, 정답 20토픽 환경의 추정 토픽 수를 SGHMC 15.4개 → AWSGHMC 20.0개로 정확 복원 · 포스터논문 장려상**

수행 Logistic-Normal 모수화(Simplex 제약 제거) + Sparse Dirichlet Prior(활성 토픽 수를 데이터가 결정) + AWSGHMC(다봉 사후분포의 로컬 트랩 탈출)를 결합한 새 모델 BNTM과 샘플러를 설계

2025 – 2026
제1저자

### AWSGLD를 이용한 전이 네트워크 토픽 모델 추론

한국자료분석학회지 28(1) 109–121 게재 Python · AWSGLD · TNTM

> **TNTM 추론을 MH-Gibbs + AWSGLD로 바꿔 잡음 텍스트에서도 안정적 · 해석 가능한 토픽 전이 구조를 추정: IMDB 리뷰 1,000문장 실험에서 토픽 다양성 SGD 0.48 → AWSGLD 0.96(2배), 문장마다 무작위 단어 50개를 넣은 조건의 perplexity는 SGLD보다 약 10배 낮음**

수행 문장 토픽은 MH-Gibbs, 전이행렬 · 단어-토픽 분포는 AWSGLD로 추론. TNTM 원 논문에 없는 추론 수식을 유도해 구현하고, 문장마다 무작위 단어 0 · 50 · 100개를 넣어 SGD · SGLD와 비교

2025
제1저자

### 자율주행 도메인에서 LoRA 기반 sLLM 파인튜닝 연구

**한국자료분석학회지 27(3) 769–780 게재** PyTorch · Transformers · PEFT(LoRA) · Phi-4-mini · RAG

> **자율주행 판단을 설명하는 정확 · 일관된 실시간 응답을 목표로 LoRA FT-Driver(Phi-4-mini 3.8B, 파라미터 0.01% 학습)를 제안해 RAG 대비 ROUGE-1 0.0888 → 0.1495(68.4%↑), 교통법규 위반 분류 Accuracy 0.505 → 0.745**

**수행** BDD-X 주행 설명 주석 26,228개로 LoRA 파인튜닝, RAG(k=1)와 같은 조건에서 정량 비교

## 실무 경험

2023.12 – 2024.04
팀 2명

### JERESFARM · 데이터 분석 인턴

**스마트팜** Python · statsmodels(ARIMA · VAR · VECM) · scikit-learn · LGBM

> **분석 인력이 없던 농장에서 생육 데이터(개체 18개 · 20일)로는 영향요인을 규명할 수 없음을 검정으로 확인하고, 후속 센서 · 카메라 배치와 측정 항목을 현업과 협의해 제안 → 인턴 종료 후 공공 데이터 작물 분류 모델(Test F1 0.81)로 이어 농장에 전달**

2024.05 – 2024.06
개인

### 환경조건 기반 작물 분류 모델 (JERESFARM 인턴 후속)

**인턴 종료 후 개인 프로젝트 · 결과 · 코드 농장 전달** Python · Pandas · scikit-learn · LightGBM · Feature Importance · PDP

> **농촌진흥청 공공 데이터 827,080건으로 작물 분류 모델 6개 중 F1 격차가 가장 작은 LightGBM(Test 0.81, 격차 0.03 vs Bagging 0.17 · RF 0.21)을 고르고, 온도 25°C · $CO_2$ 400ppm 임계 구간을 도출해 결과와 코드를 JERESFARM에 전달**

**수행** 공통 환경변수 5개 선정 · 결측과 클래스 구성 정리, Decision Tree · SVM · K-NN · Bagging · Random Forest · LightGBM 비교

## 연구과제 참여

2025 – 2026 **TNTM을 활용한 임베디드 시스템 문서의 주제 흐름 분석** · 연구책임자 · 한국연구재단 석사과정생연구장려금 · RS-2025-25437035

2024 – 2027 **베이지안 추론을 위한 적응적 가중 SGMCMC 알고리즘** · 참여연구원 · 한국연구재단 · RS-2024-00352792 · 2차년도 샘플러 구현 · 실험 · 분석 전담

2025 – 2026 **초격차산업기반표준전문인력양성** · 참여연구원 · KIAT · RS-2025-02215617 · 표준 프로젝트 2건

## 수상

2026 **한국자료분석학회 하계학술대회 포스터논문 장려상** · Fixed-K Shrinkage BNTM with AWSGLD Inference · 제1저자

2023 **고려대학교 빅데이터사이언스학부 통계학술제 최우수상** · 택시 수요 분석 · 팀 3명

2023 **미래모빌리티 및 세종지역혁신 아이디어 공모전 장려상** · Smart Green-STOP · 3D 구현 담당 · 세종특별자치시

## 프로젝트 직무 관련 · 성과 순

2023
팀 3명 · QGIS 시각화 · 분석 코드

### 택시 수요 분석을 통한 택시 서비스 개선 방안

**통계학술제 최우수상** R · 계층적 군집분석(Ward.D) · QGIS · 공공 데이터 병합

> **서울시 공공 데이터 6종을 직접 구해 병합하고 공차율 지표를 설계해 서울 25개 자치구를 6개 군집으로 나누고, 군집별 문제와 배차 전략을 제안해 통계학술제 최우수상**

**수행** 빅데이터캠퍼스(택시운영분석 · 표준노드아이디DB) · 국가공간정보포털(행정구역) · 서울 열린데이터광장(유동인구 2종) 등 데이터 6종 병합. 요일별 승차건수, 면적당 대중교통 분포율, 유동인구 대비 역 · 정류장 분포 계산, 공차율 지표 설계 후 3개 변수 증감 조합 + 계층적 군집분석

2025
팀 4명 · 수집 · 지표 정의 · 발표

### 대학 기숙사 운영 유형 분류 (대학알리미 공시 데이터)

**2025 대학알리미 데이터 아이디어 공모전 본선 진출** Python · 공시 데이터 전처리 · 지표 설계

> **수용률 · 이익률 지표를 정의해 대학 기숙사를 4개 운영 유형으로 분류하고 유형별 특징 · 6개 개선안을 제시, 구성과 시각화로 좋은 평가를 받아 공모전 본선 진출**

2024
팀 2명

### 베이지안 기법을 이용한 강수예보 정확도 분석

**학부 베이지안 PBL(A+)** Python · 베이지안 갱신 · 베이즈 팩터 검정

> **기상청 예보 약 18만 건으로 강수확률을 사후확률로 다시 계산해, 강수확률 70% 이상이면 비가 올 확률 88~95%(베이즈 팩터 7.36 이상), 0~30%면 0에 가깝다는 판단 기준 도출 · 과목 A+**

**수행** 예보시간 × 강수확률 구간 결합분포로 가능도 구성, 강수확률을 사전확률로 5단계 갱신, 베이즈 팩터 ≥ 1을 판정 기준으로 설정(사전확률 설계 · 갱신 · 검정 · 결론 담당)

2023
개인

### 잦은 배달 음식 섭취가 건강에 미치는 영향

**학부 수업 프로젝트(A+)** R · 다중 로지스틱 회귀 · AIC 변수 선택 · K-means · 계층적 군집분석

> **2022 식품소비행태조사 6,366명으로 식사 방법별 건강 오즈비를 추정해 단체급식 1.25 · 일반식당 1.19 · 집밥 1.14 · 배달 0.80을 밝히고, 배달 빈도보다 식생활 습관이 건강에 더 크게 작용함을 확인 · 과목 A+**

**수행** 건강 상태를 종속변수로 다중 로지스틱 회귀(AIC 1995 → 1989로 변수 선택, 다중공선성 변수 제거), 식생활 역량 10문항 + 배달 빈도로 K-means(덴드로그램 · Elbow로 k=4)

2024.09 – 12
개인 · 기획부터 검증까지

### 자전거 대여 시스템 데이터베이스 설계

**수업 프로젝트** MySQL · SQL · E-R 모델링 · PHP

> **요구사항 7개 항목을 4개 릴레이션으로 설계하고 삽입 · 갱신 · 삭제 연산으로 3NF를 검증, PHP 웹 화면과 연동**

## 활동 · 리더십

| | |
|---|---|
| 2025.03 – 현재 | **DLM연구실 대표** · 구성원 소통 · 세미나 · 공동 연구 자원 관리 |
| 2025.03 – 09 | **학부생 연구원 프로그램 대학원생 멘토** · 멘티 1명과 연구 주제 · 방법론 · 실험 설계를 함께 진행해 포스터 발표까지 완료 |
| 2023 · 2025 | **Python · Excel 실습 멘토** · 디지털리터러시 · 글로벌역량멘토링 수업 실습 지원 |
| 2023.02 – 12 | **예큐레이션 마케팅 서포터즈 5인 팀장** · 자율 기획 방식으로 바꿔 참여도 개선, 콘텐츠 29건 · 대표 영상 조회 2,523회 |
| 2024.12 – 2025.01 | **미국 UNLV 해외연수 · CES 2025 참관** · 임베디드 AI · 머신러닝 PBL 공동 과제 |

## 기술

| | |
|---|---|
| 언어 · 자격 | Python(Pandas), R, SQL(MySQL · Google BigQuery), Git, CUDA, Excel · ADsP(2023.11) · OPIc IM1(2026.09) |
| ML · DL | PyTorch, TensorFlow, scikit-learn, Transformers, PEFT(LoRA · QLoRA), OpenPCDet, LangChain, Chroma |
| 통계 · 추론 | SGLD · SGHMC · SGNHT · AWSGLD · AWSGHMC · MH-within-Gibbs 구현, 시계열(ARIMA · VAR · VECM), 베이지안 검정 |