이력서

김다연

dayun0405@gmail.com | 포트폴리오 kim-da-yeon.github.io | GitHub Kim-Da-yeon



핵심 요약

텍스트 데이터에 맞춰 LLM과 토픽 모델을 학습하고 비교합니다. 파인튜닝 · 검색 증강 · 캐시 증강을 같은 조건에서 정량 비교하고, 문장 순서를 다루는 토픽 모델을 직접 설계했습니다.

KCI 제1저자 논문 2편 게재 · 투고 예정 2편(SCI급 1편) · 한국연구재단 석사과정생연구장려금 연구책임자 · 수상 3건(통계학술제 최우수상 외)

경험 1 — **LLM 파인튜닝 · 검색 증강**
LoRA로 RAG 대비 ROUGE-1 68.4%↑(학술지 게재), FT+CAG로 BLEU-1 2.6배 · TER 75.9%↓, 출처를 반환하는 RAG 챗봇
PEFT(LoRA · QLoRA) · CAG · LangChain · Chroma

경험 2 — **기술 성장 예측 (연구책임자)**
논문 11만 · 특허 2만 건으로 3년 뒤 성장 토픽 예측 AUC 0.876 · 0.746. 미래 정보를 막는 rolling-origin 평가 설계
BigQuery SQL · GPU 샘플러 · 로지스틱 회귀

경험 3 — **토픽 모델 · MCMC 샘플러 설계**
토픽 수를 데이터로 정하는 BNTM과 AWSGHMC 샘플러 설계. 직접 설계한 모의실험 데이터 5종 모두 토픽 수 정확 복원, 실데이터 2종 perplexity 최저
SG-MCMC · 베이지안 추론 · Python

경험 4 — **데이터 품질 · 추천**
LLM 메타데이터 표준 정규화로 적합률 48.4% → 91.4%(43.0%p↑), 추천 성능 손실 없음을 10 seed t-검정으로 확인
LightGCN · ISO · BCP 47 · 통계 검정

경험 5 — **현장 데이터 분석 (인턴)**
측정 데이터의 한계를 검정으로 규명 → 공공 데이터로 전환해 Test F1 0.81 · 환경 임계값 도출 → 센서 측정 설계
statsmodels · scikit-learn · LGBM

학력

2025.03 – 2027.02 (졸업예정) — **고려대학교 일반대학원 빅데이터사이언스학과 석사과정**

2021.03 – 2025.02 — **고려대학교 세종캠퍼스 빅데이터사이언스학부 학사** · 융합전공 자율주행시스템학과 · 표준학

연구 · 논문

2025 · 제1저자

자율주행 도메인에서 LoRA 기반 sLLM 파인튜닝 연구

한국자료분석학회지 27(3) 769–780 게재 PyTorch · Transformers · PEFT(LoRA) · Phi-4-mini · RAG

> **Phi-4-mini(3.8B)를 파라미터 0.01%만 학습하는 LoRA로 자율주행 도메인에 맞춰, 같은 조건 RAG 대비 ROUGE-1 0.0888 → 0.1495(68.4%↑)**

2025 – 2026 · 연구책임자 · 제1저자

전이 네트워크 토픽 모델을 이용한 임베디드 기술의 성장 예측

한국연구재단 석사과정생연구장려금 과제 성과 · 투고 예정 Python · GPU 샘플러 · Google BigQuery(SQL) · OpenAlex · L2 로지스틱 회귀

> **논문 초록 114,066건 · 미국 특허 21,028건으로 3년 뒤 성장할 기술 토픽을 예측해 AUC 논문 0.876 · 특허 0.746, 성장 이유를 토픽 전이로 설명**

한계→해결 — 시점을 섞은 교차검증은 미래 정보가 섞여 성능이 부풀 → 과거 자료로만 학습하는 rolling-origin 평가(논문 13개 · 특허 11개 결과연도). 토픽 모델까지 기준연도마다 다시 추정해 기준연도 이후 문헌을 빼도 AUC 논문 0.828 · 특허 0.691

2025 – 2026
개인 연구 · 제1저자

Fixed-K Shrinkage BNTM with AWSGHMC Inference

SCI급 학술지 투고 예정 Python · NumPy · SG-MCMC(AWSGHMC · SGHMC · SGLD) · MH-within-Gibbs · 베이지안 추론

> **토픽 수를 데이터로 정하는 토픽 모델과 샘플러를 설계해, 직접 설계한 모의실험 데이터 5종 모두에서 토픽 수를 정확히 복원(10 seed)하고 실데이터 2종에서 perplexity 최저 달성**

한계→해결 모의실험 기준으로 맞춘 샘플러 설정이 실데이터의 큰 에너지 범위에서 작동하지 않음(한 구간에 갇힘) → 구간 폭을 데이터 에너지 범위에 비례하도록 바꿔 정상화

2025 – 2026
제1저자

AWSGLD를 이용한 전이 네트워크 토픽 모델 추론

한국자료분석학회지 28(1) 109–121 게재 Python · AWSGLD · TNTM

> **Simplex 제약 때문에 경사 기반 추론이 어려운 TNTM에 AWSGLD를 적용해 SGD 대비 토픽 다양성 0.48 → 0.96(2배), 잡음 조건에서 SGLD 대비 perplexity 약 10배 개선**

한계→해결 토픽 수 K를 미리 정해야 하고 잡음이 커지면 이점이 줄어듦 → 후속 연구 BNTM에서 희소 사전분포와 AWSGHMC로 해결

실무 경험

2023.12 – 2024.03
팀 2명

JERESFARM · 데이터 분석 인턴

스마트팜 Python · statsmodels(ARIMA · VAR · VECM) · scikit-learn · LGBM

> **현장 생육 데이터로는 결론을 낼 수 없음을 검정으로 확인하고, 공공 데이터로 과제를 다시 정해 Test F1 0.81 모델과 환경 임계값을 도출, 다음 작물의 센서 측정 설계까지 연결**

한계→해결 테스트 데이터가 10%뿐이라 R^2 0.99는 과적합으로 판단, 원인을 종속변수 관측 부족으로 규명 → ① 농촌진흥청 공공 데이터로 작물별 최적 환경과 토지에 맞는 작물을 찾는 6종 작물 다중 분류로 전환 ② 다음 작물(딸기) 농장 사전 조사 · 카메라 센서 구성 협의

연구과제 참여

2025 – 2026 **TNTM을 활용한 임베디드 시스템 문서의 주제 흐름 분석** · 연구책임자 · 한국연구재단 석사과정생연구장려금 · RS-2025-25437035

2024 – 2027 **베이지안 추론을 위한 적응적 가중 SGMCMC 알고리즘** · 참여연구원 · 한국연구재단 · RS-2024-00352792 · 2차년도 샘플러 구현 · 실험 · 분석 전담

2025 – 2026 **초격차산업기반표준전문인력양성** · 참여연구원 · KIAT · RS-2025-02215617 · 표준 프로젝트 2건

수상

2026 **한국자료분석학회 하계학술대회 포스터논문 장려상** · Fixed-K Shrinkage BNTM with AWSGLD Inference · 제1저자

2023 **고려대학교 빅데이터사이언스학부 통계학술제 최우수상** · 택시 수요 분석 · 팀 3명

2023 **미래모빌리티 및 세종지역혁신 아이디어 공모전 장려상** · Smart Green-STOP · 3D 구현 담당 · 세종특별자치시

프로젝트 직무 관련 · 성과 순

2025.03 – 2025.09
대학원생 멘토 · 멘티 1명

파인튜닝과 CAG 결합 대화형 AI 성능 개선 연구 (기후정책)

에코업혁신융합대학사업단 학부생 연구원 프로그램 · 포스터 발표 QLoRA(4bit) · CAG(KV 캐시) · BLEU · ROUGE · BERTScore · CHRF · METEOR · TER

> **파인튜닝 모델에 문서를 KV 캐시로 미리 올리는 CAG를 붙여 BLEU-1 0.235 → 0.600(2.6배), TER 318.7 → 76.9(75.9%↓), 반복 생성 편차 79% 감소**

2025
개인

국제 메타데이터 표준 통합 LLM 기반 그래프 증강 추천시스템

수업 프로젝트(A+) · KIAT 표준전문인력양성 과제 성과 Python · LLM(LLMRec) · LightGCN · ISO 3166-1 · BCP 47 · 대응표본 t-검정

> **LLM이 만든 메타데이터를 국제 표준으로 정규화해 표준 적합률 48.4% → 91.4%(43.0%p↑), 상호운용성 0% → 80.3%, 추천 성능 손실 없음 · 과목 A+**

2024 – 2025
팀 2명 · 파이프라인 전 구간

sLLM + Advanced RAG 기반 SONY 제품 설명서 챗봇

LangChain · Chroma · bge-m3 · Re-rank · KoAlpaca-7B · Tavily · Streamlit

> **제품 6종 설명서를 한 창구에서 검색하고 답변마다 파일명 · 페이지 번호를 반환하는 RAG 챗봇 구현, 반환 페이지를 원문과 대조해 출처 확인**

한계→해결 7B 모델 답변이 매끄럽지 않음 → 원인을 모델 크기 · 프롬프트 · 청크 경계 · 중복 출처로 분석. 도메인 적응은 후속 LoRA 파인튜닝 연구, 파인튜닝 모델의 출처 부재는 FT+CAG 연구로 이어서 다룸

2025
개인

AWSGLD-TNTM 기반 미국 자율주행 · 자동차 TBT 규제 분석

KIAT 표준전문인력양성 과제 성과 Python · AWSGLD-TNTM · LDA

> **미국 Federal Register 규제 원문에 AWSGLD-TNTM을 적용해 LDA 대비 Topic Coherence 0.42 → 0.5743(약 37%↑), 규제 흐름을 3단계로 정리**

협업 · 리더십

2025.03 – 09 **학부생 연구원 프로그램 대학원생 멘토** · 멘티 1명과 연구 주제 구체화 · 방법론 선정 · 실험 설계를 함께 진행해 포스터 발표까지 완료

2022 – 2023 **마케팅 서포터즈 4건 · 예큐레이션 5인 팀 리더** · 콘텐츠 기획과 이벤트 운영을 이끌어 콘텐츠 29건 총 조회 3,671회

기술

언어 · 자격	Python, R, SQL, Git, CUDA · ADsP(데이터분석 준전문가, 2023.11)
ML · DL	PyTorch, TensorFlow, scikit-learn, Transformers, PEFT(LoRA · QLoRA), OpenPCDet, LangChain, Chroma
통계 · 추론	SGLD · SGHMC · SGNHT · AWSGLD · AWSGHMC · MH-within-Gibbs 구현, 시계열(ARIMA · VAR · VECM), 베이지안 검정