

김다연 (Dayeon Kim)

GitHub: github.com/Kim-Da-yeon | 고려대학교 세종캠퍼스 빅데이터사이언스학과 석사과정

SUMMARY

- KCI 등재지 한국자료분석학회지(JKDAS)에 제 1 저자 논문 2 편 게재, SCI 급 학술지 1 편 투고 예정 (베이지안 추론·토픽 모델링, 모두 제 1 저자)
- NRF 석사과정생연구장려금 PI(연구책임자) 선정, BNTM 확장 연구를 제 1 저자로 진행 중
- 정형·비정형 데이터 전반에 걸쳐 회귀·양상불·군집·베이지안·딥러닝·LLM·토픽 모델링 등 다양한 방법론 실전 적용 경험
- 자율주행·모빌리티(교통)·스마트팜 등 실제 프로젝트로 다뤄본 도메인 경험을 바탕으로 문제 정의부터 결과 해석까지 수행
- 다수 모델을 정량 지표(R^2 , Coherence, BEV AP 등)로 비교·선택하고 결과를 의사결정으로 연결하는 문제 해결 능력

학력

고려대학교 세종캠퍼스

2025.03 - 현재

빅데이터사이언스학과 석사과정 (졸업예정: 2027.02)

- 석사 논문: Fixed-K Shrinkage Bayesian Transition Network Topic Model with AWSGHMC Inference
- 지도교수: 전수영 교수

고려대학교 세종캠퍼스

2021.03 - 2025.02

빅데이터사이언스학부 학사 (부전공: 자율주행시스템학과)

출판물

Kim, D., & Cheon, S. (2026, SCI 투고 예정). Fixed-K Shrinkage Bayesian Transition Network Topic Model with AWSGHMC Inference.

- [배경] 선행 연구(JKDAS 28(1), AWSGLD)에서 남은 두 한계 — 토픽 수 K 사전 고정, 잡음 환경에서 이점 상쇄 — 를 문제 정의로 삼아 확장
- [문제] 기존 TNTM 은 토픽 수 K 를 사전에 고정해야 하고 Simplex 제약으로 경사 기반 추론이 어려움 → 고차원 다중 모드 사후분포에서 로컬 트랩 발생
- [방법] Logistic-Normal 모수화 + Sparse Dirichlet Prior 로 활성 토픽 수 자동 결정, AWSGHMC 하이브리드 추론 (MH-within-Gibbs + Dirichlet + 미니배치 AWSGHMC) 설계
- [결과] 모의실험($K_{true}=30$)에서 30 개 진짜 토픽을 정확 복원(Sentence Accuracy 1.00, 파라미터 복원 오차 0.09) — 다른 샘플러는 로컬 트랩에 갇혀 14~19 개만 복원. FAERS·NTSB·모의실험 모두에서 AWSGHMC 가 최저 에너지 도달(SGLD 계열은 3~16% 더 높은 에너지에 정착), Document-completion perplexity 가 HTMM·LDA·다른 샘플러 대비 모든 조건에서 최저
- [활용 기술] Python, PyTorch, NumPy, SciPy

Kim, D., & Cheon, S. (2026). Inference of Transition Network Topic Model using AWSGLD. 한국자료분석학회지 (JKDAS), 28(1), 109-121.

- [문제] TNTM 은 문장 간 토픽 전이를 모델링하지만 SGD/SGLD 등 기존 추론은 잡음 환경에서 안정성·확장성 저하
- [방법] TNTM 에 AWSGLD 적용 — 사후분포를 구간별 적응 가중해 다중 모드 사후 평탄화, 로컬 트랩 탈출 및 대규모 데이터 확장성 확보
- [결과] 원본 데이터에서 SGD 대비 토픽 다양성 2 배($0.48 \rightarrow 0.96$), 잡음 50 개 조건 SGLD 대비 Perplexity 약 10 배 우수 — Coherence·Diversity·Perplexity 종합 비교로 검증
- [활용 기술] Python, PyTorch, NumPy

Kim, D., Cheon, S., & Joo, A. (2025). Fine-tuning Study of LoRA-based sLLM in Autonomous Driving Domain. 한국자료분석학회지(JKDAS), 27(3), 769-780.

- [문제] 도메인 특화 sLLM 의 응답 품질 개선 필요, 전체 파라미터 파인튜닝은 자원 부담 큼

- [방법] Phi-4-mini-instruct(3.8B) 기반, BDD-X 데이터셋(주행 영상 6,970 개·주석 26,228 개)으로 전체 파라미터의 약 0.01%만 조정하는 LoRA 파인튜닝 수행. RAG(k=1,3,5)와 정량 비교
- [결과] ROUGE-1 0.0888 → 0.1495 로 약 68% 향상(RAG 대비), 응답 시간 평균 1.145 초. Traffic violations 확장 실험(약 7 만 건)에서도 Accuracy 0.745·Macro F1 0.731 로 도메인 전이 능력 검증
- [활용 기술] Python, PyTorch, Transformers, LoRA

참여 연구

- 한국연구재단(NRF) - 베이지안 추론을 위한 적응적 가중 SGMCMC 알고리즘

2024 - 2027
- 참여연구원 (RS-2024-00352792)
- 고차원 확률 모델의 효율적 사후분포 추정을 위한 SGMCMC 기반 추론 알고리즘 연구 및 대규모 텍스트 토픽 모델 학습 안정성 분석
- 한국연구재단(NRF) - TNTM 을 활용한 임베디드 시스템 기술 문서의 주제 흐름 분석

2025 - 2026
- 연구책임자(PI) (석사과정생연구장려금지원사업, RS-2025-25437035)
- 문장 간 주제 전이 구조를 반영하는 토픽 모델 설계 및 대규모 텍스트의 의미 구조·시간에 따른 토픽 변화 모델링 수행
- KIAT - 초격차산업기반표준전문인력양성

2025 - 2026
- 참여연구원 (RS-2025-02215617) — 표준학 융합전공 과정 이수 중

실무 경험

- JERESFARM, 예산

2023.12 - 2024.03
- 데이터 사이언티스트 인턴
- [상황] 작물 생육 데이터가 하루 1 회 측정(18 개 개체, 20 일 관측)에 그쳐 종속변수 관측이 부족, 보간으로 채운 값의 정확도 검증 수단도 부재
 - [현장 데이터 분석] 결측 구간 선형·spline 보간 후 시계열(VAR, VECM)로 유의성 검정 → 종속변수에 유의한 독립변수 도출되지 않음을 정량 확인. Lasso 회귀로 유의 변수 15 개 후보 추출하되 Y 관측 부족에 따른 예측 해석 한계를 결론에 명시적으로 보고
 - [공공 데이터 확장] 현장 데이터 한계를 근거로 농촌진흥청 공공 데이터로 재접근 → 6 개 모델(Decision Tree, SVM, K-NN, Bagging, Random Forest, LGBM) 비교하여 6 종 작물 다중 분류. LGBM 최종 선정(Train-Test 격차가 세 앙상블 중 가장 작아 과적합 위험 최소), Feature Importance 로 온도>일사량>CO2 영향력·PDP 로 임계 구간 도출
 - [개선 제안] 데이터 한계의 원인을 측정 설계 단계로 규명하고, 현장 담당자와 카메라 사양 등 센서 환경 구축 요건 협의
 - [활용 기술] Python, scikit-learn, statsmodels, LGBM

기술 능력

프로그래밍·도구: Python, R, SQL, Git, GPU Computing (CUDA)

ML/DL: PyTorch, TensorFlow, scikit-learn, Transformers (LoRA/QLoRA), Pandas, statsmodels

자격증: ADsP

수상

- 한국자료분석학회 하계학술발표대회 포스터논문 부문 장려상

2026
- [주제] Fixed-K Shrinkage Bayesian Transition Network Topic Model with AWSGLD Inference (제 1 저자)
 - [내용] TNTM 의 토픽 수 고정·Simplex 제약 한계 극복 → Logistic-Normal 모수화로 활성 토픽 수 자동 결정, AWSGLD 로 다중 모드 사후분포 로컬 트랩 완화
 - [성과] 시뮬레이션·실제 코퍼스에서 다양한 조건(파라미터 중첩·희소 토픽) 대비 우수성 정량 입증

통계학술제 최우수상, 고려대학교 빅데이터사이언스학부

2023

- [문제 정의] 택시 요금 인상 후 기사·이용자 동반 이탈로 이용률이 하락하는 상황에서, 자치구별 택시 수요·공급 불균형을 해소할 데이터 기반 배차 전략 부재
- [데이터·전처리] 서울빅데이터캠퍼스·국가공간정보포털·서울 열린데이터광장·철도 데이터 포털에서 서울시 택시운행분석(2015.1~2016.4)·표준노드아이디 DB·행정구역·유동인구·버스정류소·도시철도역사 6 종 병합
- [분석 방법] 5 개 권역(도심·동북·동남·서북·서남)별 요일 승차 패턴 매핑, QGIS 로 자치구별 공간 분포 시각화, 택시 수요 기반 밀집 지역 클러스터링, 공차율(공차건수/(승차+공차)·100) 웹 인터페이스 제작
- [핵심 결과] 계층적 군집분석(Ward.D)과 대중교통 분포·유동인구·택시 이용량 3 변수의 증감 조합으로 25 개 자치구를 8 개 군집으로 분류 — 각 군집별 차별화된 배차·서비스 전략 제안
- [성과] 학술제 최우수상 수상
- [활용 기술] Python, R, QGIS

미래모빌리티 및 세종지역혁신 아이디어 공모전 장려상

2023

- IoT 센서·압전 하베스팅을 결합한 친환경 스마트 정류소(Smart Green-STOP) 모델 제안

데이터 사이언스 및 연구 프로젝트

SGMCMC 기반 3D 객체 탐지 모델 최적화

2025

- [문제] 기존 Adam 기반 3D 객체 탐지는 점추정만 가능하여 파라미터 불확실성 추정 한계 → 베이지안 샘플링 기반 대안 탐색
- [방법] KITTI 데이터셋·OpenPCDet 프레임워크의 CT-Stack 백본·PointPillars 아키텍처·GCIoU 손실 환경에서 SGD·SGLD·SGHMC·SGNHT 4 종 SGMCMC 기법을 동일 조건으로 적용(80 epoch, batch 8, OneCycle LR), 기존 Adam 기준 모델과 비교
- [결과] Adam 65.15% vs SGHMC 49.59%(BEV AP Moderate) — 이 과제에서는 적응적 학습률이 확률적 탐색보다 결정적임을 확인. SGMCMC 계열 내에서는 모멘텀 기반 SGHMC가 무작위 보행 방식(SGLD 25.67%) 대비 뚜렷한 우위
- [시사점] 최저 손실(SGHMC 0.813)과 최고 성능(Adam)이 불일치 — 손실 최소화가 과업 성능을 보장하지 않음을 확인, Adam·SGHMC 하이브리드 방향 도출
- [활용 기술] PyTorch, OpenPCDet, CUDA, Python

AWSGLD-TNTM 을 활용한 텍스트 트렌드 분석

2025

- [문제] 다년간 누적된 텍스트의 주제 변화·트렌드 분석에서 LDA 의 토픽 일관성·중복 한계 → 토픽 전이 구조를 반영한 동적 트렌드 분석 필요
- [방법] 미국 Federal Register 규제 문서 160 건 대상 AWSGLD-TNTM 적용으로 K=8 토픽 도출, 연도별 토픽 전이 네트워크 구축
- [결과] LDA 대비 Topic Coherence 약 37% 향상(0.42 → 0.5743), Topic Diversity 0.82 로 토픽 중복도 감소 — 행정 유예기(2020-21) → 환경·화학 규제 강화(2022-23) → 디지털 안전 확산기(2024-25)의 3 단계 패러다임 변화 정량 규명
- [활용 기술] Python, PyTorch, NumPy

국제 메타데이터 표준 통합 LLM 기반 그래프 증강 추천시스템

2025

- [문제] LLM 이 생성한 자유 텍스트 메타데이터의 표면형 비일관성(USA·United States·America 등) → 시스템 간 상호운용성·데이터 통합 저해
- [방법] LLMRec 이 생성한 넷플릭스 메타데이터를 ISO 3166-1·BCP 47 기반 정규화 레이어로 통합, 정규화 임베딩으로 LightGCN 추천 성능도 함께 검증
- [결과] 표준 형식 적합률 0.484 → 0.914 로 개선, 정규화 불가 항목·형식 위반 자동 검출 — 추천 성능은 통계적으로 유의한 변화 없이 데이터 품질 확보
- [활용 기술] Python, LLM (GPT/LLaMA/Gemma), LightGCN

자전거 대여 시스템 데이터베이스 설계

2024

- [문제] 자전거 대여 서비스 요구사항 기반 데이터 무결성·조회 효율 확보 필요
- [방법] E-R 다이어그램 기반 논리·물리 모델 설계 및 정규화 적용, 복합 SQL 쿼리(JOIN, 서브쿼리, 집계함수) 구현

- [결과] 일반 운영 시나리오(대여·반납·회원 관리) 처리 검증, 정규화를 통한 중복·이상 방지
- [활용 기술] MySQL, SQL

교육 및 리더십

연구실 대표 2025 - 2026

- 연구실 안전관리·장비 운영 및 세미나 일정 조율, 구성원 간 운영 업무 총괄

학습 멘토 (Python / 미적분학 / Excel) 2022 - 2025

- 프로그래밍·수학 개념을 실습 중심으로 구조화하여 전달, 개별 상담을 통한 학습 지속성 지원

기타 경험

미국 UNLV 4 주 연수 + CES 2025 현장 참관 2025

- UNLV 미래 모빌리티·AI 기술 글로벌 연수 4 주 수료, CES 2025 참관을 통한 자율주행·로보틱스·온디바이스 AI 등 글로벌 산업 트렌드 분석 — 영어 환경·다국적 참가자와의 협업 경험