이력서

김다연

abcde0405@naver.com | 포트폴리오 kim-da-yeon.github.io | GitHub Kim-Da-yeon



핵심 요약

토픽 모델과 샘플러를 직접 설계해 문서 완성 perplexity를 HTMM 대비 41.6% 낮춘 Data Scientist · ML Researcher입니다.

경험 1. 새 토픽 모델 BNTM 설계 · 모의실험 데이터 생성 | perplexity 41.6% 감소 · 토픽 수 정확 복원

- 모델 비교: 실데이터(FAERS) 문서 완성 perplexity HTMM 54.99 → BNTM 32.13 / 샘플러 비교: 모의실험 정답 20토픽에서 추정 토픽 수 SGHMC 15.4개 → AWSGHMC 20.0개(SCI급 투고 예정 · 포스터논문 장려상)

경험 2. 3D 객체 탐지 SGMCMC 적용 | 최적화기 5종 비교 · BEV AP Adam 65.15% · SGHMC 49.59%

- KITTI · PointPillars에서 SGLD · SGHMC · SGNHT를 직접 구현해 Adam · SGD와 같은 조건으로 비교, SGMCMC 중에서는 SGHMC가 가장 높음

경험 3. 서울시 택시 수요 · 공급 분석 | 통계학술제 최우수상

- 공공 데이터 6종을 병합해 25개 자치구를 6개 군집으로 분류하고 공차율 웹과 택시 서비스 개선 방향 제시

학력

2025.03 – 2027.02 (졸업예정) **고려대학교 일반대학원 빅데이터사이언스학과 석사과정**

2021.03 – 2025.02 **고려대학교 세종캠퍼스 빅데이터사이언스학부 학사** · 융합전공 자율주행시스템학과

실무 경험 · 후속 프로젝트

2023.12 – 2024.04 · 인턴 2명

JERESFARM · 데이터 분석 인턴

스마트팜 Python · statsmodels(VAR · VECM) · scikit-learn · Lasso

분석 인력이 없던 농장에서 생육 데이터(개체 18개 · 20일)로는 영향요인을 규명할 수 없음을 검정으로 확인하고, 후속 센서 · 카메라 배치와 측정 항목을 현업과 협의해 제안

2024 1학기 · 팀 3명

환경에 따른 최적 작물 예측 (JERESFARM 인턴 후속)

통계학과 머신러닝 PBL · 결과 · 코드 농장 전달 Python · Pandas · scikit-learn · LightGBM · Feature Importance · PDP

농촌진흥청 공공 데이터(원본 827,080건, 학습 · 평가 90,000건)로 작물 5종과 그 외(랜덤) 클래스를 분류하는 모델 6개를 비교, Test F1 상위 앙상블 3개 중 격차가 가장 작은 LightGBM(Test 0.81, 작물 5종 평균 약 0.77, 격차 0.03 vs Bagging 0.17 · RF 0.21)을 선정하고 결과와 코드를 JERESFARM에 전달

연구 · 논문

2025 – 2026 · 제1저자 · 공저 2인

Fixed-K Shrinkage Bayesian Transition Network Topic Model with AWSGHMC Inference

SCI급 학술지 투고 예정 Python · NumPy · SG-MCMC(AWSGHMC · SGHMC · SGLD) · MH-within-Gibbs · 베이지안 추론

기존 토픽 모델의 한계를 보완한 새 토픽 모델 BNTM과 샘플러 AWSGHMC를 직접 설계하고, 정답을 아는 모의실험 데이터(환경 5종)를 생성해 검증 · 모델 비교에서 실데이터(FAERS) 문서 완성 perplexity를 HTMM 54.99 → 32.13(41.6%↓)으로 낮추고, 샘플러 비교(모의실험 정답 20토픽)에서 추정 토픽 수를 SGHMC 15.4개 → AWSGHMC 20.0개로 정확 복원 · 포스터논문 장려상

수행 Logistic-Normal 모수화(Simplex 제약 제거) + Sparse Dirichlet Prior(최대 토픽 수 K는 고정, 그중 실제로 쓰이는 토픽 수는 데이터가 결정) + AWSGHMC(멀티모달 사후분포의 로컬 트랩 탈출)를 결합한 새 모델 BNTM과 샘플러를 설계

포스터

2025 – 2026 · 연구책임자 · 제1저자

전이 네트워크 토픽 모델을 이용한 임베디드 기술의 성장 예측

한국연구재단 석사과정생연구장려금 과제 성과 · 투고 예정 Python · GPU 샘플러 · Google BigQuery(SQL) · OpenAlex · L2 로지스틱 회귀

논문 초록 114,066건 · 미국 특허 21,028건(BigQuery SQL로 직접 추출)으로 3년 뒤 성장할 기술 토픽을 예측해 AUC 논문 0.876 · 특허 0.746(무작위 0.5, 토픽 모델까지 기준연도별 재추정 시 0.828 · 0.691), 성장 이유를 토픽 전이로 설명

수행 연도별 전이행렬을 계층 사전분포로 묶어 TNTM 확장(K=40, AWSGLD). 전이 네트워크에서 유입 · 자기전이 · 유입 출처 · 구조 변화 변수 8개를 직접 정의하고 데이터 변수 14개와 함께 예측 모형 구성

2025 – 2026
제1저자

AWSGLD를 이용한 전이 네트워크 토픽 모델 추론

한국자료분석학회지 28(1) 109–121 게재 Python · AWSGLD · TNTM

TNTM 추론을 MH-Gibbs + AWSGLD로 바꿔 IMDB 리뷰 1,000문장의 문장마다 무작위 단어 50개를 넣은 조건에서 perplexity를 SGLD보다 약 8배 낮춤(m=30). 토픽 다양성은 SGD 0.48 대비 0.96(SGLD와 같음)

수행 문장 토픽은 MH-Gibbs, 전이행렬 · 단어-토픽 분포는 AWSGLD로 추론. 추론에 필요한 미분식을 유도해 구현하고, 문장마다 무작위 단어 0 · 50 · 100개를 넣어 SGD · SGLD와 비교

논문 DOI

연구과제 참여

2025 – 2026 **TNTM을 활용한 임베디드 시스템 문서의 주제 흐름 분석** · 연구책임자 · 한국연구재단 석사과정생연구장려금 · RS-2025-25437035

2024 – 2027 **베이지안 추론을 위한 적응적 가중 SGMCMC 알고리즘** · 참여연구원 · 한국연구재단 · RS-2024-00352792 · 2차년도 샘플러 구현 · 실험 · 분석 전담

2025 – 2026 **초격차산업기반표준전문인력양성** · 참여연구원 · KIAT · RS-2025-02215617 · 표준 프로젝트 2건

수상

2026 **한국자료분석학회 하계학술발표대회 포스터논문 장려상** · Fixed-K Shrinkage BNTM Inference with AWSGLD · 제1저자 (AWSGHMC 버전은 투고 예정)

2023 **고려대학교 빅데이터사이언스학부 통계학술제 최우수상** · 택시 수요 분석 · 팀 3명

2023 **미래모빌리티 및 세종지역혁신 아이디어 공모전 장려상** · Smart Green-STOP · 3D 구현 담당 · 세종특별자치시

프로젝트 직무 관련 · 성과 순

2023
팀 3명 · QGIS 시각화 · 분석 코드

택시 수요 분석을 통한 택시 서비스 개선 방안 마련

통계학술제 최우수상 R · 계층적 군집분석(Ward.D) · QGIS · 공공 데이터 병합

공공 데이터 6종을 직접 구해 병합하고 공차율 웹을 만들어 서울 25개 자치구를 6개 군집으로 나누고, 택시 서비스 개선 방향을 정리해 통계학술제 최우수상

포스터

2025
개인

3D 객체 탐지 최적화를 위한 SGMCMC 기법 적용

수업 프로젝트(A+) PyTorch · CUDA · OpenPCDet · KITTI · PointPillars · SGLD · SGHMC · SGNHT · Adam

KITTI 3D 객체 탐지에서 SGMCMC 3종을 직접 구현해 Adam · SGD와 같은 조건으로 비교, BEV AP Adam 65.15% > SGHMC 49.59% > SGD 49.07%로 기존 Adam의 우위를 확인 · 과목 A+

저장소

2026.10 – 11
팀 3명 · 공고 대조(온톨로지) · 배포 단독

사장님 비서: 온톨로지 · 멀티에이전트 기반 소상공인 행정 AI 서비스

2026 하반기 AI 경진대회 학생 부문 출품(결과 대기) · Vercel 배포 완료 멀티에이전트 · RDF 온톨로지 · SHACL · Claude API · FastAPI · PyMuPDF · Vercel · Claude Code · Codex CLI

LLM 에이전트 12개 · RDF 온톨로지 · 규칙 판정기를 결합해 지원사업 공고 조건과 근거 문구를 제시하는 서비스, 근거 인용 오류 0건 · 잘못된 일치 0건, 가상 사례 30건 정답 일치 27/30(첫 측정 18/24 → 오답 분석 · 수정 후 21/24, 추가 공고 6/6)

배포 사이트 저장소

활동 · 리더십

2025.03 – 현재 **DLM연구실 대표** · 구성원 소통 · 세미나 · 공동 연구 자원 관리

2025.03 – 09 **학부생 연구원 프로그램 대학원생 멘토** · 멘티 1명과 연구 주제 · 방법론 · 실험 설계를 함께 진행해 포스터 발표까지 완료

기술

언어 · 자격	Python(Pandas), R, SQL(MySQL · Google BigQuery), Git, CUDA, Excel, ROS · Autoware(학부 실습) · ADsP(2023.11) · OPIc IM1(2026.09)
ML · DL	PyTorch, TensorFlow, scikit-learn, Transformers, PEFT(LoRA · QLoRA), OpenPCDet, LangChain, Chroma
통계 · 추론	SGLD · SGHMC · SGNHT · AWSGLD · AWSGHMC · MH-within-Gibbs 구현, 시계열(VAR · VECM), 베이지안 검정